




머신러닝(Machine Learning)을 활용한 조세·재정 정책의 평가와 설계

2020. 12

정재현 · 이환웅



머신러닝(Machine Learning)을 활용한 조세·재정정책의 평가와 설계

2020. 12

정재현 · 이환웅

서 언

4차 산업혁명의 한 축을 담당하고 있는 빅데이터의 발전과 함께, 이를 분석하기 위한 인공지능이 다양한 분야에 활용되고 있다. 그중 머신러닝은 데이터 기반 학습을 통하여 작업의 성능을 향상시키는 것으로 기존 IT 분야뿐만 아니라 최근에는 경제학, 그중에서도 정책 설계와 효과성 평가에도 머신러닝의 적용 방안에 대한 논의가 활발히 진행되고 있다. 머신러닝은 기존의 분석방법과 비교해 ‘예측’의 문제 해결에 탁월하여, 정책의 평균효과만을 살피던 기존의 분석 방식에서 더 나아가, 정책이 더 큰 효과를 거둘 수 있는 특정 집단을 예측해내는 등 한정된 자원을 더 효율적으로 사용할 수 있게 한다. 특히 최근 실증증거에 기반한 정책 설계(Evidence-based policymaking)의 중요성이 대두되면서, 우리나라 정부에서도 조세특례심층평가, 재정사업심층평가 제도 등을 통해 조세 및 재정정책의 운용 성과를 점검하여 정책의 효과성을 증진시키는 작업을 수행해오고 있으며, 바로 이러한 점에서 머신러닝을 접목하여 정책의 효과성을 좀 더 엄밀하게 평가하고 이를 정책 설계에 반영하려는 시도에 주목할 필요가 있다.

본 연구에서는 정책의 평가 및 설계에 머신러닝이 활용되고 있는 현황을 살펴보고, 현재 시행되고 있는 조세 및 재정정책에 대한 머신러닝 분석을 수행하여 제도 개선 방안을 제시하고자 하였다. 우선 해외연구를 중심으로 정책 효과성 평가에 머신러닝이 어떻게 쓰이고, 그러한 연구결과를 바탕으로 실제 정책 설계에 어떻게 활용되고 있는지를 파악하였다. 그리고 머신러닝 분석방법이 우리나라에서 현재 시행 중인 조세특례제도의 효과성 평가를 어떻게 보완할 수 있는지를 분석하고 검토하였다. 이어서 정책 및 사업대상자의 선정에 있어 머신러닝을 통해서 정책의 효과를 최대한 끌어낼 수 있는 방안을 노인자살 예방사업을 예로 들어 논의하였다. 본 연구를 통해 머신러닝 분석을 활용하여 정책을 평가하고 설계하여 조세 및 재정정책의 효과성

을 제고하는 데에 정책적 시사점을 제공할 수 있을 것으로 기대한다.

본 연구는 본원의 정재현 박사와 이환웅 박사가 공동으로 집필하였다. 저자들은 연구 착수 단계부터 최종보고서 집필까지의 과정에서 통찰력 있는 조언을 아끼지 않은 원내 연구위원들과 원외 전문가들에게 감사의 뜻을 전하고 있다. 아울러, 연구 집필 과정에서 기초자료 수집과 문헌정리 등에 힘써준 조은빛 선임연구원과 연구행정 및 출판 과정을 도와준 연구사업팀과 지식정보팀에도 감사의 뜻을 전한다.

마지막으로 본 보고서의 내용은 저자들의 개인적인 의견이며, 한국조세재정연구원의 공식적인 견해가 아님을 밝혀둔다.

2020년 12월

한국조세재정연구원

원장 김 유 찬

요약 및 정책적 시사점

머신러닝은 알고리즘 스스로 데이터 기반 학습을 통하여 작업의 성능을 향상시키는 것으로, 기존의 모델을 활용한 추정과 비교해 더 나은 예측치를 제공한다. 최근 빅데이터의 성장과 컴퓨팅 성능의 발달로 머신러닝이 다양한 분야에 활용되고 있으며, 특히 경제학에서도 머신러닝 기법을 활용하는 연구가 활발하게 진행되고 있다. 개인 컴퓨터에서도 머신러닝 작업을 구현할 수 있을 정도의 높은 컴퓨팅 성능과 사용자 친화적인 통계패키지가 일반화되었으며, 대규모 미시행정 자료뿐 아니라 위성사진 및 사회관계망 데이터 등 비정형 데이터에 대한 접근이 용이해져, 조세·재정정책 및 규제설계와 효과성 평가에 머신러닝의 활용 방안에 대한 논의가 활발하다.

본 연구에서는 정책의 평가 및 설계에 머신러닝이 활용되고 있는 현황을 살펴보고, 현재 시행되고 있는 조세 및 재정정책에 대한 머신러닝 분석을 수행하여 제도 개선 방안을 제시하고자 하였다.

서론에 이어 제II장과 제III장에서는 최근 새로운 실증분석방법 중 하나로 주목을 받고 있는 머신러닝에 대해 개괄하고 정책평가와 설계에서 연구진들의 높은 관심을 끌고 있는 이유는 무엇인지, 그리고 대표적인 머신러닝 알고리즘인 결정트리와 랜덤포레스트에 대해 살펴보았다. 또한, 머신러닝을 활용하여 정책의 효과성 평가를 실시한 연구 사례와, 예측모델을 개발하여 정책 대상자를 선별한 최신의 연구결과들을 정리하여 시사점을 도출하였다. 제IV장에서는 머신러닝이 정책의 실질적 효과를 살펴보는 데 탁월한 점에 주목하여, 머신러닝 분석방법이 우리나라에서 현재 시행 중인 조세특례정책에 대한 기존의 효과성 분석, 즉 정책의 평균효과를 제시하던 기존 연구방법을 어떻게 보완할 수 있는지를 살펴보고 기존의 방법론 대비 유용성을 실증분석하였다. 2019년 수행한 조세특례평가 중, 비과세종합저축에 대한 조세특례 정책을 선정하여 머신러닝 알고리즘 중 하나인 커질포레스트를 활용

하여 도출한 정책효과 추정치가 기존 선형회귀를 활용한 정책의 효과성 분석과 대비해 얼마나 개선된 정책효과성 분석결과를 도출할 수 있을지를 탐색해보았다. 그 결과, 이전의 분석결과는 비과세종합저축 과세특례 제도가 평균적으로 유의미한 효과가 없음을 제시한 반면, 머신러닝 분석을 통해 본 제도의 혜택이 저축여력이 있는 노령층 등 특정 집단에 집중되었을 수 있음을 찾아내었다. 이렇게 머신러닝은 정책의 효과성 분석에 있어 기존의 평균 효과 분석에서 더 나아가 특정 집단을 대상으로 한 정책효과나 행태변화의 분석을 가능하게 하여, 정책입안자로 하여금 좀 더 통찰력 있는 제도의 설계나 효과성 평가를 가능하게 한다.

제V장에서는 머신러닝이 정책 시행에 따른 효과를 예측하고 ‘누가’ 가장 적절한 정책 대상자가 되어야 하는가를 다루는 정책 예측의 문제 해결에 탁월한 점에 주목하여, 정책 및 사업대상자의 효율적인 선정을 통해서 정책의 효과를 최대한 끌어낼 수 있는 방안을 논의하였다. 가령, 우리나라 복지정책의 경우 수급자의 자격요건을 가구의 소득평가액과 재산의 소득환산액을 합산한 소득인정액을 바탕으로 하고 있으나, 이러한 소득인정액이 실질적인 의식주 해결 능력을 정확히 예측하지 못하는 경우 복지의 사각지대가 발생할 가능성이 있다. 따라서 머신러닝 알고리즘이 쉽게 관측 가능한 변수들을 바탕으로 해당 정책의 효과가 더 높을 것으로 예측되는 특정 집단을 효율적으로 선별해낼 수 있다면, 복지 사각지대 문제점 개선에 효과적일 수 있음을 논의하고자 하였다. 그 예로 본고에서는 노인자살 예방사업을 선정하여, 머신러닝의 활용으로 기존 사업에 투여되는 한정된 재화가 좀 더 효과적으로 쓰일 수 있는 방안을 강구하였다. 설문조사 등의 정성평가가 아닌 노인 관련 행정 데이터 등과 머신러닝 알고리즘을 통해 사전적으로 고위험군에 해당하는 사람을 예측하고, 그들에 한정하여 자살예방정책을 실시한다면 정책에 소요되는 비용을 줄일 수 있기 때문에 효율성 측면에서의 개선을 기대할 수 있게 된다. 분석결과, 머신러닝의 Lasso 모델을 활용한 자살예측 모형은 자살 고위험군에 해당하는 사람을 기존의 모형에 비해 보다 정확하게 예측하여 행정데이터만을 활용한 고위험군의 식별 가능성을 보여주었다.

새로운 조세·재정정책이 충분한 사전점검 없이 시행되면 그에 따른 시행

착오로 인해 사회적 비용이 증가할 수 있다. 최근의 긴급재난지원금 지원 대상 선정과 관련된 논의에서 볼 수 있듯이, 정책이 의도한 효과를 극대화하기 위해서는 적절한 정책수혜자 선정은 그 무엇보다 중요한 선결과제이며, 머신러닝 방법론은 이러한 점에서 기존 분석보다 진일보한 결과를 제시해 줄 수 있다. 본고에서 다룬 이탈리아의 세금 환급 프로그램 예시와 비교·세종합저축 효과성 평가, 노인자살예방정책 사례에서 살펴볼 수 있듯이, 행정데이터를 활용하여 가장 효과가 좋을 것으로 기대할 수 있는 특정 집단을 선별하여 가용한 자원을 집중한다면 한정된 자원의 누수 없이 정책의 효과를 극대화할 수 있다.

사회관계망 데이터나 대규모 미시행정자료에 대한 접근성이 높아짐에 따라 머신러닝은 기존 분석방법으로는 해결할 수 없는 복잡한 문제에 대한 해결방안을 제시하는 유용한 툴로 각광받고 있다. 머신러닝이 기존의 실증분석방법을 어느 정도까지 근본적으로 바꿔놓을 수 있을지에 대한 논의는 계속 진행 중인바, 이미 정책효과 예측에 뛰어난 성능을 보인 만큼, 앞으로 우리나라의 다양한 정책평가와 정책 설계에도 본격적으로 활용될 것을 기대한다.

목 차

I. 서 론	13
II. 머신러닝과 빅데이터 개괄	16
1. 머신러닝의 개요	16
가. 빅데이터와 머신러닝	16
나. 실증분석에서의 머신러닝	16
2. 머신러닝 방법론	20
가. 머신러닝의 개괄	20
나. 머신러닝에서 예측의 문제	20
다. 머신러닝 관련 주요 개념	21
3. 결정트리와 랜덤포레스트	24
가. 결정트리의 특징	24
나. 결정트리의 기본구조	24
다. 결정트리 알고리즘과 과적합 방지방법	25
라. 랜덤포레스트의 개념과 특징	26
마. 랜덤포레스트의 실행	27
III. 머신러닝을 활용한 정책평가와 개선사례	29
1. 자원배분 방식 설계를 위한 머신러닝 적용 사례	30
2. 정책 수혜대상 선정에 머신러닝이 활용된 사례	31
IV. 머신러닝을 활용한 정책의 효과성 평가	40
1. 정책의 효과성 평가	40
가. 정책 효과성 평가	40
나. 정책의 이질적 처치효과	44
다. 커절포레스트의 특징	46

2. 조세정책의 효과성 평가: 비과세종합저축 과세특례를 중심으로	48
가. 분석의 개요	48
나. 분석방법	50
다. 분석결과	53
 V. 머신러닝을 활용한 재정정책 개선안	64
1. 한국의 재정정책 설계에 머신러닝 알고리즘의 활용 방안	64
가. 수급자의 기준에 대한 논의	64
나. 수급률 증대를 위한 논의	66
2. 사례분석: 노인자살 예방정책	69
가. 노인자살 현황	69
나. 대한민국의 자살 예방 정책 현황	73
다. 데이터	82
라. 예측 모형의 평가 기준에 관한 논의	87
마. 예측결과	92
바. 데이터의 한계점	106
 VI. 결론 및 정책적 시사점	110
 참고문헌	112
 부록	118

표목차

〈표 II-1〉 머신러닝 알고리즘과 예측성능	18
〈표 II-2〉 머신러닝 알고리즘과 관련 정규화 방법	23
〈표 IV-1〉 주요변수	52
〈표 IV-2〉 선형회귀 결과	53
〈표 IV-3〉 특성변수를 포함한 선형회귀 결과	54
〈표 IV-4〉 특성 중요도 주요변수	57
〈표 V-1〉 2020년 자살예방 및 지역정신보건사업 예산안 1	74
〈표 V-2〉 2020년 자살예방 및 지역정신보건사업 예산안 2	75
〈표 V-3〉 2016~2020년 보건복지부 자살예방사업 관련 예산	76
〈표 V-4〉 자살예방 관련 내역사업의 정책 내용 및 목표	78
〈표 V-5〉 2016~2020년 서울시 자살예방사업 관련 예산	80
〈표 V-6〉 변수 특성에 따른 변수 구분	86
〈표 V-7〉 혼동행렬 예시	88
〈표 V-8〉 선행연구 정리	94
〈표 V-9〉 Baseline 알고리즘의 성과지표	98
〈표 V-10〉 알고리즘의 성과지표(모든 변수 사용)	99
〈표 V-11〉 알고리즘의 성과지표(우울증관련 변수들 제외함)	100
〈표 V-12〉 AdaBoost 알고리즘의 변수별 영향력	101
〈표 V-13〉 Logit 알고리즘의 변수별 영향력	103
〈표 V-14〉 Logit-Post Lasso 알고리즘의 변수별 선택된 횟수	105
〈표 V-15〉 훈련데이터의 관측치 크기별 알고리즘 성과의 차이	107
〈부표-1〉 노인자살 위험군 예측 모형 분석 DB의 구성 항목	118

그림목차

[그림 II-1] 차량주행거리 예측을 위한 결정트리 예시	25
[그림 III-1] 이탈리아 세금환급정책 대상자 선정을 위한 결정트리	37
[그림 IV-1] 선형회귀와 커절포레스트의 이질적 처리효과 추정 비교	47
[그림 IV-2] 커절포레스트를 활용한 비과세종합저축의 이질적 효과 추정	56
[그림 IV-3] 소득분위에 따른 이질적 처리효과 추정	58
[그림 IV-4] 교육수준에 따른 이질적 처리효과 추정	60
[그림 IV-5] 직업군에 따른 이질적 처리효과 추정	61
[그림 IV-6] 종사 산업군에 따른 이질적 처리효과 추정	62
[그림 V-1] OECD 주요 회원국 20년간 자살률 추이	70
[그림 V-2] 2017년도 OECD 회원국 자살현황	70
[그림 V-3] 한국의 노인 자살률의 추이: 연령별 구분	71
[그림 V-4] 한국의 남성노인 자살률의 추이: 연령별 구분	72
[그림 V-5] 한국의 여성노인 자살률의 추이: 연령별 구분	73
[그림 V-6] 2018년 시·도별 노인(65세 이상) 자살률	108

I. 서론

머신러닝은 데이터 기반 학습을 통하여 작업의 성능을 향상시키는 것으로, 기존의 모델에 기반한 분석 작업과 비교해 예측치의 오차를 줄이는 데 특화되어 있다. 머신러닝이 많이 활용되는 스팸메일 필터를 예로 들면, 작업은 새로운 메일이 스팸인지 아닌지를 구분하는 것이고, 실제 스팸메일이 제대로 스팸으로 분류된 비율 등을 성능 지표로 고려할 수 있다. 여기서 머신러닝은 사전에 스팸과 일반 메일로 구분이 완료된 훈련데이터를 기반으로 스스로 학습하여 새로 주어진 메일 중에 스팸메일을 성공적으로 분류하는 비율을 높이는 과정이다.

최근 빅데이터의 성장과 컴퓨팅 성능의 발달로 머신러닝이 다양한 분야에 활용되고 있다. 특히, 개인 컴퓨터에서도 머신러닝 작업을 구현할 수 있을 정도의 높은 컴퓨팅 성능과 사용자 친화적인 통계패키지가 일반화되었으며, 대규모 미시행정 자료뿐 아니라 위성사진 및 사회관계망 데이터 등 고차원 데이터에 대한 접근이 용이해져, 실증분석에서 머신러닝 기법을 활용한 연구들이 양산되고 있다. 최근에는 효과성 평가(Impact evaluation)와 그에 따른 정책의 설계(Policy design)에도 머신러닝의 적용 방안에 대한 논의가 활발히 진행되고 있다.

본 연구에서는 우선 머신러닝에 대한 이해를 높이기 위해 머신러닝의 기본 개념을 정리하고 머신러닝의 필수 구성요소들에 대해 개괄한다. 명시적인 규칙을 설정하지 않고 프로그램 스스로 학습하는 머신러닝의 특성상, 수많은 학습 기법들이 존재하지만 그중 가장 많이 쓰이며, 기존 선형회귀 분석과는 차별성을 지니는 머신러닝 방법 중 하나인 결정트리(Decision Tree)와 랜덤포레스트(Random Forest)를 소개하고 그 특징에 대해 알아본다. 그 다음으로 최근 경제학에서 머신러닝 기법이 왜 관심을 끌고 있는지, 특히

정책평가에서 머신러닝이 왜 주목을 받고 있는지에 대해 논의하고 머신러닝을 활용하여 정책의 효과성 평가를 실시한 사례와, 예측모델을 개발하여 정책 대상자를 선별한 최신의 연구결과들을 정리하여 시사점을 도출한다.

제Ⅳ장에서는 머신러닝을 활용하여 크게 두 가지 부문, 정책의 효과성 평가와 정책 대상자 선정 측면에서 우리나라 조세재정정책의 개선안을 논의한다. 또한 머신러닝 분석방법이 우리나라에서 현재 시행 중인 조세특례정책에 대한 기존의 효과성 분석을 어떻게 보완할 수 있는지를 살펴보고 기존의 방법론 대비 유용성을 실증한다. 구체적으로는, 정책과 효과 사이의 인과적 영향에 관한 기존 연구방법보다 머신러닝을 이용한 분석이 이질적 처치효과(heterogenous treatment effects)에 대해 어떻게 더 나은 탐색 결과를 도출할 수 있는지를 제시한다. 2019년에 수행한 조세특례평가 중, 비과세종합저축에 대한 조세특례 정책을 선정하여 머신러닝을 활용한 정책효과 추정치가 기존 선형회귀를 활용한 정책의 효과성 분석과 비교하여 얼마나 개선된 정책 효과성 분석결과를 도출할 수 있을지를 살펴본다. 비과세종합저축에 대한 과세특례는 생계형 저축에 대하여 비과세하는 제도로 노인·장애인·생활보호대상자 등 취약계층의 재산형성을 지원하기 위하여 도입된 과세특례이다. 기존 분석은 가계금융복지조사를 활용하여 비과세종합저축의 저축, 자산 형성 및 이동 등에 대한 효과는 통계적으로 유의미하지 않은 것으로 분석하였으나, 좀 더 다양한 특성변수를 조합하여 처치효과를 탐색할 수 있는 머신러닝을 활용 시 개선된 효과성 추정치를 도출할 수 있을 것인지를 살펴본다. 특히, 정책 평가에 있어서 무작위 통제실험이나 준실험적 분석이 불가능한 경우, 정책 시행과 효과 사이의 인과적 영향(causal effect)을 살펴볼 수 있는 머신러닝 방법이 최근 제시되어 활용되고 있음을 고려하여, 비과세종합저축의 인과적 효과를 키절포레스트(Causal forest)를 사용하여 살펴본다.

제Ⅴ장에서는 머신러닝이 정책 시행에 따른 효과를 예측하고 ‘누가’ 가장 적절한 정책 대상자가 되어야 하는가를 다루는 정책 예측의 문제(Policy prediction problem) 해결에 탁월한 점에 주목하여, 정책 및 사업대상자의

효율적인 선정을 통해서 정책의 효과를 최대한 끌어낼 수 있는 방안을 논의한다. 많은 재정정책은 정책 및 사업대상자를 정부가 선정하고 그 자격에 부합하는 경제주체가 자발적으로 신청하는 신청주의에 기반을 두고 있다. 자격요건을 만족함에도 불구하고 해당 정책 및 사업을 신청하지 않는 경제주체가 존재할 경우, 미신청자를 정부가 관측 가능한 변수들을 이용해서 식별이 가능한지를 살펴본다. 다양한 조세·재정정책 중 자격요건이 뒤편에도 불구하고 신청하지 않는 비율이 높은 정책을 선정하여, 해당 정책의 정책순응자(complier)와 비순응자(non-complier)의 특성 파악을 머신러닝을 통해서 식별할 수 있으며 신청을 저해하는 요소 등을 분석한다. 예측된 정책비순응자를 대상으로 정부가 정책의 신청을 장려하는 신청안내 공지문자나 이메일을 집중적으로 보내는 조치를 취할 경우 정책의 접근성 측면에서 효과적인 개선이 기대될 수 있다. 그다음으로는, 수혜자의 다양한 특성을 조합하여 이질적 효과를 분석하는 데 적합한 머신러닝을 활용하여, 정책 대상자 선정(policy targeting)에 효율성을 증진시키는 방안에 대해 논의한다. 가령, 기초생활보장제도 및 여타 복지정책의 경우 수급자의 자격요건을 가구의 소득평가액과 재산의 소득환산액을 합산한 소득인정액을 바탕으로 하고 있으나, 이러한 소득인정액이 기본적인 의식주 해결의 가능성을 정확히 예측하지 못하는 경우 복지의 사각지대가 발생할 가능성이 있다. 따라서 정부가 쉽게 관측 가능한 변수들을 바탕으로 한 머신러닝 알고리즘이 소득을 기준으로 선정하는 것보다 의식주 해결 가능성을 보다 높은 확률로 예측한다면 복지 사각지대 문제점 개선에 효과적일 수 있음을 논의하고자 한다.

Ⅱ. 머신러닝과 빅데이터 개괄¹⁾

1. 머신러닝의 개요

가. 빅데이터와 머신러닝

제4차 산업의 핵심 분야로 언급되는 빅데이터 및 인공지능의 혁명은 ① 빅데이터로 불리는 방대한 데이터의 축적 ② 빅데이터 분석을 위한 머신러닝, 딥러닝 등 인공지능 분석기술의 발전 ③ 빅데이터 구축과 분석에 필수적인 컴퓨팅 성능의 발달 등 세 가지 부문의 획기적인 발전에 기반하고 있다. 그 중 ‘머신러닝(Machine learning)’, ‘딥러닝(Deep learning)’ 등의 인공지능의 세부 분야에 대한 명확한 개념 정의는 관련 전문가 사이에서도 아직 논의 중이나, 우선은 인공지능이 가장 큰 개념으로 머신러닝을 포함하고, 머신러닝에 딥러닝이 포함되는 구조로 개략적으로 이해할 수 있다. 머신러닝과 딥러닝을 구분하자면, 머신러닝은 데이터를 통해 컴퓨터가 학습하여 작업의 성능을 향상시키는 방법이며, 그중 딥러닝은 인간의 뉴런과 유사한 인공신경망 이론을 기반으로 입·출력 계층 및 복수의 은닉 계층을 활용하는 학습 방식을 뜻한다.²⁾

나. 실증분석에서의 머신러닝

머신러닝의 발전으로 인해 최근 경제학에서도 머신러닝 기법을 활용하고

1) 본 절은 본 보고서의 기초작업으로 재정포럼에 소개되었던 정재현(2019) 「머신러닝을 활용한 정책설계: 출산결정요인을 중심으로」, 『재정포럼』, 2019년 9월호의 내용을 일부 발췌하여 정리한 것이다.

2) 일부 연구에서는 딥러닝을 ‘머신러닝의 중첩’ 개념으로 보아 이를 별도로 구분하지 않기도 한다.

자 하는 연구가 활발하게 진행되고 있다. 특히, 개인 컴퓨터에서도 머신러닝 작업을 구현할 수 있을 정도의 높은 컴퓨팅 성능과 사용자 친화적인 통계패키지가 일반화되었으며, 대규모 미시행정 자료뿐 아니라 위성사진 및 사회관계망 데이터 등 고차원 데이터에 대한 접근이 용이해져, 실증분석에서 머신러닝 기법을 활용한 연구들이 양산되고 있다. 또한, 머신러닝이 과연 회귀분석을 위시한 기존의 분석방법을 완전히 대체할 수 있는 주요 실증연구방법 중 하나로 새로이 자리매김할 것인지 아니면 단순히 빅데이터에 특화된 분석방법 중 하나에 불과할 것인지에 대한 논의 또한 활발하다.

그중 최근 경제학에서 머신러닝이 주목받고 있는 이유는 기존 경제 분석이 등한시한 새로운 종류의 문제, 바로 ‘예측(prediction)’의 문제 해결에 머신러닝이 탁월한 성능을 보여주기 때문이다(Athey, 2017; Mullainathan and Spiess, 2017). 머신러닝은 특성변수 x 를 가지고 반응변수 y 의 예측치의 정확도를 모델에 대한 별다른 가정 없이 획기적으로 높일 수 있는 알고리즘을 제공한다. 선형회귀를 비롯한 기존 계량경제의 분석방법들은 특성변수와 반응변수의 관계를 사전적으로 모형화하여 핵심 모수(β)를 추정하는 것에 집중했다면, 머신러닝은 반응변수의 추정치 \hat{y} 의 예측 정확성을 향상시키는 것에 분석의 주목적이 있다.

물론 기존 선형회귀와 같은 모델기반 추정 방법 또한 준수한 예측성능을 보이는 것이 사실이다. 선형모델을 선택하고 주어진 샘플로 손실함수를 최소화하는 모델파라미터를 찾아내어 구성한 선형회귀식을 사용해 새로운 데이터 x 값에 대한 반응변수 y 를 예측할 수 있다. 하지만 머신러닝 알고리즘들이 기존 선형모델에 비해 얼마나 향상된 예측치를 제공하는가는 <표 II-1>의 예를 통해 살펴볼 수 있다. Mullainathan and Spiess(2017)는 임의로 추출된 10,000개의 미국 도시지역 주택가격자료(훈련데이터)의 면적, 방의 수 등 150개의 특성변수를 조합하여 주택가격을 예측하는 모델을 최소자승법(OLS)과 세 가지 머신러닝 알고리즘으로 훈련시킨 후, 41,808개의 신규 샘플(테스트데이터)을 활용하여 각 모델의 예측성능을 비교하였다. <표 II-1>을 통해 알 수 있는 점은 우선 대표적인 머신러닝 기법 중 하나인 랜덤포레

스트가 테스트샘플에서도 기존의 OLS보다 약 9% 정도 향상된 예측성능을 보인다는 점이다. 특히 세 가지 머신러닝 알고리즘들-결정트리, LASSO(Least Absolute Shrinkage and Selection Operator), 랜덤포레스트-의 예측치를 평균한 앙상블 방법 또한 테스트데이터에서 개별 방법보다 더 향상된 예측성능을 나타내는 것을 확인할 수 있다.

〈표 II-1〉 머신러닝 알고리즘과 예측성능

학습 알고리즘	예측성능 (R^2)	
	훈련데이터	테스트데이터
OLS	47.3%	41.7% [39.7%, 43.7%]
결정트리	39.6%	34.5% [32.6%, 36.5%]
LASSO	46.0%	43.3% [41.5%, 45.2%]
랜덤포레스트	85.1%	45.5% [43.6%, 47.5%]
앙상블	80.4%	45.9% [44.0%, 47.9%]

주: 1. 앙상블은 이전 세 가지 머신러닝 기법의 예측치를 평균한 수치임
 2. 테스트데이터의 대괄호는 부트스트랩을 이용한 95% 신뢰구간을 의미
 자료: Mullainathana and Spiess(2017), p. 90 Table 1을 바탕으로 저자 재가공

머신러닝은 대표적인 분석방법으로 자리매김하기에는 아직 해결해야 할 과제들이 산적해 있지만 특유의 뛰어난 예측성능을 바탕으로 실증분석에 기여할 수 있는 바가 분명히 존재한다. Mullainathan and Spiess(2017)가 제시한 여러 활용 방안 중 본고에서는 아래와 같이 크게 세 가지로 정리하여 논의하고자 한다.

첫째로, 머신러닝은 빅데이터를 처리하는 데 특화되어 있다. 여기서 빅데이터라 함은 단지 샘플 수가 많음을 의미하는 것이 아닌 이미지나 텍스트와 같은 고차원의 데이터 또한 포함한다. 예를 들어, 신뢰할 만한 경제통계가 부족한 개발도상국을 대상으로 방대한 픽셀 정보를 담고 있는 위성사진을 머신러닝으로 분석하여 연간 농업생산 등 비교적 신뢰할 만한 경제통계의 대리변수를 제공할 수 있다. 또한, 사회관계망의 텍스트분석을 하거나 센서

스와 같은 대규모 미시행정데이터에서 숨겨진 상관관계를 발견해내고 그를 기반으로 분류하는 작업에도 머신러닝의 활용도는 높다.

두 번째로, 기존 모수추정에 직접적으로나 혹은 암묵적으로 필수불가결하게 포함되는 예측의 과정에 머신러닝은 유용하게 쓰일 수 있다. 예를 들어, 도구변수를 활용한 2단계 최소제곱법 추정(Two-stage Least Squares, 2SLS)의 1단계는 내생변수 x 를 도구변수 및 모형의 다른 설명변수들에 회귀시켜 \hat{x} 를 구한다는 측면에서 사실상 예측의 문제이며, 따라서 기존 선형모델 사용 시 자주 직면하는 약한 도구(weak instrument) 문제도 1단계 LASSO 등을 통해 해결하고자 하는 실증분석 연구(Mueller-Smith, 2018)가 최근 제시되고 있다.

세 번째로, 머신러닝은 정책 시행에 따른 효과를 예측하고 ‘누가’ 가장 적절한 정책 대상자가 되어야 하는가를 다루는 정책 예측의 문제(Policy prediction problem) 해결에 탁월하다. ‘어떤’ 교사를 고용해야 하는가에 대한 문제(Chalfin et al., 2016), ‘어떤’ 피고인에게 보석을 허가해야 하는가의 문제(Kleinberg et al., 2018), ‘어떤’ 청소년을 대상으로 비행예방프로그램을 전개해야 하는가(Davis and Heller, 2020) 등의 문제를 다루는 데 있어 머신러닝은 개선된 해결책을 제시해줄 수 있다. 이렇게 머신러닝이 정책효과 예측에 유용한 분석도구를 제공하고 있는 이유는 바로 정책의 이질적 효과(heterogenous effects)를 살펴보는 데 아주 탁월하기 때문이다. 기존 선형모델에서는 처치 변수와 함께 실험집단의 특성변수의 교차항을 추가하여 특정한 사전적 특성을 공유한 그룹의 정책효과가 더 크게 나타남을 발견하였으나, 머신러닝은 실험군의 특성을 유연하게 조합하여 개인 수준에서의 정책효과를 예측할 수 있다(Wager and Athey, 2018). 최근에는 정책의 효과를 평가하는 데 가장 엄정한 인과관계를 증명할 수 있는 방법인 무작위통제실험(Randomized Control Trial, RCT)의 결과 분석에 머신러닝을 접목하여, 정책에 이질적 효과가 있는지의 여부뿐 아니라 어떤 특성이 이러한 이질적 효과를 야기하는지 등을 종합적으로 파악할 수 있는 머신러닝 분석법이 제시되었다(Chernozhukov et al., 2018).

2. 머신러닝 방법론

가. 머신러닝의 개괄

머신러닝은 크게 지도학습(Supervised learning)과 비지도학습(Unsupervised learning)으로 나눌 수 있다. 지도학습에는 머신러닝 알고리즘에 주입하는 훈련데이터에 하나 이상의 특성과 함께 입력 샘플 각각에 대한 원하는 답(반응변수, response)이 포함되며, 훈련된 지도학습기(Supervised learner)는 새로이 주어진 데이터의 특성을 기반으로 반응변수를 예측하게 된다. 분류(Classification)가 지도학습의 대표적인 예이며, 발신자가 누구인지, 제목에 어떤 문구를 포함하고 있는지 등의 속성을 활용하여 수신한 이메일의 스팸 여부를 구분해내는 스팸 분류기가 우리가 쉽게 접할 수 있는 지도학습 머신러닝 프로그램 중 하나이다. 지도학습 알고리즘으로는 회귀분석, 서포트 벡터 머신(Support Vector Machine, SVM), 결정트리와 랜덤포레스트, 신경망(Neural networks) 등이 있다. 비지도학습 또는 자율학습은 데이터에 반응변수가 따로 없이 특성변수들만 훈련 알고리즘에 주입되는 경우로, 알고리즘 스스로 데이터 사이의 유사성을 발견하고 그에 따라 몇 개의 그룹으로 묶는 군집분석(Clustering analysis)이 그 예이다.

경제학에서는 특성변수를 가지고 분류나 연속변수의 예측(회귀) 등 머신러닝의 예측성능의 활용 가능성에 주목하고 있기 때문에 앞으로의 논의는 지도학습을 위주로 설명하도록 한다.

나. 머신러닝에서 예측의 문제

머신러닝이 경제학의 새로운 분석방법으로 각광받고 있는 이유는 지도학습이 기존의 선형모델 추정에 비해 향상된 예측치를 제공하는 데에 있다. 예를 들어, 우리가 수집한 n 개의 주택가격(즉, 반응변수 y_i)과 각각의 주택에 대해 집의 크기, 방의 개수 등 p 개의 주택 특성변수($x_i = (x_{i1}, x_{i2}, \dots, x_{ip})^T$)를 알고 있다고 하자. 주택의 가격과 특성변수의 관계는 $y_i = f(x_i) + \epsilon$ 로 요약할 수 있으며 특성변수가 설명할 수 있는 부분(f) 외에 특성변수로 설명

할 수 없는 오차항(ϵ)이 존재한다. 우리는 여기서 주택가격과 특성변수의 n 개의 쌍을 $((x_1, y_1), (x_2, y_2), \dots, (x_n, y_n))$ 를 활용하여 주택가격을 예측할 수 있는 추정함수 \hat{f} 를 구하고자 한다. 여기서 우리가 원하는 것은 ‘예측’이기 때문에 훈련에 사용되지 않은 새로운 특성변수 조합이 주어졌을 경우, 그에 상응하는 실제 주택가격을 잘 예측하는 데에 관심이 있다. 즉, 훈련데이터(Training set)에서 높은 성능을 내는 것이 선결과제이긴 하지만 우리는 훈련 예측치인 $\hat{f}(x_1), \hat{f}(x_2), \dots, \hat{f}(x_n)$ 가 각각 y_1, y_2, \dots, y_n 얼마나 근사(近似)한 지에 대해서는 관심이 없고, 훈련 시 사용되지 않은 새로운 데이터 (x_0, y_0) 에 대해 $\hat{f}(x_0)$ 가 y_0 와 얼마나 같은지, 즉 얼마나 일반화가 잘 되었는지를 알고자 한다.

따라서 주어진 데이터에 대한 머신러닝의 성능을 평가하기 위해서는 예측된 반응값이 실제 반응값과 얼마나 가까운지를 수량화하는 것이 필요하다. 회귀에서 가장 일반적으로 사용되는 측도는 평균제곱오차(Mean Squared Error, MSE)³⁾이며, 앞서 언급한 n 개의 주택가격 샘플 전체를 훈련데이터로 활용하여 예측모델을 학습시키고 그에 따른 주택가격의 예측치와 실제 주택가격에 대한 평균제곱오차를 구한 경우 이를 훈련오차율이라 부른다. 하지만 앞서 언급했듯이 머신러닝의 주요 활용분야는 예측이기 때문에 훈련데이터에서 예측성능을 얼마나 향상시킬 수 있는가보다는 훈련에 사용되지 않은 새로운 샘플, 즉 테스트데이터(Test set) 혹은 검정세트에 대해 얼마나 예측의 정확도를 향상시킬 수 있는가에 관심이 있다. 따라서 적합한 머신러닝 방법을 찾는다는 것은 결국 검정오차율을 최소화하는 학습방법을 모색하는 것과 일맥상통한다.

다. 머신러닝 관련 주요 개념

(1) 과적합과 정규화

일차적으로 훈련오차율을 줄이는 방향으로 머신러닝 모델을 훈련하지만

3) 평균제곱오차(MSE)는 다음과 같이 표현할 수 있다. $MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{f}(x_i))^2$

낮은 훈련오차율이 반드시 낮은 검정오차율을 보장하는 것은 아니다. 이는 편향과 분산 절충(trade-off)의 문제로 이해될 수 있으며, 분산(Variance)은 다른 훈련데이터를 사용하여 추정하는 경우 \hat{f} 이 변동되는 정도를 말하며, 편향(Bias)은 실제 문제를 훨씬 단순한 모델로 근사시키는 과정에서 발생하는 오차이다.⁴⁾ 모델의 유연성(Flexibility)이 증가함에 따라 모델이 훈련데이터에 너무 잘 적합하여 훈련오차율은 감소하지만(낮은 편향) 일반성이 떨어지는 경우 과대 적합(Overfitting)이라 하며, 이 경우 훈련데이터 변동에 따라 \hat{f} 가 크게 변하여 높은 분산을 지니게 된다. 즉, 일반적으로 유연성이 높은 방법을 사용할수록 편향은 낮아지고 분산이 증가한다. 예를 들어, 고차 다항회귀모델이 일차선형모델보다 훈련데이터 A에 대해 더 잘 맞는다 하더라도 새로운 데이터 A'에 대해 예측성능을 높인다는 보장은 없으며, 반대로 비선형구조인 f 를 선형회귀로 추정을 하면 정확한 예측치를 제공할 수 없을 것이다. 따라서 편향과 분산 사이의 균형을 찾는 방법 중 하나로 과대적합을 피하기 위해 모델에 제약을 가하는 것을 정규화(Regularization)라 하며 이는 머신러닝의 필수 고려요소 중 하나이다. 학습하는 동안 적용할 정규화의 양은 규제매개변수로 결정되며 훈련 전 규제매개변수 설정은 머신러닝 알고리즘 훈련 시 매우 중요한 과정 중 하나이다. Mullainathan and Spiess (2017)는 아래 <표 II-2>와 같이 머신러닝 알고리즘과 관련 정규화 방법을 개략적으로 소개하고 있다.

4) 주어진 값 x_0 에 대한 기대오류검정 MSE는 $\hat{f}(x_0)$ 의 분산, $\hat{f}(x_0)$ 의 제곱편향, 그리고 오차항 ϵ 의 분산의 합으로 분해될 수 있다. $E(y_0 - \hat{f}(x_0))^2 = Var(\hat{f}(x_0)) + [Bias(\hat{f}(x_0))]^2 + Var(\epsilon)$ (Gareth et al., 2016)

〈표 II-2〉 머신러닝 알고리즘과 관련 정규화 방법

머신러닝 구분	정규화 방법과 관련 모수
선형모델	서브셋 선택 $\ \beta\ _0 = \sum_{j=1}^k 1_{\beta_j \neq 0}$ LASSO $\ \beta\ _1 = \sum_{j=1}^k \beta_j $ Ridge $\ \beta\ _2^2 = \sum_{j=1}^k \beta_j^2$ Elastic net $\alpha\ \beta\ _1 + (1-\alpha)\ \beta\ _2^2$
결정트리	깊이, 노드 및 잎의 개수, 잎의 크기, 각 분절점에서의 정보 획득량
랜덤포레스트	트리의 개수, 각 트리에서 사용되는 특성변수의 개수, 부트스트랩 샘플의 크기, 개별 트리의 복잡성
Nearest neighbors	이웃의 개수
Kernel regression	커널의 bandwidth
딥러닝, 신경망 등	레벨의 개수, 레벨당 뉴런의 개수, 뉴런의 연결 정도
스플라인(spline)	Knot의 개수, 순서 등

자료: Mullainathana and Spiess(2017), p. 93, Table 2를 인용하여 저자 재가공

(2) 검정오차, 교차검증과 부트스트랩

머신러닝 알고리즘의 훈련은 훈련데이터에 대해 수행하고, 적합된 모델에 검증데이터의 특성변수를 주입하여 반응변수 값을 예측한다. 우리는 검정오차가 낮은 머신러닝 방법을 선택하고자 하지만, 검정오차율은 지정된 검정 세트가 있는 경우 쉽게 계산할 수 있으나 검정세트가 따로 지정된 경우는 대개 드물다. 따라서 주어진 데이터를 가지고 검정오차율을 최소로 하는 추정방법에 대해 다양한 방법들이 제시되고 있다. 예를 들어, 주어진 관측치의 일부를 임의로 떼어 검정세트(Hold-out set)로 활용하는 검정세트기법(Validation Set Approach), 관측치를 k개의 부분집합으로 나누고 그 중 하나를 검정세트로 쓰는 k-fold 교차검증(Cross-validation), 주어진 샘플을 모집단으로 설정하고 복원(Replacement) 방식으로 임의추출하는 부트스트랩(Bootstrap) 등을 사용하여 검정오차율에 대한 추정치를 구하고 최적의 머신러닝 모델을 선택하게 된다.

3. 결정트리와 랜덤포레스트

본고에서는 최근 가장 많이 활용되고 있는 머신러닝 방법 중 하나인 랜덤포레스트 방법을 활용하여 정책의 효과성을 탐색하도록 한다. 그 전에 앞서 랜덤포레스트의 핵심 구성 요소인 결정트리의 개념과 구성 방법에 대해 소개한다.

가. 결정트리의 특징

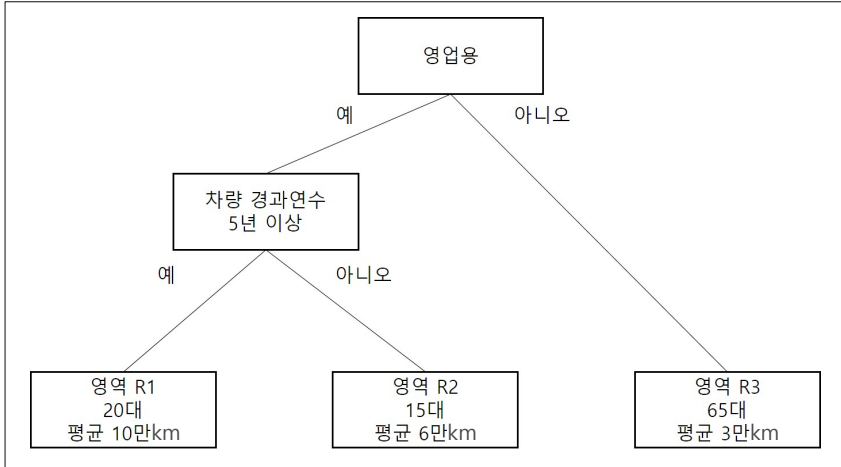
결정트리(Decision tree)는 분류와 회귀문제에 널리 사용되는 머신러닝 방법 중 하나로 특성변수에 조건을 주고 ‘예’와 ‘아니오’의 구분을 통해 데이터를 분할하는 알고리즘을 의미한다. 결정트리의 장점으로 ① 선형성을 전제하지 않기 때문에 설명변수 사이의 비선형적인 관계나 교차항 관계에 대해 유연한 탐색이 가능하고, ② 시각화가 용이하여 한눈에 이해하기가 쉬우며, ③ 특성변수에 맞게 개별 조건을 주어 처리하기 때문에 데이터 전처리 과정이 필요없다는 점이다. 단점으로는 과대적합 경향이 매우 크며 따라서 적절한 정규화과정이 반드시 필요하다. 이 장에서는 결정트리의 기본구조와 훈련방법, 그리고 정규화 방법에 대해 살펴보도록 한다.

나. 결정트리의 기본구조

임의로 선택된 차량 100대의 주행거리를 예측하는 가상의 예인 [그림 II-11]로 결정트리의 기본 구조에 대해 설명하고자 한다. 가장 위의 깊이가 0인 루트노드(Root node)에서 차량의 영업용 여부를 가지고 분류를 시작한다. 만약 아니라면 루트노드에서 깊이 1인 오른쪽의 자식 노드(Child node)로 이동한다. 만약 영업용에 해당한다면 차량 경과연수를 가지고 한 번 더 분류작업을 진행하며 이는 최종적으로 트리의 터미널노드(Terminal node) 또는 잎(Leaves)이라 불리는 영역 R1, R2, R3을 구성한다. 결정트리는 영역 R_j 에 속하는 모든 관측치들에 대해 동일한 예측을 제시하며, R_j 의 반응변수가 연속변수인 경우 훈련관측치들에 대한 평균값(즉, 비영업용 차량의 주행거

리를 R3에 분류된 65대의 주행거리를 평균하여 3만km로 예측)을, 분류의 경우 최빈값을 예측치로 제시한다.

[그림 II-1] 차량주행거리 예측을 위한 결정트리 예시



자료: 저자 작성

다. 결정트리 알고리즘과 과적합 방지방법

결정트리 훈련 알고리즘의 목적은 기본적으로 회귀트리의 경우 잔차제곱합(Residual Sum of Squares, RSS)⁵⁾을, 분류는 지니계수(Gini index)⁶⁾ 혹은 엔트로피⁷⁾ 등의 불순도(Impurity)를 최소로 하는 영역 R_1, R_2, \dots, R_j 를 찾는 것이다. 하지만 특성변수 x_1, x_2, \dots, x_p 와 해당 변수 각각의 분절점

5) $\sum_{j=1}^J \sum_{i \in R_j} (y_i - \hat{y}_{R_j})^2$ 에서 \hat{y}_{R_j} 는 j번째 영역 내의 훈련관측치들에 대한 평균 반응변수 값이다.

6) 지니 불순도의 정의는 다음과 같다: $G_i = 1 - \sum_{k=1}^n p_{i,k}^2$ 여기서 $p_{i,k}$ 는 i번째 노드에 있는 훈련데이터 중 범주 k에 속한 샘플의 비율로, 한 노드의 전샘플이 같은 k에 속해 있다면 이 노드의 지니계수는 0이다.

7) 엔트로피의 정의는 다음과 같다. $H_i = - \sum_{k=1, p_{i,k} \neq 0}^n p_{i,k} \log_2(p_{i,k})$ 한 노드의 모든 샘플이 같은 범주에 속해 있다면 엔트로피는 0이다.

(cutpoint)의 모든 가능한 조합을 한꺼번에 고려하는 것은 계산상 실현 불가능하며, 따라서 탐욕적(greedy) 알고리즘, 즉 향후 단계에 대한 계산 없이 해당 단계에서만 가장 좋은 분할을 만들어내는 특성변수와 분절점의 조합을 선택한다. 회귀분류의 경우 각 영역 내에서 잔차제곱합이 최소가 되도록⁸⁾ 이 과정을 반복하고 아래에 설명할 특정 정지 기준(Stopping criteria)이 만족될 때까지 계속 트리를 성장시킨다.

단, 결정트리는 훈련데이터에 대한 제약사항이 거의 없어 과대적합하기 쉽다. 이러한 결정트리의 유연성을 제한할 수 있는 규제매개변수로는 결정트리의 최대 깊이, 분할되기 위해 노드가 가져야 하는 최소 샘플의 수, 터미널노드가 가지고 있어야 할 최소 샘플 수, 리프 노드의 최대 수 등이 있다. 이와 더불어 불순도를 낮추는 것에 통계적으로 큰 기여가 없는 불필요한 노드를 가지치기(Pruning)하는 방법 등을 통해 결정트리의 과대적합을 방지한다.

라. 랜덤포레스트의 개념과 특징

편향과 분산의 절충 이유로, 여러 개의 머신러닝 예측을 수집하여 종합하면 가장 좋은 단일 모델보다 향상된 예측성능을 기대할 수 있다. 이러한 방법을 앙상블학습(Ensemble Learning)이라 하며 결정트리의 앙상블을 랜덤포레스트라 한다. 예를 들어 하나의 훈련데이터로부터 무작위로 추출한 각기 다른 데이터세트를 활용해 결정트리를 훈련시켜 개별 트리의 예측을 구하고, 그 예측치의 평균값을 구하는 방법을 생각해 볼 수 있다.

결정트리는 특유의 유연성으로 인해 과적합의 위험이 크며 따라서 훈련데이터의 변이에 매우 민감하게 반응한다. 따라서 이러한 예측치의 분산을 줄이기 위해, 즉 일반화를 위한 방법으로 훈련데이터의 서브셋을 무작위로 구성하여 트리를 각각 다르게 학습시키는 방법을 생각해볼 수 있다. 가장 대

8) 즉 다음 식을 최소로 하는 설명변수 x_j 와 s 값을 찾는다.

$$\sum_{i: x_i \in R_1(j, s)} (y_i - \hat{y}_{R_1})^2 + \sum_{i: x_i \in R_2(j, s)} (y_i - \hat{y}_{R_2})^2$$

표적으로 복원추출을 허용하여 임의의 훈련데이터셋을 만들어내는 부트스트랩을 통해 각 개별 트리들을 훈련시키고 훈련된 트리들의 평균 또는 최빈값을 이용해 결합시키는 방법인 배깅(Bootstrap Aggregating, Bagging)은 개별 트리의 예측성능을 유지하면서, 분산은 감소시키기 때문에 머신러닝의 예측성능을 향상시킨다. 하지만 여기서 랜덤포레스트는 한걸음 더 나아가 각 노드에서 고려할 특성변수를 선택하는 것에도 임의성을 추가한다. 즉 총 p 개의 특성변수 중 m 개의⁹⁾ 변수만이 각 분할에 사용될 변수 후보로 임의로 선택되며, 각 분할에서는 이 m 개 특성변수 중 하나만을 사용하여 분할을 진행한다. 그리하여 개별 결정트리들은 상관성이 줄어들고, 이렇게 구성한 랜덤포레스트는 훈련데이터의 변동에 민감하게 반응하지 않아 안정적인 예측성능을 얻을 수 있다.

마. 랜덤포레스트의 실행

과대적합을 방지하고 일반 예측성능을 높이기 위해 랜덤포레스트에서는 개별 구성요소인 결정트리의 매개변수와 양상블을 제어하는 데 필요한 매개변수를 설정할 수 있다. 주요 매개변수로는 ① 포레스트의 크기, 즉 트리의 개수 ② 개별 트리의 최대 허용 깊이 ③ 노드 분할 시 고려할 특성변수의 개수 등이 있다. 구체적으로는 포레스트를 구성하는 트리의 수가 적으면 일반화 능력이 떨어져 검정오차율이 높고, 트리의 수가 많으면 오차율은 줄지만 훈련과 테스트 시간은 증가한다. 특성변수의 경우, 각 노드 분할 시 전수가 아닌 무작위로 선택한 특성변수 후보군에서 분절점을 찾도록 하는 것은 개별 트리의 훈련오차율을 높일 수는 있지만, 분산을 낮추어 포레스트의 검정오차율을 줄이는 더 나은 모델을 훈련할 수 있게 한다.

랜덤포레스트는 하나의 결정트리와는 달리 수많은 결정트리를 조합하기 때문에 예측치를 제시하는 과정을 한눈에 파악하기 불가능하다. 따라서 각 특성변수의 중요도를 요약해서 제공하는 특성 중요도(Feature importance)

9) 분류의 경우, 각 분할에서 고려되는 특성변수의 수 m 은 p 의 제곱근값에 근사한다.

를 활용하여 포레스트의 예측과정에 대해 개략적으로 이해한다. 특성 중요도는 어떤 특성을 사용한 노드가 랜덤포레스트 내 모든 트리에 걸쳐서 평균적으로 불순도를 얼마나 감소시키는지를 파악하여 측정한다. 큰 특성 중요도 점수를 가지는 변수는 작은 값을 갖는 변수보다 반응변수 예측에 높은 중요성을 갖고 있음을 의미한다.

Ⅲ. 머신러닝을 활용한 정책평가와 개선사례

최근 정부의 재정정책 및 규제의 설계에 많은 경제학자들이 활발히 참여하고 있고 이러한 추세는 더욱더 증가할 것으로 기대된다. 알빈 로스(Alvin E. Roth)는 1999년 피셔-슐츠(Fisher-Schultz) 강의에서 경제학자들의 정책 설계의 활발한 참여와 정책의 설계 시 경제학적인 이론뿐만 아니라 실험경제학과 시뮬레이션을 활용하는 엔지니어적인 태도를 취해야 한다고 주장하였으며(Roth et al., 2004), 에스테르 뒤플로(Esther Dufllo)는 경제학자들의 정부정책 및 규제의 설계에 기여하는 정도가 급증하고 있으며 정책 설계 시 정책의 세세한 부분까지 고려하는 태도가 필요하다고 주장하였다. 그녀는 이를 위해서 배관공적인 태도가 요구된다고 주장하였는데 여기서 배관공적인 태도란 현실세계에서 어떤 정책이 효과적일지 고민할 때 이론을 바탕으로 정책을 설계하는 것이 아니라 정책의 일부 조항을 세밀하게 변화시키고 이에 따른 결과를 면밀하게 관찰하면서 최적의 정책을 형성해가는 태도를 의미한다(Dufllo, 2017).

이처럼 경제학자들이 정부정책 설계에 활발히 참여하는 분야는 정책 설계의 성격에 따라 2가지 정도로 구분할 수 있다. 첫 번째로 자원배분의 방식의 설계, 두 번째로 정부정책 수혜 대상의 선정과 정책수여자에게 전달하는 방법의 개선이다. 최근 활발하게 이루어지고 있는 실증경제학과 기계학습 방법론의 접목을 고려하였을 때 경제학자의 정책 설계 참여는 정부에 새로운 조언과 지침을 보다 많이 제공해 줄 것으로 기대된다. 이번 장에서는 최근의 정부 정책과 규제의 개선과 관련한 경제학의 논의에 대해서 살펴보고 머신러닝이 이러한 논의에 기여하고 있는 실증연구 사례에 대해서 살펴본다.

1. 자원배분 방식 설계를 위한 머신러닝 적용 사례

시장설계이론은 경제학적인 메커니즘과 인센티브를 통해 자원의 안정적인 배분을 연구하는데, 시장설계이론 분야의 연구자들은 의대졸업생들의 병원 배정방법, 뉴욕 및 보스턴 학교의 배정 알고리즘, 신장 교환이식 프로그램, 난민 정착 프로그램, 주파수 경매와 같은 다양한 분야의 배분 문제를 개선하는 데 기여하고 있다.

구체적으로 몇 가지 사례를 살펴보자면 먼저 ‘학교 배정 알고리즘’의 경우 기존의 배정시스템에서는 학생들이 지원하지 않는 학교에 배정이 되거나 혹은 학생들이 본인의 진짜 선호를 지망순위에 기입하지 않고 2지망의 학교를 1지망에 올려 쓰거나 2지망에 인기없는 학교를 쓰는 등의 전략적인 행위를 유발하였다. 이와 관련하여 Atila Abdulkadiroglu, Roth Alvin과 같은 연구자들은 지원자들의 전략적 행위를 억제하면서 배분과정의 공정성 문제도 적절히 고려할 수 있는 잠정수락 알고리즘(Deferred Acceptance Algorithm)을 제안하였고 이러한 알고리즘은 실제 뉴욕 및 보스턴의 학교 배정 알고리즘의 개선에 활용되었다. 결과적으로 뉴욕의 경우, 기존에는 9만여 명의 학생 중 3만명가량이 지원하지 않는 학교에 배정되는 등의 비효율이 발생하였던 반면에 잠정수락 알고리즘을 도입한 이후 3,000여 명의 학생만이 지원하지 않는 학교에 배정되고 대부분의 학생이 원하는 학교에 배정되는 효과가 나타났다. 보스턴의 경우 전통적으로 사용한 학교 배정 알고리즘은 학생들이 1지망 학교에 떨어지는 경우 다음 지망의 학교에 진학할 가능성이 하락하는 방식이었는데 이에 따라 2지망하는 학교를 1지망으로 상향하여 지원하는 등의 전략적 행위가 학부모들 사이에서 빈번하게 발생하였다. 이러한 문제점에 대한 대안으로 보스턴은 2006년부터 잠정수락 알고리즘을 도입하였고 본인의 선호와 다르게 학교를 지원하는 전략적 행위 등의 문제점이 개선되었다.

‘신장 교환이식 프로그램’의 제도 개선과 관련해서도 매칭 연구자들의 기여가 돋보이는데 기존의 신장 교환이식 프로그램의 경우 신장이식을 받아야 하는 수혜자와 기증 의사가 있는 가족 등의 혈액형 및 적합성이 일치하

지 않는 경우에 양자교환이식(pairwise kidney exchange) 방식을 통해서 다른 수혜자와 기증자의 조합을 찾아서 서로 신장을 맞교환하였다. Roth et al.(2004)의 연구에서 이러한 교환알고리즘을 개선하여 3자 이상의 참여자들과 사망자로부터 기증받는 신장을 포함시켜 한 번에 더 많은 이식수술을 가능하게 하는 알고리즘인 Top Trading Cycle and Chain을 제안하였다. 이러한 제안을 바탕으로 미국의 대형 병원들은 컨소시엄을 구성하여 새로운 신장 교환이식 프로그램을 도입하였는데 이를 통해 2008년 연간 300여 건이던 신장 교환이식이 2014년 기준 연간 800여 건으로 늘어나게 되었다.

마지막으로 최근의 시장설계이론의 연구 성과가 정책 개선에 기여한 사례를 소개하자면 난민정착 프로그램을 들 수 있다. 유엔난민기구의 연간 글로벌 동향보고서(Global Trends Report)에 따르면 2018년 기준 예멘·시리나 내전, 베네수엘라의 위기 상황 등을 통해서 발생한 전 세계 난민은 7천여 만명을 넘고 있으며 150만명가량의 난민은 즉시 재정착이 필요한 것으로 나타났다. 난민의 재정착 문제의 경우 특정 난민을 배정할 지역의 학교 배정 문제, 언어교육, 취업교육 등 고려해야 할 다차원적인 제약조건들이 존재하는데 기존 매칭이론의 경우 이러한 제약조건을 동시에 만족하기 어려워서 해당 이론의 적용에 어려움을 겪었다. David Delacretaz, Scott Komminers와 같은 연구자들은 이론적인 연구결과와 머신러닝을 결합하여 난민 재정착 문제를 해결하려는 여러 가지 시도를 하였는데 이러한 연구결과를 바탕으로 우스터 대학(The College of Wooster), 룬드 대학(Lund University), 옥스퍼드 대학(University of Oxford)은 애니(Annie)라는 인공지능 프로그램을 공동 개발하여 미국에서 2018년부터 난민들을 가장 적합한 도시로 배정시켜주는 데 활용하고 있다.

2. 정책 수혜대상 선정에 머신러닝이 활용된 사례

정책의 대상을 선정하기 위해 고려해야 하는 사항 중에 하나는 정책의 혜택을 가장 크게 볼 것으로 여겨지는 집단을 파악하는 것이다. 이러한 질문에 대답하기 위해 연구자들은 무작위 통제 실험 데이터(Randomized Control

Experiment) 혹은 관찰 데이터(Observation Data)를 활용하여 정책효과의 이질성 분석을 시도하고 있으며 이를 바탕으로 정책의 효과가 큰 집단을 식별해 정책 대상자 선정에 개선책을 제공하려 하고 있다. 특히 행정데이터 등의 빅데이터의 사용이 비약적으로 증가함에 따라 많은 연구자들이 표본을 사회경제학적인 특성에 따라 세세하게 쪼개어 정책의 효과를 추정하고 있다(Wager and Athey, 2018).

이질성 분석과 관련하여 최근의 연구 동향을 좀 더 살펴보면, 연구자들이 정책의 효과가 가장 클 것으로 예상되는 집단을 모형을 통해서 추정하고 추정된 모형을 바탕으로 집단별 정책의 효과를 추정하는 시도가 눈에 띄게 증가하였는데 이러한 시도는 방법론적인 측면에서 두 가지로 구분할 수 있다. 먼저 첫 번째로, 정책의 효과가 클 것으로 예상되는 집단을 모형을 통해서 추정한 후 상황에 따라서는 예측된 추정치를 기준으로 집단을 구분하여 정책의 효과를 추정하는 방법론이다. 구체적으로 최근의 많은 연구들이 처치를 받지 않은 관측치를 기준으로 (통제그룹)종속변수와 설명변수들 간의 관계를 모형을 통해서 추정하며, 그다음 종속변수로 예상되는 값을 추정된 관계식을 이용하여 예측하고 예측된 종속변수의 값을 기반으로 관측치를 분리하여 정책의 효과를 추정한다(Abadie et al., 2018; Pane et al., 2013; Hemelt, et al., 2013; Rodriguez-Planas, 2012). 예를 들어, Hemelt, et al. (2013)은 초등교육에서의 정책적인 프로그램이 아이들의 대학등록에 미친 영향을 살펴보았는데, 이러한 프로그램은 아이들의 평균적인 대학등록에 유의미한 영향을 미치지 않는 것으로 나타났지만 모형을 통해서 예측된 대학등록을 할 확률이 매우 낮은 그룹에서는 해당 프로그램이 대학 등록에 통계학적으로 양(+)의 효과가 있음을 보였다.¹⁰⁾ Davis and Heller(2020)는 시카고에서 실시된 청소년 여름 고용 프로그램이 평균적으로는 효과가 없는 것

10) Abadie et al.(2018)은 처치효과에 사용될 표본을 이용하여 집단의 종속변수의 값을 추정하고 추정된 것을 통해서 충화하여 집단별로 정책의 효과를 추정하는 방법론을 내생적 충화방법(Endogenous Stratification)이라 명명하였으며 이러한 방법론의 경우 정책 효과의 추정에 편의가 있음을 보였기 때문에 해당 연구결과들의 해석에는 주의가 요구된다.

으로 보이지만, 적은 비용으로도 높은 효과를 거둘 수 있는 특정 그룹을 머신러닝을 통해 찾아내어 정책적 시사점을 제시한 바 있다.

〈참고: 청소년 고용 프로그램의 이질적 처리효과에 대한
Davis and Heller(2020)의 연구〉

미국의 청소년 고용 프로그램의 효과성을 분석한 기존 선행연구에서는 많은 자원이 투입되는 프로그램만이 청소년 고용의 질을 향상시켜 청소년 비행 위험을 줄일 수 있다는 결론이 많았으나, 최근에는 Davis and Heller(2020)의 연구를 필두로 저비용의 프로그램으로도 청소년 범죄를 예방할 수 있는 고용 프로그램을 설계할 수 있음을 제시하고 있다. 기존 연구에서는 고용의 질이 개선되면 범죄의 기회비용이 증가하고 따라서 청소년이 범죄에 빠질 유인이 줄어든다는 이론적 접근하에, 청소년 고용의 질을 개선할 수 있는 고비용의 직업훈련 프로그램만이 청소년 비행의 위험을 줄일 수 있다는 입장을 취하고 있었다. 하지만 Davis and Heller(2020)는 시카고 청소년 여름 고용 프로그램(SYEPs)의 효과를 머신러닝을 사용하여 분석한 결과, 저비용의 청소년 고용 프로그램으로도 특정 집단을 대상으로 청소년 범죄예방 효과가 있을 수 있음을 밝혀내었다. 연구방법으로는 우선 시카고 청소년 여름 고용 프로그램에서 무작위로 두 개의 그룹을 선정하여, 첫 번째 고등학생 그룹은 최저임금 8.25달러 8주 시간제 여름 일자리를 제공하고 성인 멘토를 제공하였고, 두 번째 그룹은 6주 프로그램으로 기존 자격기준을 완화하여 다른 고용 프로그램 대상이 된 학교 밖 청소년도 포함하였다. 이후 시카고 공립학교, 일리노이 주 경찰, 일리노이 주 고용부의 행정데이터를 활용하여 참가한 청소년 데이터를 추적하였다. 그 결과, 프로그램을 제공한 두 해에 걸쳐 첫 해 42%, 두 번째 해 33% 등, 청소년 범죄가 극적으로 감소한 효과를 찾아내었지만, 참가자의 총체포건수는 변하지 않았고 인적자본

과 관련된 지표들도 개선되지 않은 것으로 나타나, 이전 연구와 같이 저비용 고용 프로그램의 경우 청소년 비행예방 효과가 제한적일 수 있음을 제시하였다. 하지만, 범죄의 성격에 따라 그리고 프로그램 수혜자의 특성에 따른 이질적 처치효과를 머신러닝을 활용하여 추가로 분석한 결과, 특정 집단에서는 해당 정책의 효과가 다를 수 있음을 밝혀내었다. 구체적으로는, 커질포레스트를 활용하여 고용이 향상된 특정 그룹을 선정하고, 이들 집단에선 비폭력적인 범죄가 증가하는 것으로 나타나, 인적자본 개선으로 고용의 질이 향상되면 범죄를 감소시킨다는 기존의 이론과는 다른 결과가 도출될 수 있음을 밝혀내었다. 이들은 다른 그룹과 비교하여 결석이 적고, 히스패닉과 여성이 많으며, 체포 기록이 없는 특성을 발견해내었으나, 결국 이 그룹은 애초에 고용프로그램이 목표로 했던 청소년 그룹이 아니었던 것으로 판단해낼 수 있었다. 하지만 이들의 사기 등의 비폭력 범죄의 위험성은 증가하는 것으로 분석하였는데, 이는 청소년 고용 프로그램이 범죄에 대한 기회비용이 증가하여 범죄를 감소시킬 것이라는 전통적인 이론에 대한 의문을 제기할 수 있는 근거로 활용되었다. 결론적으로 이 연구는 이질적 처치효과 분석의 필요성, 즉 어떤 종류의 고용 프로그램이 누구에게 도움이 되는지 분석하기 위한 머신러닝 분석 방법의 유용성을 보여주고 있다.

Athey(2018)는 기계학습 알고리즘과 경제학의 접목이 최근에 활발하게 일어나고 있으며 이러한 접목이 활발하게 이루어질 분야로 정책효과의 이질성 추정을 꼽았다. 그녀의 진단처럼 정책효과의 이질성을 추정하는 첫 번째 방법론인, 즉 정책의 효과가 클 것으로 예상되는 집단을 정의하고 이러한 집단을 기계학습 방법론을 이용하여 예측하는 연구는 최근 활발하게 이루어지고 있다(Sansone, 2019; Andini et al., 2018; McBride and Nichols, 2015; Chandler, et al., 2011). 예를 들어, Sansone(2019)는 미국의 고등학교 중퇴 방지 프로그램의 효과성을 높이기 위해 중퇴의 위험을 예측하는 모형을 기

계학습 알고리즘을 통하여 구축한 후 해당 알고리즘이 식별한 중퇴의 고위험군으로 여겨지는 집단을 정책 대상으로 삼는 것을 제안하였으며, Andini et al.(2018)은 이탈리아의 내수경기 활성화를 위해 실시된 세금환급 정책을 연구하였는데 정책의 효과성이 가장 클 것으로 여겨지는 집단을 기계학습 알고리즘을 통하여 식별하는 시도를 하였다. 이탈리아의 세금환급제도는 연간 임금이 8,145~26,000유로 사이의 모든 임금노동자를 정책의 대상으로 선정하고 총 70억유로에 달하는 금액을 지원하였다. 연구자들은 기존의 기준(연간 임금 8,145~26,000유로)이 아닌 결정트리 알고리즘을 사용하여 유동성 제약에 빠질 것으로 보이는 집단의 예측을 시도하였고 이러한 알고리즘을 이용하여 정책 대상을 선정하였을 때 정책의 효과(소비활성화 효과)가 더욱 클 수 있음을 보여주었다.

〈참고: 세금 환급정책의 Andini et al.(2018)의 연구〉

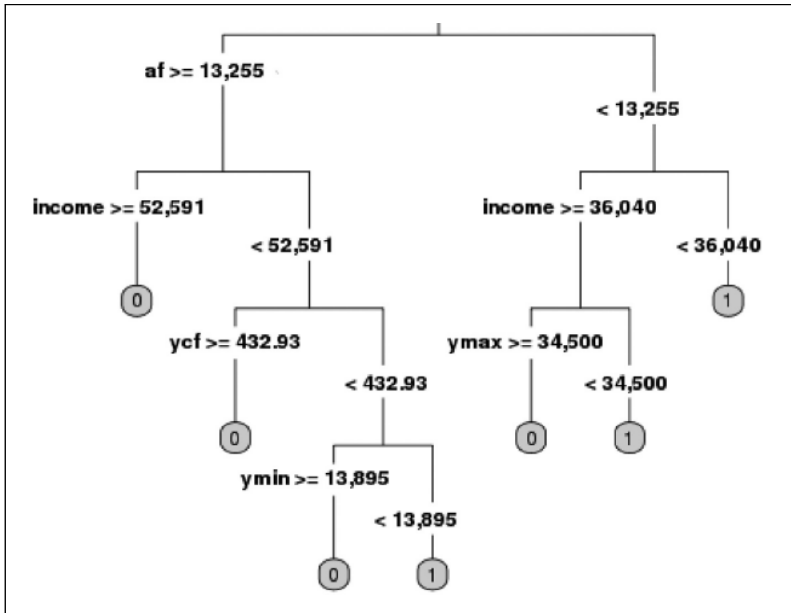
Andini et al.(2018)은 2014년 이탈리아의 가구 소비 촉진을 위한 세금환급 정책에 대하여, 실제 정책 대상자와 머신러닝 알고리즘으로 선정된 정책 대상자를 비교하여, 머신러닝을 활용한 정책 대상자 선정이 소비 진작 효과를 더 높일 수 있었는지를 분석하였다. 2014년 이탈리아 정부는 가구 소비 촉진을 위하여 80유로의 세금을 환급해주는 정책을 시행하였는데, 본 연구는 2014년의 실제 정책 대상자였던 연간 총소득이 8,145유로 이상 26,000유로 미만인 근로자 그룹과 머신러닝 알고리즘으로 선택된 대안 그룹의 정책효과를 비교하였다. 2010년과 2012년 이탈리아 중앙은행의 가구소득 조사자료(SHIW)를 활용(훈련데이터)하여 머신러닝 예측모델을 설정한 후 2014년 자료를 적용하여 소득 보조가 필요한 가구를 구분해내고, 이들과 실제 세금 환급을 받은 가구의 소비를 비교하였다. 연구에서는 3개의 머신러닝 알고리즘(결정트리, k-최근접이웃 알고리즘, 랜덤포레스트)과 1개의 선형모델을 사용하였고, 머신

러닝 알고리즘이 예측의 정확성 측면에선 선형모델과 유사한 결과를 도출하였지만, 결정트리가 일부의 특성 변수만으로도 간단하고 직관적인 지원 대상 선정 모델을 제공한다는 측면에서는 주 분석 모델로 활용되었다. 결정트리 알고리즘은 데이터를 작은 부분집합으로 계속 분할하면서 부분집합의 이질성(heterogeneity)이 가장 낮을 때까지 분할하여 예측값을 생성한다는 측면에서, 노드 수가 많을수록 데이터가 과대적합(overfit)되었다는 것을 의미한다. 이런 상황에서는 훈련데이터에서는 예측력이 높지만 새로운 데이터에서는 예측력이 낮아지게 되며, 따라서 매개변수를 사용하여 노드의 수를 조절하는 방법으로 문제 상황을 해결하였다. 결정트리의 앙상블인 랜덤포레스트는 예측력을 높이며 과대적합을 방지한다는 측면에서 결정트리보다 더 나은 결과를 제공할 수 있지만, 제공된 데이터셋의 활용 가능한 특성 변수가 다양하지 못하고 제한적인 경우 결정트리 모델이 더 적합하여, 본 연구에서는 결정트리 모델을 가장 적합한 머신러닝 알고리즘으로 판단하고 활용되었다.

결정트리 분석결과는 [그림 III-1]로 직관적으로 도식화할 수 있으며, 가구의 소비를 결정하는 데 영향을 미치는 변수는 금융자산, 가처분소득, 금융소득, 최대근로소득, 최소근로소득 등 가구의 소득과 자산인 것으로 나타났다. 머신러닝 알고리즘을 통한 세금 환급프로그램의 목표 그룹은 [그림 III-1]의 노드 ①에 해당하는 그룹으로, 연간 금융자산이 13,255유로 미만인면서, 가처분소득이 36,040유로인 그룹과, 가처분소득은 36,040유로 이상이지만 가구원의 최대근로소득은 34,500유로 미만인 그룹, 연간 금융자산이 13,255유로 이상이지만 가처분소득은 52,591 유로 미만이고, 연간금융소득은 432.93유로 미만이며, 가구원의 최소소득이 13,895유로 미만인 그룹으로 정의할 수 있다.

[그림 III-1] 이탈리아 세금환급정책 대상자 선정을 위한 결정트리

(단위: 유로)



자료: Andini et al.(2018), p. 95 (Figure 6)

결정트리 머신러닝 방법을 사용하여 분석한 결과, 우선 2014년 데이터를 사용하여, 80유로의 지원금이 결정트리로 선정된 유동성 제약을 겪고 있는 가구와 그렇지 않은 가구에 미친 영향을 분석한 결과, 소비제한이 있는 가구의 경우 세금환급 지원금은 식품소비에 양(+)의 효과가 있는 것으로 나타났다. 특히 결정트리로 선정된 대안 그룹에 속한 가구의 경우 지원금의 36.9%를 식품소비에 지출하는 것으로 나타났다. 둘째, 실제 정책 대상자 중 유동성 제약이 없는 가구에 지원된 지원금 규모가 약 20억유로(총지출의 29.5%)에 해당하는 것으로 나타나, 정책의 효과성을 개선할 여지가 충분한 것으로 분석되었다. 즉, 71%의 가구가 결정트리 알고리즘에 의해 유동성 제약이 예측되는 그룹으로 구분되고 지원금을 받은 것으로 나타났는데, 이는 나머지 29%가 세금환급을 받을 필

요가 없었던 대상이었다는 것을 의미한다. 유동성 제약이 없다고 예측된 가구에 지원금을 제외하였다면, 현재 정책으로 지출된 70억유로 중 29.5%인 약 20억유로를 절감할 수 있었을 것이며, 20억유로를 소비 제한적이지만 지원금은 받지 못한 가구에 지원하였다면 소비 진작효과가 더욱 증대되었을 것임을 시사한다. 따라서, 연구진들은 당시 세금환급분의 분배 방법을 개선할 수 있는 두 가지 방법을 제안하였다. 첫째, 머신러닝 알고리즘으로 선택되지 않은 그룹, 즉 유동성 제약이 없다고 예측된 가구의 지원금을 줄인다면, 현재 정책의 소비촉진효과는 유지하면서 정부 지출을 감축할 수 있거나, 둘째, 머신러닝 알고리즘으로 선택되지 않은 그룹에서 알고리즘이 선택한 그룹(소비에 제한이 있다고 예측된 가구)으로 지원금 대상자를 변경한다면, 정부 지출은 유지하면서 소비 촉진효과를 증대시킬 수 있다고 판단하였다.

이질성 분석과 관련하여 활발히 연구가 이루어지고 있는 두 번째 방법론은 기계학습 알고리즘을 통해서 최대의 효과를 거둘 수 있는 특정 집단을 식별하는 것이다. 첫 번째 방법론이 정책의 효과가 클 것으로 여겨지는 집단을 사전적으로 정의하고 모형을 통하여 이러한 집단을 예측하였다면 기계학습을 이용한 방법론은 데이터를 통해서 정책효과가 클 것으로 예측되는 집단을 규명하는 것이다. 다만, 이러한 방법론은 수많은 변수들을 사용하여 처치효과가 큰 집단을 식별해야 하기 때문에 일종의 정책 효과가 있는 집단을 찾기 위해 수없이 많은 모형을 추정하는 모형 탐색(model specification search)으로 여겨질 수 있어서 주의가 필요하다. 왜냐하면 수많은 모형의 추정을 통해 처치효과가 클 것으로 여겨진 집단의 경우 표본에서의 Overfitting 문제로 인하여 실제 새로운 표본이 주어졌을 때 정책의 효과가 없는 것으로 나타날 수 있기 때문이다. 이와 같은 과도한 모형 탐색을 방지하기 위해 전미경제학회와 많은 의학학회들의 경우 연구자들에게 사전 연구계획서를 제출하게 하고 제출된 내용에 한해서만 이질성 분석을 허용하고 있다

는 점도 명심해야 할 사항이다. 다만 최근에 많은 연구들이 이러한 문제점을 해결할 수 있는 기계학습 알고리즘을 연구하고 있으며(Wager and Athey, 2018; Athey et al., 2017; Asher et. al., 2016; Athey and Imbens, 2017), 특히 Athey and Imbens(2017)의 방법론은 정책의 이질성만을 식별하는 것뿐만 아니라 집단별 이질성에 대한 가설 검증까지 시행할 수 있기 때문에 이러한 방법론들을 이용한 정책의 이질성 추정은 더욱 활발하게 이루어질 것으로 보이며 정부의 정책 대상자 선정에 의미 있는 정보들을 제공해줄 수 있을 것으로 보인다.

이와 더불어 경제학자들이 정부정책 설계에 기여할 수 있는 분야는 정부정책을 정책 수혜자에게 전달하는 방법론에서 찾을 수 있다. 특히 행동경제학의 이론에 기반한 많은 연구들은 개인들의 선택 설계에 약간의 변화를 주었을 때 정책 수혜자들의 삶이 더 나은 방향으로 변화시킬 수 있다는 것을 보여주었고(Thaler and Cass, 2008) 이러한 통찰력에 기반하여 공공정책을 설계하려는 시도들이 미국과 영국을 위시한 많은 나라에서 활발하게 이루어지고 있다. 예를 들어, 오바마(Obama) 대통령은 「행정명령 13707」을 통해 행동경제학의 이론적 통찰력을 기반하여 국민들에게 좋은 일자리, 건강한 삶, 교육, 그리고 저탄소사회를 만들 수 있음을 강조하였으며 이러한 행정명령에 기반하여 최신 행동경제학 연구를 기반으로 정부정책 설계에 조언과 지침을 제공하는 SBST(the Social and Behavioral Sciences Team)를 운영하고 있다.¹¹⁾

요약하자면 이번 장에서는 정부의 조세·재정정책 및 규제의 설계에 경제학자들의 참여는 정책 설계의 성격에 따라 세 가지로 구분하였고 각 분야별 구체적인 연구동향을 살펴보았다. 최근 활발하게 이루어지고 있는 실증경제학과 기계학습 방법론의 접목을 고려하였을 때 경제학자의 정책 설계의 참여는 정부에 새로운 조언과 지침을 보다 많이 제공해 줄 것으로 기대된다.

11) 「행정명령 13707」에 대한 전문은 아래의 링크를 통해서 확인할 수 있다.
<https://www.whitehouse.gov/sites/whitehouse.gov/files/images/EO%2013707%20Implementation%20Guidance.pdf>, 접속일자: 2020. 12. 11.

IV. 머신러닝을 활용한 정책의 효과성 평가

1. 정책의 효과성 평가

가. 정책 효과성 평가

정책의 효과성 평가(evaluation)는 정책의 시행으로 인한 정책 목적을 달성했는지의 여부(효과성 유무 여부)와 그러한 효과의 크기가 어느 정도인지를 파악하는 과정을 의미한다. 예를 들어, 국가가 노인·장애인·생활보호대상자 등 취약계층의 재산형성을 지원하기 위하여 도입한 비과세종합저축에 대한 과세특례 정책의 효과성 평가를 고려해보자. 비과세종합저축에 대한 과세특례는 정책 대상자인 65세 이상 거주자, 장애인, 독립유공자와 그 유족 또는 가족, 상이자, 기초생활수급자, 고엽제후유의증 환자, 5·18민주화운동 부상자 등을 대상으로 그들이 가입한 비과세종합저축에서 발생하는 이자소득 또는 배당소득에 대하여 비과세하는 제도이다. 정책입안자는 생계형 저축을 지원하는 이 정책을 통해 취약계층이 안정적인 삶을 영위할 수 있는 재산형성에 도움을 줄 수 있기를 기대하고 있다. 이를 위해 정책입안자는 해당 정책이 취약계층의 재산형성에 어느 정도로 기여하였는지, 그렇다면 그 효과의 크기는 어느 정도인지 알고 싶을 것이다. 경제학자들은 이러한 정책의 효과성 분석을 엄밀히 수행하고 분석결과에 따라 효율적인 운영 개선안을 제안할 수 있다.

효과성 평가를 실제로 수행하기 위해 가장 우선적으로 고려해야 할 것은 해당 정책의 수혜를 받은 집단과 그렇지 않은 집단의 성과를 비교하는 것이다. 하지만 두 집단 성과의 단순 비교는 주의를 필요로 한다. 비과세종합저축의 경우 본 금융상품에 가입하는 것은 전적으로 개인의 선택에 달려 있기 때문이다. 만약 취약계층 중에서도 상대적으로 높은 저축여력을 지니고 있

는 집단이 주로 비과세 금융상품에 가입하였다면, 우리가 관찰할 수 있는 두 집단 간 저축액의 차이는 정책 본연의 성과와 정책효과 이전의 개인의 역량(여유 자산, 저축 성향 등)의 차이가 결합된 것이기 때문이다. 만약 후자의 크기가 크다면 이러한 집단 간의 단순 비교를 정책의 성과로 상정하는 것은 정책의 효과성 평가를 과소 혹은 과대하게 측정하는 것일 수 있다.

앞의 예에서 살펴본 바와 같이 정책의 효과성을 측정하는 일은 일견 직관적인 작업으로 보이지만, 실제로 그 정확한 크기를 가늠하는 것은 결코 쉽지 않다. 그 이유를 이론적으로 따져보기 위해 위에서 설명한 예를 활용하여 정책 평가론의 기본적인 구조를 살펴보자.¹²⁾

비과세종합저축의 가입을 고려하고 있는 개인을 영어 소문자 i 로 표현하고 그가 정책에 가입했을 경우의 성과(예를 들어, 저축액)를 Y_i^T 로, 가입하지 않았을 경우의 성과를 Y_i^C 로 표현하자. (Y_i^T, Y_i^C) 는 정책 대상자 개인 i 의 잠재적 성과(potential outcomes)로서 사전에 정해져 있으며 실제로 가입했는지의 여부에 따라 둘 중 하나의 값만이 개인 i 의 실현된 성과(realized outcome) Y_i 로 관측된다. 정책이 개인 i 에게 미치는 영향을 계산하기 위해서는 정책에 가입했을 경우의 성과 Y_i^T 에서 가입하지 않았을 경우의 성과 Y_i^C 를 차감해야 한다. 하지만 개인 i 는 정책에 가입하거나 하지 않는, 둘 중 하나의 선택만을 할 수 있기 때문에, 연구자는 개인 i 의 정책의 가입 및 미가입에 따르는 잠재적 성과(Y_i^T, Y_i^C) 두 가지를 동시에 관측할 수 없으며, 따라서 정책이 개인에게 미치는 영향 $Y_i^T - Y_i^C$ 은 현실적으로 계산이 불가능하다. 바로 이것이 인과적 추론에 있어서의 근본문제(Fundamental Problem for Causal Inference)로 불리는 이유이다.

이러한 문제는 정책의 평균적인 효과를 구할 때에도 똑같이 발생한다. 저축능력, 기존의 보유 자산 등 정책 가입 이전의 개인 간의 차이에 따라 정책의 효과가 다르게 나타날 수 있기 때문에 사실 정책 담당자 입장에서 더욱 중요한 숫자는 정책효과와 평균값 $E[Y_i^T - Y_i^C] = E[Y_i^T] - E[Y_i^C]$ 이다. 하지만 인과적 추론에 있어서 근본문제로 인하여 관측할 수 있는 데이터만을 가

12) 정책평가론의 기본구조에 대한 설명은 오영민 외(2015) 내용을 바탕으로 작성하였다.

지고 이 값을 계산하는 것은 불가능하다. 그 이유를 살펴보기 위해 변수 D_i 를 정책에 가입할 경우 1, 가입하지 않는 경우에는 0의 값을 갖는 더미변수로 정의하자. 정책에 가입한 사람들을 대상으로 파악할 수 있는 성과의 평균값은 조건부 평균 $E[Y_i^T|D_i=1]$ 으로, 이는 모든 개인을 대상으로 정책 가입 성과를 평균한 $E[Y_i^T]$ 와는 다른 값일 것으로 판단된다. 마찬가지로 정책에 가입하지 않은 사람을 대상으로 미가입 시의 성과를 평균한 값은 조건부 평균 $E[Y_i^C|D_i=0]$ 으로 $E[Y_i^C]$ 와는 일반적으로 다르다. 따라서 관측가능한 데이터만을 가지고 정책효과의 평균값 $E[Y_i^T - Y_i^C]$ 을 계산 또는 추정할 수 있는 방법은 없다.

그렇다면 관측 가능한 데이터를 이용해 정책에 가입한 사람의 성과 평균에서 가입하지 않은 사람의 성과 평균을 차감한 값은 무엇일까? 먼저 그 차이를 아래와 같이 다시 써보자.

$$E[Y_i^T|D_i=1] - E[Y_i^C|D_i=0] = (E[Y_i^T|D_i=1] - E[Y_i^C|D_i=1]) + (E[Y_i^C|D_i=1] - E[Y_i^C|D_i=0])$$

이 표현에 따르면 우리가 현실적으로 계산할 수 있는 평균의 차이는 다음 두 가지 항목의 합과 같다. 첫 번째 항목은 처치집단 대상 평균처리효과(Average treatment effects for the treated, ATT)로 정책에 가입한 사람만을 대상으로 측정한 정책의 효과로 정의된다. 두 번째 항목은 실제 정책에 가입한 사람들이 만약 가입하지 않았을 가상의 경우의 성과평균 $E[Y_i^C|D_i=1]$ 에서 실제 정책에 가입하지 않은 사람들의 성과평균 $E[Y_i^C|D_i=0]$ 을 차감한 값이다. 다시 말해 이 값은 정책에 가입한 집단과 그렇지 않은 집단 사이에 관찰되는, 정책 가입 여부와는 무관한 본연적인 성과의 차이를 의미한다. 이 항목은 선택편향(selection bias)이라고 정의되며, 일반적으로 경우에 따라 양수, 음수 또는 0의 값을 가질 수 있다. 예를 들어, 실제로 비과세종합저축에 가입한 사람들이 비가입자에 비해 자산형성 능력이 상대적으로 뛰어나다면 이 두 번째 항목은 양(+)의 값을 갖게 된다.

위의 결과로부터 우리는 위의 식의 두 번째 항목, 즉 선택편향이 존재하지 않는다면 정책에 가입한 사람의 성과평균에서 가입하지 않은 사람의 성과평균을 차감한 값은 정책에 가입한 사람들을 대상으로 한 정책효과의 평균값이라는 사실을 알 수 있다. 더불어 만약 한 개인의 잠재적 성과와 정책 가입 여부 사이에 상관관계를 찾을 수 없을 때(unrelated), 이 값은 우리가 알고자 하는 정책효과의 평균값인

$$E[Y_i^T - Y_i^C] = E[Y_i^T] - E[Y_i^C]$$

과 같다는 사실이 알려져 있다(Angrist, et al., 1996). 또한, 회귀식 $Y_i = \beta_0 + \beta_1 D_i + \epsilon_i$ 을 최소자승법(ordinary least squares) 방법을 이용해 추정 한 $\hat{\beta}_1$ 값은 위에서 설명한 정책에 가입한 사람의 성과평균에서 가입하지 않은 사람의 성과평균을 차감한 값과 같다.

$$\hat{\beta} = \hat{E}[Y_i^T | D_i = 1] - \hat{E}[Y_i^C | D_i = 0]$$

하지만 선택편향이 존재하지 않는다는 가정하에서만 추정치 $\hat{\beta}_1$ 가 정책효과의 평균값과 같다는 결론에 다다를 수 있기 때문에, 정책효과의 엄밀한 측정을 위해서는 정책에 가입한 사람과 그렇지 않은 사람 사이의 본연의 차이, 즉 정책 가입 이전의 효과 차이인 선택편향을 없앨 수 있는 방안을 강구해야 한다. 이는 정책 가입 여부와 개인의 특성 간의 관련성, 즉 상관관계를 끊어내야 함을 의미하며, 이를 위한 대표적인 방법은 정책 가입 자격을 무작위적으로 부여해 정책 가입 자격이 주어진 처치집단과 그렇지 않은 비교집단 사이의 특성 차이가 (통계학적으로) 균형을 이루게 하는 것이다. 이렇게 정책의 처치집단(수혜집단)과 비교집단을 무작위로 구성하여 측정된 정책의 효과가 선택편향으로부터 자유롭도록 설계한 정책 평가방법을 무작위통제실험(RCT, Randomized Controlled Trials)이라 하며 정책의 성과를 가장 엄밀히 평가할 수 있는 방안 중 하나(golden standard of causal inference)

로 인식되고 있다. 최근에는 정책의 효과를 평가하는 데 가장 엄정한 인과 관계를 증명할 수 있는 방법인 무작위통제실험의 결과 분석에 머신러닝을 접목하여, 정책에 이질적 효과가 있는지의 여부뿐 아니라 어떤 특성이 이러한 이질적 효과를 야기하는지 등을 종합적으로 파악할 수 있는 머신러닝 분석법이 제시되었다(Chernozhukov et al., 2018; 오영민 외, 2015).

나. 정책의 이질적 처치효과

앞서 다룬 인과적 추론의 근본문제로 인해, 정책의 효과는 개인 단위에서는 파악하지 못하고 연구자들은 대체로 개인 효과들을 평균한 평균 처치효과를 파악할 수 있는 추정량을 선호한다. 하지만 전체 그룹 내의 부집단(subgroup)별로 처치효과가 상당히 이질적이어서 평균효과를 파악하는 것에 제약이 존재하거나, 혹은 부집단별로 개별적인 처치효과를 파악하는 것 자체가 정책 설계나 평가에 더 큰 함의를 주는 경우도 충분히 존재한다. 물론 정책의 효과성 평가 시 정책 대상자의 평균효과가 주요 관심사이며, 그러한 평균효과의 유무 여부가 정책의 성패를 좌우하는 주요 평가 요소로 고려된다. 하지만 특정 집단에서는 부(-)의 효과가 나타나고, 반대로 또 다른 특정 집단에서는 양(+)의 효과가 나타나는 경우, 집단 전체의 평균효과를 구하는 선형분석의 경우 영(0)의 효과가 추정될 가능성이 있다. 또한, 양(+)의 효과가 나타날 것으로 사전적으로 기대했던 특정 집단이 부(-)의 효과가 나타나는 경우, 해당 집단을 파악하고 그 집단의 특성을 특정할 수 있다면, 좀 더 효과적인 정책 설계가 가능할 것이다. 가령 비과세종합저축의 경우 해당 금융상품의 가입을 결정하게 하는 데 대상자의 어떤 특성이 가장 크게 영향을 끼치며, 또 어떠한 특성을 공유하고 있는 특정 집단이 가장 높은 가입률을 기록하고 혹은 가장 높은 저축효과 또는 자산형성 효과를 기록하는지 파악하는 것이 중요하다.

이렇게 머신러닝이 정책효과 예측에 유용한 분석도구를 제공하고 있는 이유는 바로 정책의 이질적 효과를 살펴보는 데 아주 탁월하기 때문이다. 기존 선형모델에서는 처치변수와 함께 실험집단 특성변수의 교차항을 추가하

여 특정한 사전적 특성을 공유한 그룹의 정책효과가 더 크게 나타남을 발견하였으나, 머신러닝은 실험군의 특성을 유연하게 조합하여 개인 수준에서의 정책효과를 예측할 수 있다(Wager and Athey, 2018). 하지만 기존의 선형회귀 분석에서도 이질적 처치효과를 탐색하는 것은 어느 정도 가능하였던 것이 사실이다. 전체 표본 중 특정 조건을 만족시키는 부표본으로 제한한 후, 처치효과를 구하거나 전체 표본을 활용하지만, 특성 변수와 처치변수의 교차항을 추가하여 교차항의 계수의 통계적 유의성을 파악함으로써 가능하였다. 예를 들어, 기존 금융자산의 보유 정도가 비과세종합저축의 가입 여부를 결정짓는 데 가장 크게 영향을 끼치는 특성 변수임을 사전적으로 가정하고 부표본을 만들거나 교차항으로 포함시킬 수 있다.

하지만, 이러한 선형모델을 통한 이질성 탐색은 크게 두 가지 단점을 지니고 있다. 우선 선형모델은 처치변수와 하나하나의 특성변수와의 교차항 계수의 통계적 유의성을 파악하고 그 의미를 전달하는 데에는 어느 정도 효과적이지만, 한 개 이상의 여러 특성변수가 유연하게 조합되어 만들어내는 부표본 내에서 처치효과를 판단하고 싶은 경우, 관측치의 수보다 추정해야 할 모수의 수가 많아지는 경우가 충분히 발생 가능하다. 가령 5개의 특성변수가 존재하고 하나의 처치변수가 있다고 가정하면, 특정변수에 따라 다른 이질적 효과를 탐색해내기 위해 총 64개의 계수를 추정해내야 한다. 이러한 제약으로 인해 연구자는 이질적 처치효과에 가장 큰 영향을 끼칠 것으로 고려되는 일부의 특성변수만을 선택하여 이질적 처치효과 분석을 수행하는데, 바로 이 과정에서 연구자의 처치효과에 대한 가정이 포함되게 된다. 이론적 모델에 기반한 실증분석의 경우, 해당 특성변수의 선택은 이론적 근거가 있긴 하지만, 대부분의 실증 분석의 경우 이질적 효과를 낼 것으로 ‘기대’하는 변수를 선택하고 분석을 진행하기 때문에, 실제로는 가장 큰 이질적 효과를 가져올 특성변수는 연구자의 가정에 포함되지 않는 특성변수일 가능성이 충분히 존재한다.

이렇게 기존의 선형회귀모델로는 이질적 효과 분석에 어느 정도의 한계가 존재하며, 바로 이러한 점이 머신러닝이 이질적 효과성 탐색 측면에서 주목

을 받고 있는 이유이다. 머신러닝은 연구자의 가정 같은 아무런 사전 정보 없이 처치효과의 이질성을 이끌어내는 특성변수들을 효율적으로 선별해낼 수 있는 방법론을 제시한다. 예를 들어 머신러닝 방법론 중에 다음 절에서 다룰 커절포레스트는 특성 변수들 중에 처치효과에 가장 큰 영향을 끼치는 특성변수 중요도를 직관적으로 제시한다.


다. 커절포레스트의 특징

단순히 예측의 문제를 탐색하는 데 머신러닝이 사용된 것을 넘어서서, 최근에는 머신러닝 방법론을 사용한 인과적 효과 탐색, 좀 더 정확히는 이질적 처치효과(Heterogeneous treatment effects) 탐색 방법에 관한 연구 논문들이 계속해서 발표되고 있다. 가장 대표적으로 Athey et al.(2019)이 논의한 커절포레스트(Causal Forest)이다. 기본적으로 랜덤포레스트의 학습방법, 즉 개별적인 결정트리를 반복적으로 구성하고 이를 통합적으로 대표할 수 있는 모형을 구성하는 방식은 그대로 사용하되 각각의 개별 트리들을 단순 평균 내는 것이 아닌, 각각의 결정트리에 다른 가중치를 부여하여 인과적 효과를 탐색하는 작업을 거친다.

특히 이질적 처치효과를 추정해내는 데 있어 랜덤포레스트 방식과 비교해 커절포레스트가 가진 특성은 크게 두 가지로 정리할 수 있다. 첫째로, 기존 랜덤포레스트에서는 회귀분류의 경우 각 영역 내에서 잔차제곱합이 최소가 되도록 개별 결정트리를 성장시킨다. 하지만 커절포레스트의 경우, 각 영역에 분류된 처치그룹과 통제그룹 간의 관심변수(y) 값의 차이로 계산되는 처치효과가 가장 큰 값을 가질 수 있도록 분류를 진행한다. 둘째로, 예측치를 제공하는 것과 비교하여 인과적 처치효과를 다루는 것이 지니는 가장 큰 차이점 중 하나는 처치효과에 대한 통계적 유의성을 함께 제공해야 한다는 것이다. 이를 해결하기 위해 Athey et al.(2019)은 Honest tree 방법론을 제시하고 있다. 동일한 관측치를 가지고 개별 결정트리를 성장시키고 처치효과를 구하는 데에 동시에 사용할 수 없다는 전제하에 기존의 훈련데이터를 다시 한 번 더 임의로 나누어서, 분절데이터(Splitting subsample)와 추정데이

터(Estimating subsample)로 구분하고, 분절데이터는 개별 결정트리를 키우는 데 사용하고 추정데이터는 처치효과와 예측값을 만들어내는 데에 사용한다. 즉, 우선 분절데이터셋을 사용하여 성장시킨 개별 결정트리에 추정데이터를 입력하여 처치그룹과 통제그룹 간의 효과 차이의 평균, 즉 개별 처치효과와 예측값을 구한다. 이 과정은 결국 처치집단과 비교집단을 통계적으로 균형을 이루게 한 후, 선택편향의 영향을 최소화한 무작위통제실험을 개별 결정트리를 통해 구성하는 과정으로 이해할 수 있으며, 따라서 커절포레스트가 추정하는 처치효과는 일치추정량(consistent estimator)으로 간주할 수 있게 된다. 이러한 과정을 통해 추정된 이질적 처치효과 예측의 우수성은 예시로 제시된 아래 [그림 IV-1]에서 살펴볼 수 있다.

[그림 IV-1] 선형회귀와 커절포레스트의 이질적 처치효과 추정 비교



자료: STATWORX Blog, "Machine Learning Goes Causal II: Meet the Random Forest's Causal Brother," <https://www.statworx.com/ch/blog/machine-learning-goes-causal-ii-meet-the-random-forests-causal-brother/>, 접속일자: 2020. 12. 10.

[그림 IV-1]의 좌측 도표는 변수 x_1 과 x_2 를 조합하여 각각의 변수의 조합별로 처치효과가 상이한 가상의 예를 설정한 그림이다. 즉, 특정 x_1 과 x_2 값의 조합에 의해 각각의 관측치는 개별적으로 더 높은 정책의 효과(붉은색)를 보일 수 있고, 상대적으로 낮은(녹색) 효과를 나타낼 수 있다. 이러한 개별 단위의 정책효과와 예측치를 구하는 데 있어, 본 예시는 두 가지 예측모델의 성능을 보여주고 있다. 우선 가운데 도표는 선형모델로 개별 처치효과

를 구했을 때의 경우이다. 실제의 이질적 처치효과(좌측 도표)와 상당히 차이가 있게 개별 처치효과와 예측치가 도출되었으며, 이는 특성변수 x_1 과 x_2 를 선형으로밖에 결합할 수 없는 모델의 한계 때문인 것으로 이해할 수 있다. 반면, 우측의 도표는 커질포레스트를 활용하여 개인단위의 예측된 처치효과를 보여주고 있다. 좌측의 도표와 거의 흡사한 형태를 보여주고 있어, 기존 선형모델 대비 특성변수를 유연하게 조합하여 거의 실제와 가깝게 처치효과를 예측한 것을 파악할 수 있다.

2. 조세정책의 효과성 평가: 비과세종합저축 과세특례를 중심으로

가. 분석의 개요

본 연구에서는 2019년 수행한 조세특례평가 중, 비과세종합저축에 대한 과세특례(「조세특례제한법」 제88조의 2)를 선정하여 커질포레스트 분석을 진행한다. 머신러닝을 활용한 정책효과 분석이 기존 선형회귀를 활용한 분석과 비교하여 얼마나 엄밀하게 정책 효과성을 분석할 수 있을지, 또 기존 분석에서 더 나아가 좀 더 효과적인 정책 설계를 할 수 있는 정책적 함의를 도출할 수 있을지를 살펴본다.

비과세종합저축에 대한 과세특례는 노인·장애인·생활보호대상자 등 취약계층의 재산형성을 지원하기 위하여 도입된 제도로, 생계형 저축에 대하여 비과세하는 조세특례제도이다. 주 정책 대상자는 65세 이상 거주자, 장애인, 독립유공자와 그 유족 또는 가족, 상이자, 기초생활수급자, 고엽제후유의증환자, 5·18민주화운동부상자 등이나, 2018년 말 기준, 전체 가입자 427만명 중 65세 이상이 92.5%인 약 395만명으로 65세 이상 거주자가 본 과세특례제도의 주 정책 대상임을 파악할 수 있다. 정책 대상자들은 금융회사 및 6대 공제회가 취급하는 저축(투자신탁·보험·공제 등 포함) 상품에 비과세 적용을 신청하여 가입하며, 비과세종합저축에서 발생하는 이자소득 또는 배당소득에 대하여 비과세하고 있다. 기존 『비과세종합저축에 과세특례 의무심층평가』 보고서(정재현 외, 2019)에서는 노인, 장애인 및 저

소득층 등 취약계층에 대한 자산형성지원은 사회투자 관점, 사회정책 관점 및 제도적 저축이론 측면에서 타당성이 충분한 것으로 평가하여 지원대상으로 적정하다고 판단하였다. 하지만, 일부 만 65세 이상 노인 또는 장애인 중 고소득층 및 고액자산가에게 혜택이 집중될 가능성도 존재하여, 수직적 형평성을 저해할 가능성이 있어, 이를 완화하기 위한 다양한 보완책을 마련할 필요가 있음을 지적하였다. 실제로 국세청 납세자료를 활용하여 가입자 특성을 분석한 결과, 금융소득이 높을수록, 그리고 다른 비과세·감면 금융상품을 활용 중인 저축자일수록 본 과세특례에 가입할 가능성이 높은 것으로 나타난 바 있다. 금융소득 하위 5분위의 가입률은 평균 약 3%에 불과한 반면 상위 5분위의 가입률은 약 69%로, 금융소득 상위 3분위가 보유한 비과세종합저축에서 발생하는 금융소득이 전체의 약 91%를 차지하고 있기 때문이다.

기존 보고서(정재현 외, 2019)의 효과성 분석에서는 2014년 법 개정과정에서 가입가능 연령이 상향(가입가능 연령제한을 60세에서 65세로 상향)되었고, 따라서 가입조건이 외생적으로 결정되는 준실험적 방법을 통해 간접적으로 정책 도입의 평균효과를 추정하였다. 통계청에서 발표하는 가계금융복지조사를 활용하여 분석을 진행한 결과 첫째로, 비과세종합저축 과세특례제도의 저축, 자산이동, 자산형성지원 등에 대한 전체 대상 그룹에 대한 평균효과는 통계적으로 유의미하지 않은 것으로 제시하였다. 그다음으로, 비과세종합저축 과세 특례제도가 가입대상 전체에 평균적으로는 유의미한 효과가 없을 수 있으나 세부 특정 집단에는 효과가 나타날 수 있는 가능성을 검정할 필요성이 있다고 판단하여 근로 및 사업소득이 있는 가구와 없는 가구로 구분하여 각각 분석을 진행하였다. 분석결과, 전체 표본에 대한 분석에서와 마찬가지로 근로 및 사업소득이 있는 가구와 근로 및 사업소득이 없는 가구 모두에서 통계적으로 유의미한 계수가 추정되지 않았다. 마지막으로, 순자산액 5분위 중 1분위에 속한 가구와 순자산액 5분위 가구에 대하여 비과세종합저축 제도의 효과를 분석하였다. 정책의 기본 목표 중 하나가 저소득층의 저축 및 재산 형성에 기여하는 것이기 때문에 저소득층

중심으로 정책효과가 나타날 가능성을 평가할 필요성이 있고 또한, 자산이 많은 가구들의 경우 저축 여력이 높아 본 제도의 혜택을 더 많이 받을 수 있는 유인이 존재하기 때문에 순자산액이 높은 가구를 중심으로 정책효과를 검정할 필요성 역시 존재하기 때문이다. 하지만 앞선 분석결과와 마찬가지로, 순자산액 기준 1분위 가구와 5분위 가구 모두에서 저축, 자산이동, 자산형성지원 등에 대한 통계적으로 유의미한 계수가 추정되지 않았다. 물론, 본 정책의 평균효과가 실질적으로 크지 않을 가능성을 충분히 고려할 수 있겠으나, 기존 분석의 특성상 정책 대상자 개인 수준의 정책효과를 파악하는 데에는 한계가 있다는 점 또한 유념해야 한다. 다음 절에서는 이 점에 주목하여, 다양한 특성변수를 조합할 수 있는 머신러닝을 활용해 개선된 효과성 추정치, 특히 가입 대상자별로 정책효과의 예측치를 도출하는 이질적 처치효과를 탐색할 예정이다.

나. 분석방법

기존 비과세종합저축 과세특례의 효과성 평가를 진행한, 『조세특례 심층 평가 보고서』(정재현 외, 2019)에 제시된 실증분석 방법론을 최대한 활용하여 머신러닝이 얼마나 이질적 효과성 분석에 유용하게 쓰일 수 있을지를 탐색하도록 한다. 비과세종합저축의 주요 정책 대상은 노인계층으로, 가입 가능 대상자에 대한 연령 기준이 외생적으로 변경된 사례가 있었다. 즉, 2014년 법 개정 과정에서 가입가능 연령제한을 60세에서 65세로 강화하고 가입가능연령을 1세씩 점진적으로 상향조정함에 따라 2014년 당시 60세였던 1954년생은 2014년 이후 항시 가입 가능하나, 당시 59세였던 1955년생은 2019년 당시까지 가입이 불가하였다. 이러한 외생적인 자격기준 변화를 활용하여 기존 효과성 분석(정재현 외, 2019)에서는 두 집단 간의 저축 행태 비교를 통하여 비과세종합저축의 효과를 측정한 바 있다. 구체적으로는, 1954년생과 1955년생은 비과세종합저축 가입 자격을 제외한 모든 점에서 유사한 두 집단이라는 합리적 가정하에, 1954년생의 만 60세를 기점으로 저축액, 저축 형태(금융 혹은 실물자산), 자산 형성의 변화와, 1955년생의 만

60세 이후의 변화를 비교하는 이중차분법을 통해 비과세종합저축의 효과를 측정하였다. 즉, 1954년생과 1955년생이 가입자격 외에 다른 특성들에는 차이가 없다는 가정을 한다면, 해당 기간 동안 1954년생이 처치그룹, 1955년생은 통제집단으로 정의할 수 있다. 이전 연구에서는 저축효과, 자산효과 등의 다양한 지표를 활용하여 정책의 효과성을 판별하려 하였으나, 이질적 효과를 파악하는 예시를 제시하고자 하는 본 연구의 특성상, 가장 큰 변화가 예상되는 저축효과, 구체적으로는 적립식 예금의 증감 유무를 가지고 정책의 효과성을 판별하고자 한다.

본 분석에 활용된 자료는 2014년부터 2019년까지의 가계금융복지조사로, 샘플 중 가구주가 비과세종합저축에 가입이 가능한 2016년 기준 만 60세를 처치그룹으로, 만 59세를 통제그룹으로 하여, 만 1세씩 증가하여 분석 표본을 설정하였다. 총 4,290명을 분석 샘플로 하여 이 중 처치그룹은 1,875명으로 43.7%를, 통제그룹은 2,415명으로 나머지 56.3%를 차지하고 있다. 커질 포레스트 분석에 포함된 특성변수는 적립식 저축액의 결정과 높은 상관관계를 지니는, 즉 내생성을 갖는 변수들은 제외하고 적립식 저축액의 결정 전에 이미 정해진 것이라고 합리적으로 가정할 수 있는 변수들을 위주로 분석에 포함하였다. 특성변수 리스트는 가구주의 성별, 가구원 수, 가구주의 교육 수준, 가구주의 동거 여부, 수도권 거주 여부, 가구주의 직업과 종사하는 산업군, 근로형태, 혼인 상태, 소득 5분위 등이다.

〈표 IV-1〉 주요 변수

특성 변수 구분	특성변수 내역
가구주 개인특성	가구주 성별, 가구원 수, 가구주 동거 여부(1인 가구, 같이 살고 있음, 따로 살고 있음(직장), 따로 살고 있음(학업 등)), 가구주 혼인상태(미혼, 배우자 있음, 사별, 이혼) 수도권 거주 여부
가구주 교육 수준	안 받음, 초등학교, 중학교, 고등학교, 대학(3년제 이하), 대학교(4년제 이상), 대학원 이상
가구주 직업	관리자, 전문가 및 관련종사자, 사무종사자, 서비스 종사자, 판매 종사자, 농림어업숙련 종사자, 기능원 및 관련 기능 종사자, 장치·기계조작 및 조립 종사자, 단순노무 종사자, 군인
가구주 종사상 지위	상용근로자, 임시·일용 근로자, 고용원이 있는 자영업자, 고용원이 없는 자영업자, 무급가족 종사자, 기타 종사자(실적급의 보험설계사, 대리 운전기사, 학습지 방문 교사 등), 기타(무직자, 가사, 학생 등)
가구주 종사 산업군	농업·임업 및 어업, 광업, 제조업, 전기·가스·증기 및 수도사업, 하수·폐기물처리·원료재생 및 환경복원업, 건설업, 도매 및 소매업, 운수업, 숙박 및 음식점업, 출판·영상·방송통신 및 정보서비스업, 금융 및 보험업, 부동산업 및 임대업, 전문·과학 및 기술 서비스업, 사업시설관리 및 사업지원 서비스업, 공공행정·국방 및 사회보장 행정, 교육 서비스업, 보건업 및 사회복지 서비스업, 예술·스포츠 및 여가관련 서비스업, 협회 및 단체·수리 및 기타 개인 서비스업, 가구내 고용활동 및 달리 분류되지 않은 자가소비 생산활동, 국제 및 외국기관
가구주 소득 분위	경상소득 5분위 보완자료

자료: 통계청, 「가계금융복지조사」 코드집(가구 마스터)을 기반으로 저자 작성

분석에 앞서 비과세종합저축의 가입 자격 여부는 출생연도로 결정되지만 분석 기간 중의 적립식 저축액은 연령이 증가함에 따라 달라질 수 있음을 고려하여, 해당 해의 적립식 저축액을 연령의 고정효과를 통제하고 남은 잔차를 사용하여 분석을 수행하였다. 다양한 머신러닝 패키지를 제공하고 있는 R을 사용하여 분석을 수행하였으며, 커절포레스트는 grf패키지를 사용하여 분석을 수행하였다.

다. 분석결과

우선 <표 IV-2>는 선형회귀¹³⁾분석결과를 보여주고 있다. 연령의 고정효과를 통제하고 남은 적립식 저축액의 잔차를 종속변수로, 비과세종합저축에 가입 가능한 1954년생 여부를 처치변수로 설정하여 선형회귀 결과를 도출하였다.

〈표 IV-2〉 선형회귀 결과

(단위: 만원)

특성 변수	반응 변수: 적립식 예금액 총액(잔차)
비과세종합저축 가입자격(1954년생)	-0.0000445 (560.7847)

자료: 통계청, 「가계금융복지조사」 자료를 이용하여 저자 작성

이전 정재현 외(2019)의 분석결과와 같이 음(-)의 계수를 보여주고, 통계적으로 유의미하게 측정되지 않았음을 알 수 있다. 이는 가입자격이 주어지지 않은 1955년생과 비교하여, 1954년생에게 주어진 비과세종합저축의 가입 자격의 평균 처치효과가 통계적으로 유의미하지 않음을 의미한다. 이어서 처치변수 외에도 <표 IV-1>에서 설명한 주요 특성변수를 추가로 포함하여 선형회귀 분석을 수행하였다. 처치변수와 함께 통계적으로 유의미하게 측정된 특성변수를 추려 <표 IV-3>에 정리하여 제시하였다.

13) 선형회귀식은 다음과 같다: $y_{it} = \alpha + \beta D_{1954} + X'_{it}\gamma + \tau_t + \epsilon_{it}$, y_{it} 는 적립식 저축액, D_{1954} 는 1954년생 여부, 즉 비과세종합저축 가입자격을, X 는 개인 특성변수를, τ_t 는 연령 고정효과이다.

〈표 IV-3〉 특성변수를 포함한 선형회귀 결과

(단위: 만원)

특성 변수	반응 변수: 적립식 예금액 총액(잔차)
비과세종합저축 가입자격(1954년생)	296.8 (527.5)
가구원 수	-704.9** (331.9)
가구주 교육수준	1,774*** (224.6)
수도권 거주여부	1,127* (579.2)
가구주 직업의 관리자 여부	13,324*** (3,424)
소득 1분위 여부	-15,628*** (1,156)
소득 2분위 여부	-12,712*** (990.4)
소득 3분위 여부	-11,191*** (947.0)
소득 4분위 여부	-9,159*** (937.3)
Observations	4,290
R-squared	0.153

주: *, **, *** 은 각 10%, 5%, 1% 수준에서 통계적으로 유의함
자료: 저자 작성


처치변수의 경우 이전의 결과와 마찬가지로, 계수의 크기와 방향은 변화하였지만 여전히 통계적으로 유의미하게 측정되지 않았음을 알 수 있다. 하지만, 주요 특정변수들 중 가구원 수, 가구주의 교육수준, 수도권 거주 여부, 가구주의 관리자(직업) 여부, 그리고 소득의 크기(소득 분위) 등이 적립식 저축액의 크기가 같은 연령대의 다른 가구에 비해 평균적으로 적은지 혹은 많은지를 결정할 수 있음을 파악할 수 있다. 대체적으로 가구원 수가

많을수록 그리고 소득 분위가 5분위에서 1분위로 갈수록, 즉 소득이 줄어들수록 적립식 저축액의 크기가 평균에 비해 적은 양상을 보이며, 반대로, 가구주의 교육 수준이 높을수록, 수도권에 거주하는 경우, 그리고 가구주의 직업이 관리자인 경우 적립식 저축액의 규모가 상대적으로 큰 것을 관찰할 수 있다.

하지만 두 선형회귀 분석의 결과 처치변수, 즉 비과세종합저축의 저축효과(적립식 저축)가 0이 아닐 것이라고 판단하기에는 충분한 근거를 제시해 주고 있지 못하다는 결론은 동일하게 도출할 수 있다. 물론 평균효과의 유무 여부가 정책의 성패를 좌우하는 주요 평가 요소로 고려되지만, 특정 집단에서는 부(-)의 효과가 나고, 반대로 또 다른 특정 집단에서는 양(+)의 효과가 나타나는 경우, 집단 전체의 평균효과를 구하는 선형분석의 경우 영(0)의 효과가 추정될 가능성을 배제할 수 없다. 또한, 양(+)의 효과가 나타날 것으로 기대했던 특정 집단이 기대와는 다르게 부(-)의 효과가 나타나는 경우, 즉 비과세종합저축의 경우는 양(+)의 효과를 기대했던 저소득 취약계층에서 효과가 발견되지 않거나 부(-)의 효과가 나타나는 경우가 존재한다면, 그 이유를 세밀히 파악을 하고 이질적 처치효과를 야기하는 특성을 잘 이해할 수 있다면, 좀 더 효과적인 정책 설계가 가능할 것이다. 비과세종합저축의 경우 어떠한 특성을 공유하고 있는 특정 집단이 가장 높은 저축효과 또는 자산형성 효과를 보여주는지를 파악하는 것이 중요하다.

본 연구에서 수행한 커절포레스트 분석은 바로 이러한 경우에, 이질적 처치효과가 있었는지를 판별하는 유용한 분석방법을 제공하고 있다. 커절포레스트 분석을 통해 각각의 관측치별로 처치효과의 예측치를 구할 수 있고, 해당 처치효과를 오름차순으로 정리하여 [그림 IV-2]에 정리하였다. 대부분의 처치효과가 0에 몰려 있는 가운데, 왼쪽 끝에는 부(-)의 처치효과가 발생하고, 또 오른쪽 끝에는 양(+)의 처치효과가 발생함을 알 수 있다. 즉 비과세종합저축의 가입자격이 주어지는 해당 나이가 되는 경우, 특정 그룹의 사람들은 적립식 저축금액이 다른 그룹에 비해 낮아졌음을, 또 반대로 어떤 특정 그룹의 사람들의 적립식 저축금액이 다른 그룹에 비해 높아졌음을 뜻한다.

[그림 IV-2] 커절포레스트를 활용한 비과세종합저축의 이질적 효과 추정



자료: 통계청, 「가계금융복지조사」 자료를 활용하여 저자 작성

이제는 이러한 이질적 처치효과를 이끌어내는 주요 설명변수에 대해 탐구해야 한다. 이러한 변수를 분석하는 과정은 결국 보다 큰 정책적 효과를 거두기 위해 어떤 특성을 가진 집단으로 한정된 자원을 집중하여야 하는지를 판단하는 근거로 활용될 수 있다. 커절포레스트 분석틀 중에는 예측결과에 대한 설명을 위해서 반응변수에 영향을 미치는 특성변수들의 상대적 중요도를 제시할 수 있는 ‘특성 중요도(variable importance)’를 계산할 수 있다. 상위 5개의 주요변수를 <표 IV-4>에 정리하였으며 이는 비과세종합저축에 가입할 수 있는 가입자격이 되었을 때 적립식 저축금액의 증감 여부를 결정하는 데 영향을 미치는 주요 결정변수로 이해할 수 있다.

〈표 IV-4〉 특성 중요도 주요변수

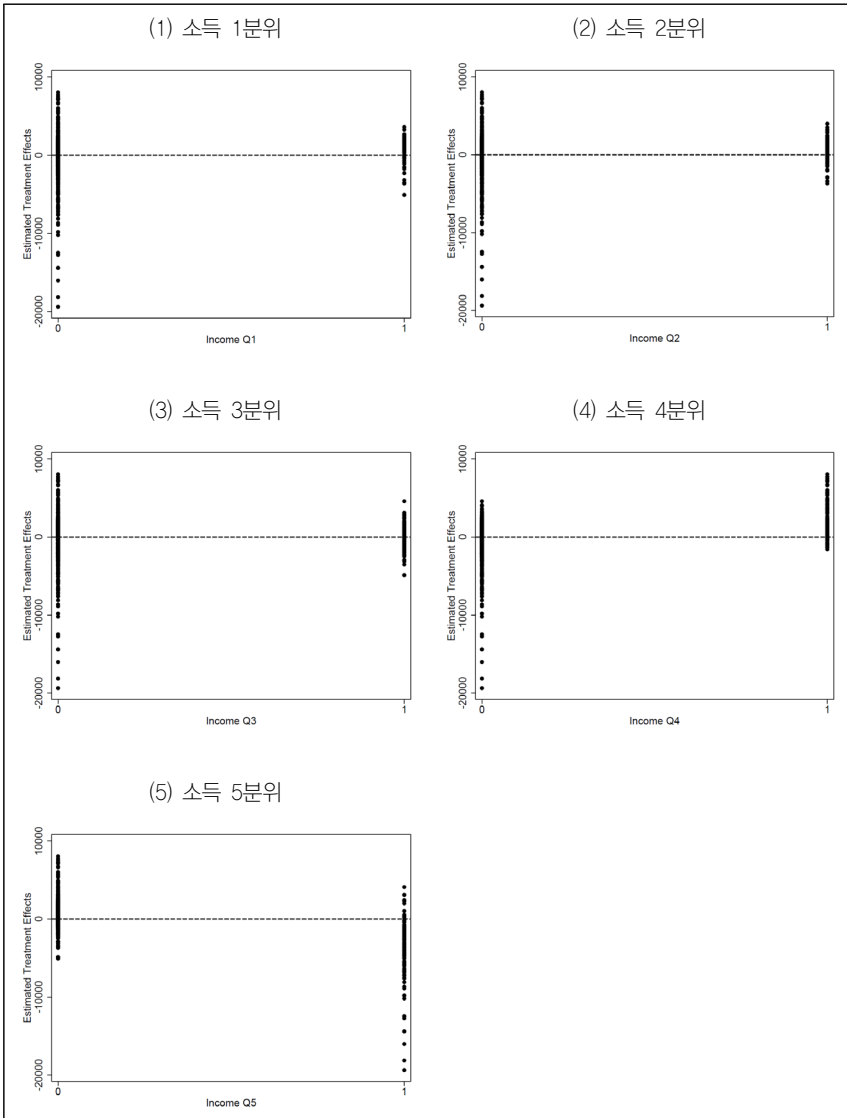
특성 변수명	상세 내역
quint_inc_Q5	소득분위 5분위 여부
hhh_educ	가구주의 교육수준
hhh_indu_F	가구주의 건설업 종사 여부
hhh_job_2	가구주의 직업이 전문가 및 관련 종사자 여부
hhh_jtype_7	가구주의 종사상 지위가 기타(무직자, 가사, 학생 등)의 여부

자료: 통계청, 「가계금융복지조사」 자료를 활용하여 저자 작성

적립식 저축액의 규모를 결정하는 데 있어 소득의 크기가 가장 중요한 요소로 작용한다는 것을 알 수 있으며 그다음으로 가구주의 교육 수준, 가구주의 종사 산업, 직업 등의 순으로 적립식 저축액의 크기와 관련이 있음을 알 수 있다.

특성 중요도 분석을 통해, 비과세종합저축 가입자격의 효과가 소득 수준에 따라 다를 수 있음을 파악하였다. 여러 개의 특성변수들이 이질적 처치 효과와 상관관계를 지니는 주요 변수임을 파악하였고 그중 하나인 소득 분위별, 특히 소득 5분위에 따라 비과세종합저축 가입자격의 정책효과를 살펴볼 수 있도록 [그림 IV-3]에서 정리하여 제시하고 있다.

[그림 IV-3] 소득분위에 따른 이질적 처치효과 추정




자료: 통계청, 「가계금융복지조사」 자료를 이용하여 저자 작성

『2019 조세특례 심층평가 보고서 (I)』(정재현 외, 2019)의 타당성 분석에서 비과세종합저축의 비과세 정책의 혜택이 저축여력이 있는 고소득 혹은

고액 자산가에게 집중될 가능성을 논의한 적이 있고 따라서 높은 소득분위, 즉 소득 5분위에서 비과세종합저축 가입자격이 적립식 저축액의 크기의 차이에 주는 영향이 어느 정도 있을 수 있다는 예측을 할 수 있다. 이는 실제로 [그림 IV-3]에서 발견할 수 있다. 각각의 그림은 소득이 해당 분위일 때 (Income $Q_x=1$) 각 소득분위에 해당하는 개인의 비과세종합저축 가입 자격이 주어졌을 때 예측할 수 있는 개인 수준별 처치효과, 즉 적립식 저축액의 증감 여부를 제시하고 있다. 그림 (1)~(4)까지는 각각의 소득분위에 해당하였을 때 처치효과가 대체적으로 0의 값에 몰려있는 가운데, 그림 (5), 즉 소득분위 5분위에 속하는 사람들이 비과세종합저축 가입 자격(만 65세)이 되었을 때 적립식 저축액의 크기가 평균과 비교하여 줄어든 수 있음(소득분위 5분위에 해당하는 개인(Income $Q_5=1$)의 개별 처치효과 크기가 0을 대체로 하회)을 보여주고 있다. 또 한 가지 주목할 점은, 소득분위 4분위의 경우, 개별 처치효과가 대체로 0에 몰려있는 가운데, 다른 소득분위의 효과와 비교하여 어느 정도 양(+)의 처치효과를 보여주고 있음을 발견할 수 있다. 각각의 분위별로 비과세종합저축 가입자격의 여부가 적립식 저축의 크기에 미치는 영향이 다른 점은 추가 분석의 대상이긴 하지만, 이렇게 각 소득분위별 개별 처치효과 크기와 방향을 살펴볼 수 있는 것은, 기존의 선형분석과 비교하여 머신러닝 분석방법을 통해 정책효과를 측정할 때 기대할 수 있는 중요 장점 중 하나로 인식될 수 있다.

그다음으로 [그림 IV-4]에서는 가구주의 교육수준에 따른 비과세종합저축 가입자격이 적립식 저축액에 미치는 영향을 개인단위에서 살펴보았다. 각각의 교육수준은 1=안 받음, 2=초등학교 졸, 3=중학교 졸, 4=고등학교 졸, 5=대학교(3년제 이하) 졸, 6=대학교(4년제 이상) 졸, 7=대학원 이상 졸의 최종 학력을 의미한다. 대부분의 개인단위의 적립식 저축액의 차이가 0에 몰려있어 비과세종합저축 가입자격이 미치는 영향이 미미하다고 판단할 수 있는 가운데, 대학교(3년제 이하) 졸(6)과 대학원 이상(7)의 학력에서 비과세종합저축의 가입자격에 따라 적립식 저축액의 규모가 차이가 발생할 수 있음을 발견할 수 있다.


[그림 IV-4] 교육수준에 따른 이질적 처치효과 추정



자료: 통계청, 「가계금융복지조사」 자료를 이용하여 저자 작성

그다음으로 [그림 IV-5]에서는 가구주의 직업에 따른 비과세종합저축 가입 자격이 적립식저축액에 미치는 영향을 개인단위에서 살펴보았다. 각각의 직업군은 1=관리자, 2=전문가 및 관련종사자, 3=사무종사자, 4=서비스 종사자, 5=판매 종사자, 6=농림어업숙련 종사자, 7=기능원 및 관련 기능 종사자, 8=장치·기계조작 및 조립 종사자, 9=단순노무 종사자, 군인을 의미한다. 대부분 직업군에서 비과세종합저축 가입자격 여부에 따른 개인단위의 적립식 저축액의 차이가 0에 몰려 있어 비과세종합저축 가입자격이 저축에 미치는 영향이 미미하다고 판단할 수 있는 가운데, 전문가 및 관련종사자(2)와 사무종사자(3)의 직업에서 비과세종합저축의 가입자격에 따라 적립식 저축액의 규모가 차이가 발생하였음을 판단할 수 있다. 앞서 진행한 분석과 일관되게, 평균적으로 높은 근로소득을 지닌, 즉 조금 더 높은 저축여력을 가질 것으로 기대할 수 있는 직업군-관련종사자(2)와 사무종사자(3)-에서 이질적인 처치효과를 관측할 수 있다.

[그림 IV-5] 직업군에 따른 이질적 처치효과 추정




자료: 통계청, 「가계금융복지조사」 자료를 이용하여 저자 작성

마지막으로 [그림 IV-6]에서는 가구주의 종사 산업군에 따른 비과세종합저축 가입자격이 적립식 저축액에 미치는 영향을 개인단위에서 살펴보았다. 각각의 산업군은 1=운수업, 2=건설업, 3=도매 및 소매업, 4=농업,임업 및 어업, 5=제조업, 6=부동산업 및 임대업, 7=사업시설관리 및 사업지원 서비스업, 8=숙박 및 음식점업, 9=공공행정, 국방 및 사회보장 행정을 의미한다. 대부분 직업군에서 비과세종합저축 가입자격 여부에 따른 개인단위의 적립식 저축액의 차이가 0에 몰려 있어 비과세종합저축 가입자격이 저축에 미치는 영향이 미미하다고 판단할 수 있는 가운데, 가구주가 건설업에 종사하는

경우(2) 비과세종합저축의 가입자격에 따라 적립식 저축액의 규모가 차이가 발생하였음을 판단할 수 있다.

[그림 IV-6] 종사 산업군에 따른 이질적 처치효과 추정



자료: 통계청, 「가계금융복지조사」 자료를 이용하여 저자 작성

분석결과를 종합하면, 앞선 소득분위에 따른 분석결과와 연장선상의 결과로 고소득, 고자산가 등 은퇴 후 여유자금에 대한 능력이 있는 경우에 한하여 비과세종합저축의 가입자격이 적립식 저축금액에 영향을 끼칠 수 있음을 의미한다. 즉, 비과세종합저축 과세특례 제도가 애초에 취약층을 대상으로 저축을 도모할 수 있도록 설계된 데 반해, 실제로 본 제도의 혜택은 실제로

저축 능력이 있는 사람들, 즉 높은 소득을 가지거나 높은 소득이나 자산을 가진 것으로 유추할 수 있는 집단(대졸 이상, 사무직 직군 등)에게서 효과가 나타날 수 있음을 암시하는 대목이다. 이렇게 머신러닝은 이전의 선형 분석으로는 파악하기 쉽지 않았던, 특정 집단의 처치효과를 분석할 수 있게 하여, 이전에 평균효과 분석에서 더 나아가 특정 제도가 가져올 특정 집단의 효과나 행태 변화의 분석을 가능하게 하여, 정책입안자로 하여금 좀 더 통찰력 있는 제도의 설계나 효과성 평가를 가능하게 한다.

V. 머신러닝을 활용한 재정정책 개선안

1. 한국의 재정정책 설계에 머신러닝 알고리즘의 활용 방안

조세·재정정책의 설계에서 중요한 부분은 첫째, 정책의 대상을 정하는 것(수급자의 기준을 정의) 그리고 둘째, 정책 대상자의 참여율을 높이는 방법이다. 이번 장에서는 기계학습 방법론이 우리나라의 조세·재정정책의 개선에 어떻게 활용될 수 있는지 두 가지 부분을 중심으로 논의한다.

가. 수급자의 기준에 대한 논의

정책의 수급자를 정하는 기준은 정책입안자의 목표가 무엇인지에 따라 다르게 나타날 수 있다. 만약에 한정된 자원을 이용하여 정책이 기대하는 효과를 최대화하는 것이 목적이라면 정책의 대상자를 정하는 기준을 정책의 효과를 최대화할 것으로 여겨지는 집단으로 하는 것을 고려할 수 있을 것이다. 통계학적 방법론을 사용하여 정책의 효과를 최대화하는 집단을 식별하는 방법은 앞서 언급하였던 것처럼 크게 두 가지 방법론으로 구분할 수 있다. 먼저, 현재 계획 중인 정책과 유사한 과거 정책의 효과를 임의실험 혹은 준실험적인 방법론을 기반으로 정책효과의 이질성을 추정하는 것이다. 이를 통해서 정책의 혜택이 큰 집단을 식별하게 된다면 이러한 집단을 정책수급의 기준으로 설정하여 한정된 재화를 집중적으로 사용하는 것이 가능할 것이다. 특히 이질적 효과의 추정에 사용되는 기계학습 알고리즘의 비약적인 발전과 빅데이터의 축적은 연구자들이 정책효과의 이질성을 다양한 측면에서 살펴볼 수 있게 하여 사회경제학적인 구분(소득, 연령, 지역, 성별 등)에 의한 1차원적으로 수급자의 기준을 정하는 것이 아니라 보다 폭넓은 변수들을 고려한 기준 설정이 가능해질 것으로 보인다.

하지만 정부가 계획 중인 모든 정책에 과거의 비슷한 사례가 존재하지 않기 때문에 그리고 존재하더라도 정책의 효과를 추정할 수 있는 데이터가 존재하지 않을 수 있기 때문에 모든 정책의 설계에 앞서 말한 방법론을 활용하는 것은 현실적으로 어려움이 많다. 차선책으로 수급자의 기준 설계에 사용할 수 있는 방법은 사전적으로 정책의 효과가 클 것으로 예상되는 집단을 정의하고 이런 집단에 속할 확률을 통계학적인 모형을 이용하여 예측하는 것이다. 그리고 이러한 예측에 따라 정책의 효과가 클 것으로 예상되는 집단을 수급자의 기준으로 정하는 것이다.

예를 들어, 경제 불황이 지속되는 상황에서 정부의 정책목표가 일정금액을 국민에게 지급함으로써 불황에 빠진 내수경제의 활성화에 있다면 그리고 한정된 재원으로 인하여 특정 기준을 만족하는 국민들에게만 일정 금액을 제공해야 하는 상황에 있다면 정부는 이와 같은 방법론의 사용을 고려할 수 있다. 즉 사전적으로 정책의 효과(수급자의 소비지출 확대)가 클 것으로 예측되는 사람을 정의하고(유동성 제약에 빠져있는 사람) 개인이 이런 집단에 속하게 될 확률을 통계학적인 모형을 이용해서 예측하여 정책 수혜자의 수급기준으로 정하는 것이다.

이런 모형을 통해서 수급자의 기준을 정하기 위해서는 모형의 예측력이 무엇보다도 중요한데 이용 가능한 빅데이터의 증가와 기계학습 방법론의 결합은 전통적인 회귀분석 방법론을 이용한 추정보다 추정오차를 획기적으로 줄일 수 있어 기계학습 방법론을 이용한 수급자의 기준을 설계하려는 시도들이 향후 많은 나라에서 활발하게 이루어질 것으로 기대된다.¹⁴⁾ 다만 수급자의 기준 선정에 기계학습 방법론을 활용하는 논의는 수급대상자의 정책의 순응 정도를 고려하는 것은 아닌데 만약 정책 수혜효과가 클 것으로 예측된 집단의 정책 순응 정도가 평균적으로 저조하다면 예상하였던 정책의 효과를 기대할 수 없기 때문에 수급자 선정 시 집단별 정책의 순응 정도도 고려되

14) Sansone(2019)는 기계학습 방법론을 이용하여 고등학교에서 자퇴할 위험이 있는 학생들을 예측하였는데 실제 자퇴한 학생들 중에서 모형이 자퇴로 예측한 확률을 보여주는 recall rate의 경우 회귀분석식에 비해(6.4~15.5%) 기계학습 방법론을 사용할 경우 대략 50% 이상의 퍼포먼스의 증가를 보여주었다(16~28.1%).

어야 할 것이다.

나. 수급률 증대를 위한 논의

우리나라의 많은 복지재정정책들은 정부가 복지정책의 수급자 자격요건을 제시하고 복지 대상자들이 정책당국에 신청하는 ‘신청주의’에 기반하고 있다. 이러한 신청주의에 대해 학계와 전문가들이 지적하는 문제점은 신청주의가 수급의 자격이 있음에도 불구하고 현행 사회복지제도의 혜택을 받지 못하는 복지 사각지대를 발생시킨다는 점이다. 과거 송파구의 세 모녀 자살, 성북구의 네 모녀 자살 그리고 양주시의 세 부자 자살사건의 경우에 이러한 복지 사각지대의 문제점을 여실히 보여주는데 전문가들은 복지 수급의 자격이 있음에도 불구하고 이러한 사각지대가 발생하는 이유로 수급자 기준 선정의 복잡성과 신청절차의 복잡성 등을 들고 있다. 즉 수급자들이 사회복지 제도에 대한 지식 부족으로 본인이 수급 자격이 있다는 것을 인지하지 못하는 경우도 있으며 혹은 자격기준에 대해서는 인지하고 있지만 신청주의에 내포된 절차의 복잡성이 복지제도에 대한 신청을 저해한다는 것이다.

이러한 자격기준의 복잡성은 국민기초생활보장제도의 수급신청 가구를 조사한 한국보건사회연구원의 『2019년 한국복지패널 기초분석 보고서』(여유진 외, 2019)에 잘 드러나 있다. 해당 보고서에 따르면 2018년 국민기초생활보장제도의 수급을 신청한 가구들 중에서 국민생계·의료·주거·교육급여를 모두 수급하는 가구는 7.39%에 불과하였으며, 67.68%에 해당하는 대다수의 가구는 4개의 급여 중에서 일부만 수급하는 것으로, 그리고 24.92%에 해당하는 가구는 수급자로 선정되지 못한 것으로 나타났다. 해당 보고서는 수급자 선정에서 탈락한 이유에 대해서도 추가적인 조사를 하였는데 생계·의료·주거·교육급여의 경우 소득 및 재산이 기준금액보다 많은 경우를 이유로 뽑은 경우가 88.4%, 88.17%, 90.62%, 67.17%에 해당하였다. 이는 현행 제도에서 지원자들이 본인이 지원 대상자인지 파악하기 어려움을 보여주고 있다.

실제로 국민기초생활보장제도의 수급자 기준으로 사용되는 소득인정액의 계산은 소득평가액과 재산의 소득환산액만을 이용하여 간단해 보이지만 재산의 소득환산액의 경우 소유한 재산의 종류에 따라서 재산의 소득환산비율이 다르게 정해져 있어서 신청자가 재산의 소득환산액을 명확하게 파악하기가 어렵다. 추가적으로 신청자가 신청하는 급여의 종류에 따라 지원 대상자의 소득인정액이 몇 분위에 속하는지가 다르게 정해지는데 이러한 복잡성이 본인의 자격 여부를 파악하기 어렵게 만드는 것으로 보인다.¹⁵⁾

마지막으로 지원 절차의 복잡성 또한 현행 복지제도에서 문제점으로 자주 지적되고 있다. 사회보장 수급자가 복지제도를 신청하기 위해서는 정부24 포털이나 복지포털에 접속해야 하며 또한 해당 복지제도가 요구하는 수많은 구비서류를 작성해서 제출해야 하는데 이러한 절차적 복잡성 또한 복지제도의 수급률을 저하시키는 원인으로 보인다.

정부 정책의 수급률 저하에 대하여 행동경제학에 기반을 둔 많은 연구들은 수급률을 높이는 방안으로 정부가 제공하는 정보 혹은 신청 절차의 복잡성을 간소화하는 것을 제안한다(Glazerman et. al., 2020; Bettinger et. al., 2009). 예를 들어, 미국 연방정부에서는 저소득층에 학자금을 대출해주는 프로그램(Free Application for Federal Student Aid, FAFSA)을 운영하고 있는데 이러한 학자금 대출제도를 이용하는 저소득 가구의 비율은 높지 않은 것으로 나타난다. 이러한 현상의 원인으로 전문가들은 본인이 정책 대상의 요건을 만족시키는지 파악하기 어렵다는 점 그리고 학자금 대출 신청 시 많은 서류의 제공 및 신청 절차가 복잡하다는 점을 들고 있다. 이러한 문제점에서 착안하여 Bettinger et al.(2012)은 무작위 실험에서 FAFSA에 내재되어 있는 수급자 기준 및 신청 과정의 복잡성을 제거해 주기 위해 처치그룹에 수급자격 여부에 대한 정보를 제공하고 FAFSA를 신청하는 데 도움을 제공하였는데 처치집단의 경우 통제집단에 비해 FAFSA에 통계학적으로 유의미하게 많이 지원하는 것으로 나타났다. 다만 국내의 경우, 정책의 설계과정에서 정책 대상자에게 전달되는 정보의 복잡성이나 신청절차의 간소화가 정책 순

15) 주거급여의 경우 소득인정액 기준 중위소득 45% 이하이다.

응성에 미치는 영향에 대한 연구가 전무한데(권남호, 2018) 향후 정책 수급을 높이기 위해서는 이런 분야의 연구가 필요해 보인다.

신청주의의 한계점에서 기안한 정책 수급률의 저하를 극복하기 위한 노력은 여러 지자체에서 진행하고 있다. 서울시의 경우 2014년 적극적 발굴주의로의 전환을 선언하며 신청주의의 보완에 나섰으며 이를 위해 '위기가정 발굴·지원 특별대책본부'를 구성하며 복지전문 상담사 260명, 사회복지직 363명 및 보조인력 423명 등을 대폭 충원해 복지 사각지대를 조사하며 대상자를 발굴하고 있다.¹⁶⁾ 다만 이러한 적극적 사각지대의 발굴의 경우 현장에서 사회복지를 전담하는 공무원의 큰 규모의 추가고용이 전제되어야 하므로 재정에 큰 부담이 될 수 있다.

만약 이용 가능한 데이터를 기반으로 수급률이 낮은 집단을 사전적으로 정의하고 해당 집단을 대상으로 정부가 집중적으로 정책 신청을 장려하는 신청안내 공지문자 혹은 이메일을 보내는 조치를 취할 경우 한정된 재화를 효율적으로 사용하면서 정책의 순응성을 효과적으로 개선하는 것을 기대할 수 있다. 다만 정책의 순응자와 비순응자의 구분을 몇 개의 간단한 변수를 통해서 식별하는 것은 어려울 가능성이 높는데 정책 대상자에 대한 고차원적인 정보의 사용이 용이해진 만큼 기계학습 방법론을 사용한다면 정책순응자와 비순응자의 특성 파악이 가능할 것으로 보이며 신청을 저해하는 요소 등을 분석하는 것도 가능해 보인다. 다만 현재까지 정책 순응도를 높이기 위하여 기계학습 방법론을 사용하는 연구는 전무한데 이는 현재 이용 가능한 많은 패널데이터들의 경우 해당 조사자가 특정 재정정책의 자격 요건을 만족하는지 여부를 제공하고 있지 않기 때문으로 보인다. 이러한 현실적인 제약 속에 대상자의 수급요건의 만족 여부 그리고 실제로 수급을 하는지를 식별할 수 있는 경우는 근로장려세제(EITC) 정도가 있는데 「한국복지패널」 데이터를 바탕으로 살펴본 결과 자격요건 대비 신청률이 매우 높은 것으로 나타나 수급률을 높이기 위한 정책의 대상으로 적절하지 않은 것으로 보인

16) 서울특별시 보도자료, 「서울시, '신청주의'→'적극적 발굴주의' 어려운 이웃 찾아 나선다」, 2014. 3. 13.

다. 따라서 본 연구에서는 기계학습 방법론을 적용한 수급률을 높이기 위한 방안에 대해서는 추후 과제로 남겨 놓고 정책의 효과를 최대화하는 집단을 기계학습 방법론을 활용하여 선정하고 이를 기준으로 정책을 설계하는 방안에 대해 구체적인 예시를 바탕으로 논의할 예정이다.

2. 사례분석: 노인자살 예방정책


가. 노인자살 현황

[그림 V-1]은 한국을 포함한 OECD 주요 회원국의 인구 10만명당 자살로 인한 사망자의 수를 1998년부터 2017년까지 보여주고 있다. 한국의 경우 파란색 실선으로 표시되어 있는데 2000년에 10만명당 16.6명으로 최저치를 기록한 이후 지속적으로 증가하여 2009년에는 33.8명을 기록하였으며 이후 2011년까지 비슷한 추세를 보이다가 2011년 이후 지속적으로 감소하여 이용 가능한 가장 최근 연도인 2016년에는 24.6명을 기록하여 2002년 수준까지 하락하는 중이다. 이러한 하락에도 불구하고 OECD의 주요 회원국들과 비교하면 우리나라의 자살률은 상대적인 순위에서도 첫 번째 혹은 두 번째이며 절대적인 숫자도 리투아니아와 더불어 나머지 국가들과 비해 여전히 큰 격차를 발생하고 있어서 자살문제에 대한 정부의 정책의 중요성은 여전히 크다고 할 수 있다.¹⁷⁾

17) [그림 V-2]는 이용 가능한 최근 연도를 기준으로 모든 OECD 회원국의 자살률을 비교하고 있는데 우리나라의 10만명당 자살로 인한 사망자는 24.6명으로 1위를 차지하였으며 절대적인 수준에서도 3위인 라트비아가 18.1명인 것을 감안한다면 매우 높은 수준임을 알 수 있다.

[그림 V-1] OECD 주요 회원국 20년간 자살률 추이


(단위: 인구 십만명당 명)



자료: 중앙자살예방센터, 「국제자살통계」 자료를 바탕으로 재작성

[그림 V-2] 2017년도 OECD 회원국 자살현황

(단위: 인구 십만명당 명)




자료: 중앙자살예방센터, 「국제자살통계」 자료를 바탕으로 재작성

우리나라의 이러한 높은 자살률은 높은 노인 자살률에 기인하고 있다. 보건복지부에서 발간한 『2020 자살예방백서』에 따르면 2016년 기준 한국의 청소년(10~24세) 자살률은 8.2명으로 OECD 회원국 중에서 10위이며 한국의 평균 자살률인 24.6명의 33.33%에 그치고 있는 반면 2016년 기준 한국의 노인(65세 이상) 자살률은 53.3명으로 OECD 국가들 중에 압도적으로 높은 수치를 기록하고 있으며 한국의 평균 자살률의 약 2.17배에 이르고 있다.

[그림 V-3]부터 [그림 V-5]에서는 높은 노인 자살률을 성별로 그리고 연령대별로 분리해서 살펴보기 위해 연령 및 성별 자살률의 추이를 1998년부터 2018년까지 보여주고 있다. 해당 그림들은 통계청의 사망원인통계를 활용하여 작성하였는데 OECD의 국가별 통계와는 다르게 2018년까지 데이터를 사용할 수 있어서 한국의 자살률의 최신 경향까지 파악할 수 있다는 장점이 있다.

[그림 V-3] 한국의 노인 자살률의 추이: 연령별 구분

(단위: 인구 십만명당 명)




자료: 통계청, 「사망원인통계」 자료를 이용하여 재작성

[그림 V-3]은 한국의 노인 자살률 추이를 보여주는데 노란색 선, 회색 선, 주황색 선, 파랑색 선은 각각 80세 이상, 75~79세, 70~74세, 65~69세의 노인 자살률을 1998년부터 2018년까지 보여주고 있다. 그림에서 보면 알 수 있듯이 연령이 높은 집단일수록 자살률은 연령이 낮은 집단에 비해 20년간 계속 높았으며 특히 80세 이상 노인의 자살률은 2001년부터 급속히 증가해 2003년 이후의 경우 10만명당 자살률이 100명을 상회하였으며 이러한 추세는 2012년까지 지속되었음을 알 수 있다. 이러한 높은 자살률이 성별에 따라 다르게 나타나는지 파악하기 위해 [그림 V-4]는 남성 노인만을 대상으로, [그림 V-5]는 여성 노인만을 대상으로 연령별 자살률의 추이를 살펴보았다. 결국 한국 노인의 높은 자살률의 가장 큰 원인은 한국 남성의 높은 자살률임을 알 수 있는데, 구체적으로 한국 남성의 경우 여성에 비해 모든 연령집단에서 그리고 모든 연도에서 자살률이 압도적으로 높았으며 연령을 통제하고 남성과 여성을 비교하였을 경우 65세 이상 모든 연령대에서 최소 2배 이상의 차이가 발생하고 있다.

[그림 V-4] 한국의 남성노인 자살률의 추이: 연령별 구분


(단위: 인구 십만명당 명)



자료: 통계청, 「사망원인통계」 자료를 이용하여 재작성

[그림 V-5] 한국의 여성노인 자살률의 추이: 연령별 구분

(단위: 인구 십만명당 명)



자료: 통계청, 「사망원인통계」 자료를 이용하여 재작성

나. 대한민국의 자살 예방 정책 현황

한국 정부는 높은 수준의 자살률 문제에 적극적으로 대응하기 위해 2004년부터 자살예방대책 기본계획을 수립하였고 2011년에는 「자살예방 및 생명존중문화 조성을 위한 법률」을 제언하였다. 자살률의 지속적인 하락에도 불구하고 자살문제는 여전히 중요한 문제로 대두되고 있었고 문재인 정부는 2018년에는 ‘자살예방 및 생명존중문화 확산’을 국정과제로 제언했으며 이에 따른 『자살예방 국가 행동 계획』(2018~2022년)을 수립하여 자살예방정책에 대한 청사진을 제시하였다.

『자살예방 국가 행동 계획』을 좀 더 구체적으로 살펴보면 과학적 근거에 기반하여 자살예방에 대한 전략적 접근을 추진하며 자살 고위험군 발굴을 위한 전 사회적 네트워크를 구축하고, 적극적 개입·관리를 통한 자살위험을 제거하며, 사후관리 강화를 통한 자살확산을 예방하며, 그리고 마지막으로 대상별 자살예방을 추진하는 것을 목표로 하고 있다(보건복지부 정신건강

강정책과 보도자료, 2018.1.23., 「자살예방 국가 행동계획」).¹⁸⁾ 이에 따라 중앙정부와 지자체는 다양한 자살예방사업을 운영 중에 있는데 본 연구에서는 자살예방정책과 관련한 중앙정부의 정책방향을 살펴보기 위해 국회에 제출한 예산안을 먼저 검토하였다.

〈표 V-1〉 2020년 자살예방 및 지역정신보건사업 예산안 1

(단위: 백만원, %)

세부사업명	2018년 결산	2019년 계획		2020년		증감	
		당초	수정(A)	정부안	확정(B)	(B-A)	(B-A)/A
자살예방 및 지역정신보건사업	61,072	72,900	72,900	97,436	97,646	24,746	33.9

자료: 재정정보공개시스템, 「열린재정: 재정통계 > 상세재정통계DB > 예산 > 세출/지출 세부사업 예산편성현황 (총액)」의 내용을 바탕으로 저자 작성. <http://www.openfiscaldat.go.kr/portal/main.do> (접속일자: 2020. 6. 16.)

검토 결과, 보건복지부 국민건강증진기금의 세부사업인 자살예방 및 지역정신보건사업(단위사업명: 정신건강증진사업)에 자살예방을 위한 정부정책들이 포함되어 있으며 해당 세부사업과 관련한 예산안의 구체적인 내용은 〈표 V-1〉에 작성하였다. 해당 사업에 배정된 예산안은 2020년에 976억 4,600만원으로 2019년 729억원에 비해 약 33.9%가 증가하였는데 해당 예산안은 자살예방뿐만 아니라 지역정신보건사업을 포괄하고 있어서 자살예방에 어느 정도의 예산이 사용되었는지 파악하기 어렵다는 한계점이 존재한다. 따라서 〈표 V-2〉에서는 해당 세부사업을 내역사업별로 나누어서 작성하였는데 국회의안정부시스템의 「2020년 예산안 및 기금운용계획안」을 참조하였다. 〈표 V-2〉를 보면 알 수 있듯이 2020년 계획안을 기준으로 자살 예방 및 지역정신보건사업에서 자살 예방과 연관된 내역사업들이 차지하는 비중은 29.67%에 불과한데 이는 세부사업을 가지고 자살예방정책의 정부 지출의 추세를 파악하기가 어려움을 보여주고 있다.

18) 해당 보도자료에 대한 전문은 아래의 링크를 통해서 확인할 수 있다.
http://www.mohw.go.kr/react/al/sal0301vw.jsp?PAR_MENU_ID=04&MENU_ID=0403&page=44&CONT_SEQ=343649, 접속일자: 2020. 12. 10.

〈표 V-2〉 2020년 자살예방 및 지역정신보건사업 예산안 2

(단위: 백만원, %)

사업명	2019계획		2020 계획안(B)	증감	
	당초	수정(A)		B-A	비중
계	72,900	72,900	97,436	24,536	33.7
지역정신보건사업	49,543	49,543	68,531	18,988	38.3
광역정신건강복지센터 운영	5,849	5,849	5,996	147	2.5
기초정신건강복지센터 운영	17,405	17,405	18,336	931	5.3
정신건강복지센터 인력확충	13,825	13,825	19,287	5,462	39.5
응급개입팀 운영	—	—	2,005	2,005	순증
아동청소년정신건강증진사업	4,309	4,309	4,392	83	1.9
통합정신건강증진사업	4,649	4,649	15,009	10,360	222.8
노숙자 등 중독자 사례관리	300	300	300	—	—
안산정신건강 트라우마센터	2,000	2,000	2,000	—	—
정신건강사례관리시스템 운영	664	664	664	—	—
중앙정신건강복지사업지원단	320	320	320	—	—
정신건강정책연구개발	200	200	200	—	—
운영비(직접수행)	22	22	22	—	—
자살예방 및 생명존중문화조성	23,357	23,357	28,905		
생명존중문화조성	2,837	2,837	2,837	—	—
자살예방교육 및 인력양성	2,093	2,093	2,093	—	—
자살유해정보모니터링	100	100	100	—	—
자살 고위험군 집중관리(응급실)	6,326	6,326	9,481	3,155	49.9
기초정신건강복지센터 자살예방사업 지원	—	—	1,811	1,811	순증
중앙자살예방센터운영	411	411	411	—	—
심리부검체계구축	3,982	3,982	3,982	—	—
민관협력자살예방사업	700	700	700	—	—
자살 유족 지원사업	600	600	1,145	314	60.4
지역자살예방 및 정신건강 증진사업	4,174	4,174	4,174	—	—
지역사회기반 자살예방사업	100	100	100	—	—
자살예방실무자 등 정신건강증진	512	512	512	—	—
자살예방 상담전화 운영체계 개선	1,300	1,300	1,337	37	2.8
자살예방정책 연구개발	200	200	200	—	—

자료: 국회의안정보시스템, 「2020년도 예산안」, 「2020년도 기금운용계획안」

자살예방 사업들만을 한정하여 정부 지출 추세를 파악하기 위해 <표 V-3>은 세부사업인 자살예방 및 지역정신보건사업에서 자살과 관련된 내역사업만을 분리하여 2016년부터 2020년까지의 예산안의 변화를 보여주고 있다. 2020년 자살과 관련한 내역사업들은 총 289억 500만원으로 2016년 59억 2,600만원과 비교하여 약 4.88배 증가하였음을 알 수 있다. 이러한 증가는 자살 고위험군 집중관리, 심리부검체계 구축과 같은 기존 내역사업의 예산 증가와 지역자살예방 및 정신건강 증진사업 그리고 기초정신건강복지센터 자살예방사업 지원과 같은 신규 내역사업의 출연에서 기인한 것으로 보인다.

〈표 V-3〉 2016~2020년 보건복지부 자살예방사업 관련 예산

(단위: 백만원)

사업명	2016	2017	2018	2019	2020
자살예방 및 생명존중문화조성	5,926	7,331	13,654	23,357	28,905
생명존중문화조성	1,280	1,280	1,280	2,837	2,837
자살예방교육 및 인력양성	300	300	1,475	2,093	2,093
자살유해정보모니터링	100	100	100	100	100
자살 고위험군 집중관리(응급실)	2,000	3,292	4,700	6,326	9,481
기초정신건강복지센터 자살예방사업 지원	—	—	—	—	1,811
중앙자살예방센터 운영	386	399	400	411	411
심리부검체계 구축	960	960	3,840	3,982	3,982
민관협력자살예방사업	700	700	700	700	700
자살 유족 지원사업				600	1,145
지역자살예방 및 정신건강 증진사업	—	—	—	4,174	4,174
지역사회기반 자살예방사업	—	100	100	100	100
자살예방실무자 등 정신건강증진				512	512
자살예방 상담전화 운영체계 개선			650	1,300	1,337
자살실태조사	—	—	200	—	—
자살예방정책 연구개발	200	200	200	200	200

자료: 보건복지부 예산 및 기금운용계획 개요를 연도별로 추출하여 재작성

자살예방과 관련한 내역사업 중 노인의 자살예방을 위해 사용된 정책을 분리하기 위해서는 코호트별로 분류하는 작업이 필수적인데 다수의 내역사

업의 정책 대상이 코호트별로 특정하고 있는 것이 아니기 때문에 내역사업의 명칭을 바탕으로 노인자살예방 사업만을 특정하는 것은 현실적으로 불가능하다. 따라서 본 연구에서는 차선택으로 어떤 내역사업이 노인들을 정책 대상에 포함하고 있는지 파악하기 위해 보건복지부의 「2020년 세입세출 사업별 설명자료(예산, 기금)」 내용을 살펴보았으며 내역사업별 정책 내용 및 목표를 <표 V-4>에 정리하였다. <표 V-4>의 내역사업들 중에 노인들의 자살예방 방지를 위한 정책을 포함하고 있는 내역사업은 민관협력자살예방사업과 지역자살예방 및 정신건강 증진사업 등임을 파악할 수 있었다. 구체적으로, 민관협력 자살예방사업에서 빈곤계층 밀집지역 노인자살예방사업을 운용하고 있으며 지역자살예방 및 정신건강 증진사업의 경우에도 자살 고위험군(독거노인포함)의 사례관리를 통한 자살 재시도를 선제적으로 방지하기 위한 정책을 운용하고 있다. 하지만, 노인을 위한 자살예방정책의 경우 사업의 규모가 크지 않는데 빈곤계층 밀집지역 노인자살예방사업의 경우 2019년은 5월 말 기준으로 5~6개 기관을 선정하여 기관당 최대 5천만원을 지원하였으며 2017년과 2018년의 경우도 각각 2억원과 3억원의 규모로 사업이 수행되었다(『노인건강분야 사업 분석』, 국회예산정책처, 2019)¹⁹⁾

앞서 언급하였던 것처럼 『자살예방 국가 행동 계획』은 자살예방을 위해 중앙정부 및 지자체 수준에서의 자살예방정책의 필요성을 제시하였으며 이러한 계획에 따라 지자체에서도 다양한 자살예방프로그램을 운용하고 있다. 따라서 우리나라의 자살예방정책의 현황을 종합적으로 살펴보기 위해서는

19) 2017년과 2018년 빈곤계층 밀집지역 노인자살예방 분야 사업의 추진실적은 다음과 같다.

[빈곤계층 밀집지역 노인자살예방 분야 사업 추진 실적]

연도	사업 수행 기간	지원액	사업 수행 대상 지역
2017	9~12월	1억원	2개 시군구(서울 강북구 · 성북구)
	9~12월	1억원	2개 시군구(서울 동대문구 · 중랑구)
2018	7~12월	1억 7천만원	2개 시군구(서울 강북구 · 성북구)
	7~12월	1억 3천만원	7개 시군구(인천 중구 · 동구, 안산시 상록구 · 단원구, 전남 목포 · 순천 · 나주)

자료: 국회예산정책처(2019), p.141의 내용을 바탕으로 재작성

지자체 수준에서 운영하는 자살예방프로그램의 현황을 파악하는 것이 필요하다. 다만 모든 본 연구에서 광역지자체의 자살예방정책을 살펴보는 것은 연구의 범위를 벗어나기 때문에 서울시의 경우로 한정하여 자살예방정책을 살펴보기로 한다.

〈표 V-4〉 자살예방 관련 내역사업의 정책 내용 및 목표

내역사업 및 소요예산 (백만원)	정책 내용 및 목표
생명존중문화조성(2,837)	국가 전략 및 정책 목표에 따라 자살예방활동기관 및 사회 각 분야의 전문가 그룹 등과 자살예방 네트워크를 구축을 목표로 하며 생명존중문화와 관련한 국가 전략 및 정책 목표에 따라 실증적이고 효율적인 자살예방활동을 펼침으로써, 궁극적으로 자살률 감소를 통한 '자살위험 없는 안전한 공동체 구현'의 초석을 마련하기 위한 구심적 역할을 수행
자살예방교육 및 인력양성(2,903)	자살에 대한 국민인식 개선을 위한 다양한 콘텐츠의 자살예방 교육 프로그램을 개발·보급하여 자살예방 및 생명존중문화를 조성
자살유해정보모니터링(100)	언론 및 인터넷상 자살유해정보 관리 강화 및 미디어의 건전한 환경 조성을 통해 자살을 예방하고 생명존중문화를 확산
자살 고위험군 집중관리(9,481)	응급실에 내원한 자살 시도자의 정서적 안정을 촉진하고, 필요한 치료, 서비스를 연계하여 자살 재시도 및 자살을 예방
중앙자살예방센터운영(411)	중앙자살예방센터 운영을 통해 우리나라 실정에 맞는 자살예방정책 계획 수립과 수행을 위한 기반을 구축함으로써 궁극적으로 자살률 감소
심리부검체계구축(3,982)	1. 자살 유가족의 진술과 기록 검토를 통해 자살 사망자의 심리행동 양상 및 변화 상태를 확인하고 자살의 구체적인 원인을 검증 2. 지역별(읍면동 단위) 자살 사망자 특성(원인, 수단, 장소 등)을 파악하기 위해 경찰청 변사자 자료 전수 조사(5년간 7만명)
민관협력자살예방사업(700)	자살예방사업에서의 민간부문의 자살예방 사업 참여 독려, 민관협력 강화를 위해 지원 확대가 필요함. 구체적으로 자살유가족 상담 및 자조모임 지원, 자살예방을 위한 인식 개선(캠페인 등), 자살유발정보 차단 및 자살보호 권고기준 확산 등 자살예방을 위한 민간부문의 다양한 사업을 지원함
자살 유족 지원사업(1,145)	자살 유족에 대한 상담서비스, 법률지원, 학자금 지원, 임시주거 지원 등을 원스톱으로 지원하는 시범사업을 추진함

〈표 V-4〉의 계속

내역사업 및 소요예산 (백만원)	정책 내용 및 목표
지역자살예방 및 정신건강 증진사업(4,174)	<p>자살에 대한 국가적 차원의 예방정책이 자살 위험에 노출된 개인이 처한 특수한 환경에 맞게 시행될 수 있도록 정신건강 복지센터에 자살예방 전담팀 설치.</p> <p>－ 해당 전담팀은 「자살예방법」 제13조에 따라 다음 기능 수행: 자살 관련 상담, 자살위기 상시현장출동 및 대응, 자살시도자 사후관리, 자살예방 홍보 및 교육, 자살예방 전문 인력 양성 등</p> <p>－ 특히, 자살 고위험군(자살시도자 및 자살자 유가족, 독거노인, 청소년 등) 사례관리를 통해 자살 재시도를 선제적으로 방지</p>
지역사회기반 자살예방사업(100)	<p>지자체가 지역의 특성과 자원을 고려하여 주도적인 자살예방 정책을 추진하는 성공모델 개발</p> <p>－ 지자체별 자살 특성 및 인프라를 고려한 지역 맞춤형 자살 예방사업 추진, 자살예방 실무자 전문 교육 실시, 사업 추진 성과 평가</p> <p>－ 지역 맞춤형 자살 예방사업 컨설팅, 통계교육, 홍보 콘텐츠 공유 및 경찰 수사기록을 통한 지자체 자살자 특징 조사 및 분석</p>
자살예방실무자 등 정신건강증진(512)	<p>자살예방사업 담당 공무원 등의 스트레스성 질환 등의 해소로 소진 방지 및 업무 능률성 향상을 위해 상담·사례관리 등의 정신건강 서비스의 제공이 목적</p> <p>－ 정신건강복지센터를 통해 자살예방 실무자 및 관련 종사자의 스트레스, 기분장애, 불안장애 등 해소 여부, 스크리닝 및 상담, 치료 연계 사업을 실시함</p>
자살예방 상담전화 운영체계 개선(1,337)	<p>효과적인 자살예방사업과 자살예방 상담전화의 인지도 강화 및 안정적 운영을 위해 정부 주도의 자살예방상담 전화(1393) 운영이 필요함</p> <p>－ 특수번호 사용을 통한 상담전화번호 인지도 향상으로 자살 예방 및 상담서비스 접근성 향상 추진</p>

주: () 안 소요예산은 2020년 예산 계획안 기준

자료: 보건복지부(2020a), pp.1560~1566의 내용을 바탕으로 재작성

〈표 V-5〉는 2016~2020년까지 서울시의 자살예방사업과 관련한 예산을 보여주는데 관련 예산은 2016년 54억 4,800만원에서 2020년 61억 5,900만원으로 증가하였다. 61억 5,900만원 중 30억원은 25개 구의 자살예방사업의 지원 금액으로 사용되었으며 나머지 31억 5,900만원은 서울시 자살예방센터

〈표 V-5〉 2016~2020년 서울시 자살예방사업 관련 예산

(단위: 백만원)

내용	세부내용	2016	2017	2018	2019	2020
자살예방 관련 예산		5,448	5,422	4,876	5,567	6,159
25개구 자살예방사업 지원		2,500	2,500	2,500	3,000	3,000
서울시 자살예방센터 운영		2,948	2,922	2,376	2,567	3,159
민간경상사업보조		1,003	1,253	603	403	950
	힐링프로젝트 (누구에게나 엄마가 필요하다)	200	200	200	200	297
	생명사랑 자살예방 캠페인	—	100	200	—	—
	생명문화버스	203	203	203	203	203
	힐링센터(마음치유센터) 운영	500	—	—	—	—
	스타칼리지 살자학교	100	—	—	—	—
	서울심리지원센터 운영	—	750	—	—	—
	자살예방연극	—	—	—	—	200
	생명존중 콘서트	—	—	—	—	100
	정신건강힐링프로그램개발	—	—	—	—	150
사무관리비	자살예방센터 임대료	—	23	23	—	—
민간위탁금	자살예방센터운영	1,595	1,646	1,750	1,964	2,209
	인건비	—	—	—	1,404	1,637
	운영비(임차료 등)	—	—	—	196	196
	사업비	—	—	—	364	376
민간대행사업비		350	—	—	—	—
	콜센터 구축 솔루션 프로그램	110	—	—	—	—
	콜센터 구축 관련 시설공사 등	150	—	—	—	—
	전용장비 구매(녹취, 전광판 등)	90	—	—	—	—

자료: 서울특별시, 「연도별 예산서」를 바탕으로 저자 작성

http://news.seoul.go.kr/gov/archives/category/govdata_c1/budget_c1/data_budget_c1/data_document_budget-n2, (접속일자: 2020. 6. 23.)

운영에 사용되었다. 「2019년 서울시 자살예방시행계획」 추진실적 결과보고서를 살펴보면 25개 구의 자살예방사업에 지원되는 30억원은 노인 자살예방사업에 사용되고 있음을 알 수 있는데 사업의 주요 내용을 정책목표에 따라 구분하면 다음과 같다. 먼저 첫 번째로, 노인 생명존중 인식개선 활성화를 목표로 노인 생명존중 및 정신건강 인식개선을 위한 시민 참여형 캠페인을 수행한다. 두 번째로, 노인 자살예방 인프라 및 네트워크 구축을 목표로 생명지킴이활동을 대상으로 교육을 실시하고 있으며 마지막으로, 노인 자살 고위험군 서비스 연계활동 지원을 목적으로 독거노인 생활관리사 및 방문간호사를 통해 자살 고위험군을 발굴하고 보건복지 통합자원을 연계하는 활동을 실시하고 있다.

지금까지 중앙정부와 지방정부의 자살예방정책을 살펴보았는데 종합하면 중앙·광역·기초자살예방센터는 자살예방 생명지킴이를 양성하고 자살예방 홍보 등의 다양한 사업을 추진하고 있지만 노인 특화사업을 개발하여 운영하고 있지 않음을 알 수 있었다. 또한 기존의 노인자살예방을 위한 정책의 경우에는 중앙·지방정부 모두 사업의 규모가 매우 작아서 노인자살예방을 위한 정책의 자원이 한정되어 있음을 알 수 있었다.

노인자살예방을 위한 기존의 사업의 경우 자살 고위험군을 식별하고 관리하는 정책들이 대다수를 이루고 있는데 노인자살예방정책에 투여되는 한정된 재화를 고려한다면 기계학습의 활용으로 정책의 효과성과 효율성을 개선할 수 있을 것으로 기대된다. 왜냐하면 지자체의 고위험군 관리의 경우 노인돌봄이 활동가들이 노인들을 직접 방문하여 설문조사를 통해 식별하는 과정을 거치고 있는데 이렇게 적극적으로 고위험군을 식별하기 위해서는 대규모의 노인돌봄이 활동가들의 추가 고용이 전제되어야 하기 때문이다.²⁰⁾

20) 고위험군 노인들의 식별을 위해 지자체들이 어떠한 절차를 진행하는지 파악하기 위한 정책 담당자들의 조사 및 관련 자료를 추가적으로 살펴보았다. 지자체 정신건강증진센터 보고서에 따르면 노인 돌봄이 및 맞춤형 방문간호사를 통해 노인들에게 선별검사를 실시하고 고위험군으로 파악된 경우 정신의료기관 연계서비스를 제공하는 것으로 나타났다. 이는 연구진들이 일선에서 해당 업무를 담당하는 전문가들과의 통화를 통해서도 확인할 수 있었다. 예를 들어, 강원도의 경우, 광역정신건강복지센터(강원도자살예방센터)가 중심이 되어서 각 시군구 보건소와 협업하여 지자체 노인돌봄이 활동가분들에게 일정시간 설문조사에 대한 교육 후 일대일로 방문하여 마음건강검진을 실시하여 자살

만약에 설문조사 등의 정성적인 평가가 아닌 노인들의 진료행태 및 복지수급과 관련한 행정 데이터 등과 기계학습 알고리즘을 통해 사전적으로 고위험군에 해당하는 사람을 예측하고 예측된 사람에게 노인돌봄이 활동가들이 방문하여 조사한다면 혹은 기계학습 알고리즘을 통해 고위험군으로 예측된 사람들에 한정하여 자살예방정책을 실시하여 정책에 소요되는 비용을 줄일 수 있기 때문에 효율성 측면에서의 개선을 기대할 수 있게 된다.

효과성 측면에서도 만약 기존의 방법론보다 기계학습 방법론이 고위험군의 노인들을 높은 확률로 식별한다면 이러한 고위험군에 대한 선제적 대응정책의 효과성은 증가할 것으로 보인다. 마지막으로 기계학습 알고리즘을 활용하여 모형을 구축하였을 때 정부가 손쉽게 획득할 수 있는 변수가 아닌 다른 변수들이 고위험군을 예측하는 데 중요한 것으로 나타날 수 있다. 이런 경우 만약 정부가 해당 변수에 관해서 수집하는 노력을 기울인다면 고위험군 노인의 식별을 높은 확률로 달성할 수 있기 때문에 마찬가지로 정책의 효과성·효율성을 증대시킬 수 있다. 따라서 다음 장에서는 기계학습 방법론을 사용하여 자살 고위험군을 예측하는 모형을 구축하고 어떤 변수들이 노인 자살을 예측하는 데 중요한지 살펴보도록 한다.

다. 데이터

(1) 활용 가능한 데이터의 검토

자살 고위험군의 정의는 응답자가 자살생각을 한 적이 있는지 여부에 따라서 자살생각은 한 적이 있다고 대답한 응답자는 고위험군, 그렇지 않는 응답자는 고위험군이 아님으로 정의하고 자살 고위험군의 모형을 통한 예측은 해당 데이터의 다양한 변수들을 통해서 응답자가 고위험군에 속하는지 여부를 예측하는 것이다. 따라서 자살 고위험군 예측을 위해 이용 가능한 데이터는 응답자가 자살 고위험군인지 여부를 포함하고 있어야 하는데 이런 기준에 만족하는 데이터로는 패널데이터의 경우에는 한국복지패널, 여성가

고위험군을 파악하고 있다.

족패널조사가 있으며 횡단면데이터로는 국민건강영양조사, 사회조사, 노인실태조사 등이 있다.

이러한 데이터들에서 자살생각을 한 번이라도 한 적이 있는 자살 고위험군의 비율은 매우 낮는데 데이터별로 각각 1.63%(「한국복지패널」, 2019), 2.4%(「여성가족패널조사」, 2018), 5.0%(「국민건강영양조사」, 2018)²¹⁾, 4.9%(「사회조사」, 2018), 6.25%(「노인실태조사」, 2017)로 조사되었다. 결론적으로 노인자살을 예측하기 위해서는 충분히 많은 수의 노인표본 확보가 필수적임을 의미한다. 왜냐하면 자살생각이라는 이벤트는 적은 확률로 일어나기 때문에 충분하지 못한 표본을 가지고 알고리즘을 추정하는 경우 고위험군에 해당하는 관측치가 알고리즘 fitting에 사용되는 훈련데이터에 포함될 가능성이 매우 낮게 되고 이럴 경우 알고리즘은 훈련데이터를 overfitting 하게 되어서 과분산(high variance) 문제가 발생하게 되며 순차적으로 새로운 데이터에 대한 예측력이 현저히 떨어지게 된다. 앞서 검토하였던 데이터들 중에서 충분히 많은 수의 노인을 포함하고 있는 데이터로는 「노인실태조사」뿐인데 따라서 본 연구에서는 「노인실태조사」를 활용하여 알고리즘을 구축할 예정이다.

(2) 노인실태조사

「노인실태조사」²²⁾는 한국 노인들의 다각적인 생활 현황과 욕구를 파악하며 노인 특성의 변화 추세를 예측하기 위해 한국보건사회연구원이 2008년부터 3년 주기로 실시하고 있는 조사인데 이용 가능한 가장 최근의 자료는 2017년 조사이다. 조사 대상은 2017년 기준 65세 이상 10,299명(대리응답 266명을 포함)이며 조사내용으로는 대영역 기준 ① 가구 일반사항, ② 건강 상태, 건강행태, ③ 기능 상태와 간병 수발, ④ 여가 활동과 사회 활동 및 경제 활동, ⑤ (손)자녀·배우자와의 관계 및 가구 형태, ⑥ 형제·자매/친

21) 5.0%의 수치는 표본에서 청소년은 제외한 수치이다.

22) 데이터에 대한 결과보고서는 아래의 링크를 통해 확인할 수 있다. 보건복지부, 『2017년도 노인실태조사 결과보고서』, 2018, http://www.mohw.go.kr/react/jb/sjb030301vw.jsp?PAR_MENU_ID=03&MENU_ID=032901&page=1&CONT_SEQ=344953, 접속일자: 2020. 6. 3.

인척/친구/이웃/지인과의 관계, ⑦ 자녀·부모와의 부양의 교환, ⑧ 생활환경, ⑨ 노후 생활과 삶의 질, ⑩ 정책적 이슈에 대한 노인의 인식, ⑪ 인지 기능, 마지막으로 ⑫ 경제상태 등 총 863개의 변수를 포함하고 있다.

머신러닝을 활용한 추정의 경우 많은 변수들을 활용하는 결과를 예측하는 만큼 충분한 수의 관측치를 확보하는 것이 무엇보다 중요하다.²³⁾ 이러한 측면에서 본다면 활용 가능한 관측치를 최대한 확보하는 게 중요한데 이를 위해 본 연구에서는 「2017년 노인실태조사」뿐만 아니라 「2014년 노인실태조사」의 데이터를 추가적으로 병합하여 알고리즘의 훈련에 활용하였다. 이러한 병합 시 발생하는 현실적인 문제점은 각 조사마다 해당 시점에서 연구자가 필요한 문항을 조사하였기 때문에 두 조사에서의 공통된 변수가 「2017년 노인실태조사」의 변수만을 사용한 경우와 비교해서 많은 수의 변수들을 활용하지 못한다는 점이다.

실제로 「2014년 노인실태조사」의 경우 718개의 변수를 포함하고 있는데 이중 2014년에만 포함하고 있는 변수가 105개이며 2014년 및 2017년에 공통으로 포함하는 변수는 241개 그리고 두 조사에서 공통으로 포함하고 있으나 변수명이 다른 경우는 364개였다. 변수명이 다른 경우 2017년 변수명을 기준으로 통합하였고 변수의 값이 다른 경우도 2017년을 기준으로 수치를 조종하였는데 이러한 공통으로 포함된 변수들의 변수명을 변화하는 과정을 거치면 최종적으로 608개의 변수와 20,750개의 데이터를 구축할 수 있게 된다. 「2017년 노인실태조사」만 사용하였을 경우 이용 가능한 변수 숫자인 863개와 비교한다면 255개의 변수를 활용하지 못하지만 변수를 활용하지 못하는 데서 잃게 되는 실익보다 많은 관측치를 사용함으로써 얻게 되는 이득이 크다고 판단하여 본 연구에서는 2014년과 2017년을 통합하여 구축한 데

23) 일반적인 회귀분석 선형모형의 경우에도 모형의 형태(Specification)를 정확하게 식별한 경우 관측치의 수가 증가할수록 모형의 추정계수는 참값에 근접하게 된다. 하지만 이는 모형의 형태가 정확하다는 가정에서만 참인 명제이며 모형 명세화 오류(Model Misspecification)가 있는 경우 선형모형을 사용한 예측은 관측치가 증가할수록 예측력이 높아짐을 의미하지 않음을 주의해야 한다. 예를 들어, 종속변수와 설명변수의 관계가 다차원 함수로 이루어진 경우 1차 함수만 포함한 선형모형의 경우 관측치의 수가 아무리 증가하여도 모형을 정확하게 예측할 수 없지만 머신러닝의 경우 예측의 성과를 높이기 위한 모형의 형태도 같이 고려해주기 때문에 선형모형과의 차이가 존재한다.

이터를 활용하였다.²⁴⁾

20,750명의 관측치 중 자살 고위험군임을 파악할 수 있는 질문에 대해 결측치를 표본에서 제외하면 총 20,364개의 관측치를 포함하고 있는데 이들 노인 중 8.01%는 자살을 생각해본 적이 있는 자살 고위험군으로 나타났다. 자살과 관련해서 보다 자세한 정보를 포함하고 있는 2017년 데이터를 살펴보면 자살 고위험군에 해당하는 노인 중 실제로 12.22%는 자살을 시도한 것으로 나타났으며 자살을 생각한 응답자 중 자살을 생각한 이유로는 경제적 어려움과 건강문제가 동일하게 높았으며(각각 27.94%) 그 외는 외로움, 배우자, 가족, 지인의 사망 및 갈등 등 인간관계와 관련 있는 이유들이 뒤를 이었다.

기계학습 알고리즘을 사용하여 모형을 예측할 경우 가장 먼저 실시해야 하는 작업 중에 하나는 예측변수(Predictor)로 사용될 변수에 결측치가 존재하는 경우 결측치를 다른 값으로 대체(Imputation)하는 과정이다. 이를 위해서 표본의 불필요한 변수들을 먼저 정리하였는데 총 608개의 변수 중 가구 가중치_모수추정, 가구가중치_샘플추정 등의 자살 고위험군 예측과 무관한 가중치 변수 네 개를 표본에서 제거하였다(608→604개).²⁵⁾ 「노인실태조사」의 3인 이하 가구원을 가진 가구가 91.20%를 차지하고 있어서 가구원 4인 이상의 정보에는 결측치가 많이 포함되어 있다. 따라서 가구원 4인부터 가구원 10인까지의 정보를 표본에서 제외하였다(604→522개). 그리고 예측의 대상이 되는 변수(K11)와 자살 고위험군에 해당하는 대상자에 한정하여 실시한 4가지 추가 질문 역시 예측변수에서 제외하였으며(522→519개), 마지막으로 2017년 기준 결측치(비해당 및 무응답 모드 포함)가 9,500개 이상인 변수들과 값이 1개만 가지는 변수들을 표본에서 제외하였다(519→470개). 변수 특성별 변수의 개수는 <표 V-6>에 제시하였는데 더미 및 범주형 변수가 382개이며 연속형 변수의 경우 88개로 나타났다.

최종적으로 예측에 활용할 변수는 470개인데 본 연구에서는 해당 변수가

24) <표 V-14>는 훈련데이터의 증가에 따른 각 알고리즘의 성과를 보여주고 있는데 훈련데이터의 크기가 증가함에 따라 알고리즘의 성과가 향상되는 것을 알 수 있다.

25) 예측과 무관한 변수명은 다음과 같다: wg_h ws_h wg_ind ws_ind id

더미/범주형 변수(Categorical Variable) 혹은 연속형 변수(Continuous Variable) 이냐에 따라 결측값을 대체(Imputation)하는 방식을 분리하여 진행하였다. 결측값 대체와 관련해서 한 가지 주의할 점은 2014년 「노인실태조사」의 경우 무응답(비해당)과 결측치의 구분이 가능하지만 2017년 조사의 경우 무응답(비해당)과 결측치의 구분이 불가능하다는 점이다. 두 조사에서 통일되게 결측의 사유를 구분하지 않고 결측값을 대체하는 것도 가능하지만 본 연구에서는 데이터가 가진 정보를 최대한 활용하기 위해 2014년 데이터의 경우 무응답과 결측치를 구분하여 무응답의 경우는 0의 값을 주었다. 그다음 결측치의 경우에는 2014년의 결측치와 2017년의 결측치(무응답+결측치)의 의미가 다르기 때문에 변수의 특성에 따라 다음과 같이 결측치를 대체하였다. 먼저 연속형 변수의 경우 결측치에 대해 0의 값으로 대체하였고 결측치임을 나타내는 결측더미(Missing Indicator)를 생성하였는데 2014년 결측치와 2017년 결측치를 구분하기 위해 동일한 변수에 대해서 결측치가 발생한 시점에 따라 두 개의 결측더미를 생성하였다(총 96개의 변수 추가생성).²⁶⁾ 그리고 범주형 변수의 경우에는 무응답과 구별하기 위해 2014년 결측치는 99994의 값을 2017년 결측치의 경우는 99997를 부여하였다.

〈표 V-6〉 변수 특성에 따른 변수 구분

(단위: 개)

변수 구분	변수 개수
더미변수	31
범주형 변수	351
연속형 변수	88
총합	470
결측치 관련 더미변수	96
우울증 관련 변수들	15

자료: 보건복지부, 「노인실태조사」 2014 및 2017 자료를 활용하여 저자 작성

26) 예를 들어, A라는 연속형 변수의 결측치가 존재하는 경우 해당 관측치가 2014년 결측치 혹은 2017년 결측치냐에 따라 결측치에 0의 값을 대체하고 2014년 결측치의 경우 miss_A_2014를 2017년 결측치의 경우 miss_A_2017로 생성하였다.

마지막으로 Lasso 알고리즘과 같은 일종의 Regularization 방법론을 이용 시 주의할 점은 모든 변수들의 크기를 동일하게 만들어서 변수의 크기에 따른 영향을 최소화해야 한다는 점이다. 이를 위해서는 모든 변수들의 크기를 동일하게 만들어주는 과정을 거쳐야 하는데 주로 사용하는 방법으로는 평균이 0, 분산이 1을 가지게 표준화하는 방법과, 변수의 최솟값을 0, 최댓값을 1의 범위로 변화시켜주는 방법이 있다. Guenther and Schonlau(2016)에 따르면 두 방법론 모두 Regularization 알고리즘에서 잘 작동하는 것으로 나타났다. 본 연구에서는 연속형 변수에 대해서 응답값을 0과 1의 범위로 변환하였다. 기계학습모형에 예측변수로 최종적으로 사용된 변수는 〈부표 V-1〉에서 확인할 수 있는데 연구자들이 「2014년 노인조사」와 「2017년 노인조사」를 결합한 데이터를 활용할 것을 감안하여 두 데이터의 공통된 변수명(2017년 기준), 변수의 대영역, 변수설명, 문항내용, 변수값을 같이 수록하였다.

라. 예측 모형의 평가 기준에 관한 논의

앞서 설명하였듯이 기계학습의 경우 훈련데이터(Training Data)를 통해서 알고리즘을 fitting하고 시험데이터(Test Data)를 통해서 모형의 성과를 추정한다. 모형성과의 측정은 종속변수가 연속형 변수인 경우 평균제곱오차(Mean Squared Error, MSE) 혹은 R-square를 통하여 이루어지고 있는데 종속변수가 더미변수인 경우에는 연구자들 사이에 통일된 성과측정 방법론이 존재하지 않는 상황이다. 종속변수가 더미변수인 경우 성과지표는 크게 두 가지로 분류할 수 있는데 먼저 연속형 변수에 사용하는 R-square와 비슷한 McFadden-R-square 혹은 pseudo-R-square를 모형의 성과지표로 사용할 수 있다. 직관적으로는 McFadden-R-square는 모형의 성과를 상수항만을 포함한 모형의 log-likelihood 값과 성과평가의 대상이 되는 모형의 log-likelihood 값의 비교를 통해서 측정한다.²⁷⁾ 두 번째 성과측정 방법론은 혼

27) McFadden-R-square는 다음과 같이 정의된다. 여기서 L_e 는 평가대상이 되는 모형이며

동행렬(Confusion Matrix)을 통해 산출되는 다양한 값들을 활용하는 것이다. 혼동행렬은 분류알고리즘의 성능을 표현해주는데 좀 더 구체적인 설명을 위해서 <표 V-7>에는 혼동행렬의 예시를 보여주고 있다. 혼동행렬은 네 가지의 경우를 보여주는데 먼저 True Negative의 경우는 모형의 예측값과 실제값이 모두 음성인 경우를 의미하며, False Positive는 모형이 실제값이 음성임에도 불구하고 양성으로 예측한 경우이며, False Negative는 모형이 실제로는 양성임에도 불구하고 음성으로 예측한 경우이며 마지막으로 True Positive는 모형의 예측값과 실제값 모두 양성인 경우이다.

<표 V-7> 혼동행렬 예시

구분		예측값	
		0	1
실제 값	0	True Negative (TN)	False Positive(FP)
	1	False Negative (FN)	True Positive (TP)

자료: 저자 작성

이러한 혼동행렬을 통해서 다양한 평가지표를 생성할 수 있는데 이용 가능한 평가지표는 다음과 같이 정리할 수 있다.

○ $Accuracy = \frac{TP + TN}{Total\ Observation}$ 로 전체 표본에서 실제값과 동일하게(양(+))의 값 혹은 음(-)의 값) 분류된 관측치의 비율을 의미

○ $Recall (True\ Positive\ Rate) = \frac{TP}{TP + FN}$: 실제 양(+))의 값을 가지는 관측치 중에 모형을 통해서 양(+))의 값으로 분류된 비율

$$L_{null} \text{은 상수항만을 포함한 모형을 의미한다. } R_{McFadden}^2 = 1 - \frac{\log(L_c)}{\log(L_{null})}$$

$$\circ 1 - Specificity (False Positive Rate) = \frac{FP}{FP + TN}: \text{실제 음(-)의}$$

값을 가지는 관측치 중에서 양의 값을 가지는 것으로 분류된 비율

이외에도 $F_1 - score$, Negative Predicted Value 등의 성과지표들이 존재하는데 많은 연구자들은 이와 같은 성과지표들 중에서 임의로 몇 개의 지표를 이용해서 모형의 성과를 평가하고 있다.

본 연구에서는 일정 수준의 Accuracy(90%)를 만족하는 가운데 Recall Rate를 최대화하도록 알고리즘을 최적화한 후 Recall Rate를 통해서 모형의 성과를 평가하는데 이러한 성과지표를 선택한 이유는 바로 자살 고위험군에 속하는 사람들이 표본의 대략 6%에 불과하기 때문에 모형의 성과를 판단하기 위해서는 실제 양(+)의 값을 가지는 관측치 중에서 모형을 통해서 얼마만큼 정확하게 분류가 되는지가 중요하기 때문이다. 가령 100명의 관측치 중에서 95명이 음성이고 5명이 양성인 경우를 고려하였을 때 특정 알고리즘이 95명의 음성인 관측치를 정확히 음성으로 예측하고(TN) 5명의 양성에 대해서는 모두 음성으로 예측(FN)하였다고 가정하자. 또한 다른 알고리즘의 경우 95명의 음성인 관측치에 대해 93명을 정확히 음성으로 예측하고 5명의 양성인 경우에 2명을 정확하게 예측하였다고 하자. 첫 번째 알고리즘이 실제로 양성인 관측치에 대해서 아주 부정확하게 예측하였지만 양성인 관측치가 5%에 불과하기 때문에 두 알고리즘 모두 Accuracy를 기준으로 사용하는 경우 95%로 동일하다. 따라서 실제 양성인 숫자가 음성에 비해 매우 작은 경우 그리고 양성인 관측치를 정확하게 예측하는 게 중요하다면 Accuracy를 기준으로 사용하는 것이 아닌 Recall Rate를 사용해야 하며 본 연구의 경우도 소수의 양성인 관측치를 정확하게 예측하는 것이 중요하므로 Recall Rate를 사용하는 것이 타당해 보인다.

Accuracy Rate를 일정 수준 만족하면서 Recall Rate를 최대화하는 알고리즘을 선택하는 방법은 Sansone(2019)에서 처음 소개되었다. Sansone(2019)는 정부가 정책에 사용되는 한정된 자원을 가지고 정책의 효과를 최대화하

고자 할 때 최적화된 정책 대상의 식별 과정을 모형을 통해서 보여주었다. 본 연구도 기계학습을 통하여 정부 정책의 효과성 및 효율성을 개선하는 것이 목적이기 때문에 국가의 목적함수와 정책재원이 한정되었을 때 정책의 대상자를 식별하는 알고리즘을 평가하는 최선의 지표가 무엇인지를 Sansone(2019)을 참조하여 논의하도록 한다.

만약 국가가 자살 고위험군인 노인들을 다양한 모형(기계학습 알고리즘, 전문가들의 의견)을 통해 예측하고 예측된 고위험군 노인들을 대상으로 자살예방정책을 선제적으로 취하려고 한다면 그리고 정부의 목적함수가 노인 자살이라는 사건을 한정된 재원을 가지고 최소화하는 것에 있다면 정부의 최적화 문제는 다음과 같이 표현이 가능하다.

$$\begin{aligned} \min \quad & n_1[(1-\phi)prob(1,not\ treatment)+\phi prob(1,treatment)] \\ s.t. \quad & cost \times [FP+TP] \leq B \end{aligned}$$

여기서 n_1 은 앞에서 정의한 True Positive(TP)와 False Negative(FN)의 합 즉 실제 자살 고위험군에 해당하는 노인들이며, ϕ 는 Recall Rate(True Positive Rate)으로 실제 고위험군에 해당하는 사람들 중에 모형을 통해서 고위험군으로 예측된 사람을 의미한다. $prob(type,treatment)$ 는 개인의 유형과 자살 예방프로그램에 의한 처치 여부에 따른 자살로 인해 사망할 확률을 의미한다. 마지막으로 $cost$ 는 1인당 자살예방정책에 소요되는 비용이며, FP 는 False Positive로 모형에 의해 고위험군으로 분류된 저위험군 노인의 수, 마지막으로 B 는 자살예방정책에 주어진 예산을 의미한다.

개인의 유형은 자살의 고위험군($type=1$)과 저위험군($type=0$)으로 분류하였으며 자살예방프로그램은 처치의 정도(intensity)를 구분하지 않고 처치의 여부(0 혹은 1)로 정의하였다. 자살확률함수의 특성은 다음과 같이 정의하였다.

$$\begin{aligned} prob(0,treatment) &= 0 \\ prob(1,treatment) &\geq 0 \\ prob(1,not\ treatment) &\geq prob(1,treatment) \end{aligned}$$

즉 자살확률함수에서 저위험군의 경우 처치 여부와 상관없이 자살할 확률은 0이며 고위험군의 경우 처치를 받을 경우 처치를 받지 않은 경우에 비해 자살할 확률은 줄어들지만 처치를 받는 경우도 자살할 확률이 0보다 큼을 의미한다.

$$prob(type, treatment) = \frac{type}{2 + treatment}$$

마지막으로 수식의 간편화를 위해 위와 같은 함수적 형태를 추가로 가정한다면 정부의 최적화 문제는 다음과 같이 간단하게 표현될 수 있다.²⁸⁾

$$\begin{aligned} \min \quad & \frac{1}{2} - \frac{\phi}{6} \\ \text{s.t.} \quad & cost \times [FP + TP] \leq B \end{aligned}$$

결국 정부의 최적화 문제는 주어진 예산 제약식에서 Recall Rate를 최대화하는 값을 찾는 것과 동일함을 알 수 있다. 만약 정부가 해당 정책에 대해서 사용가능한 자원과 노인 1인당 소요되는 정책비용을 알고 있다면 알고리즘의 성과를 평가할 때 모형을 통해서 예측되는 고위험군의 숫자를 제약식으로 하고 Recall Rate를 최대화하는 식으로 성과의 평가가 가능하다. 가령 주어진 예산을 고려하여 1만명의 노인에게만 사전적인 자살예방정책을 시행할 수 있다면 모형을 통해 예측되는 고위험군의 수를 만명 이하로 하는 제약조건에서 Recall Rate를 최대화하는 성과지표를 통해서 알고리즘간의 비교가 가능하다는 것을 의미한다.

28) 함수형태를 처치 정도의 선형함수로 가정하는 것도 고려할 수 있는데 그러할 경우 treatment 정도에 따른 한계효용이 체감하지 않기 때문에 위와 같은 비선형 함수가 좀 더 현실적이라고 할 수 있다.

마. 예측결과

(1) 분석에 사용할 기계학습 알고리즘 및 진행과정

본 연구에서는 다양한 기계학습 알고리즘을 이용하여 모형 예측을 시도하였다. 추가적으로 복잡한 기계학습을 사용한 모형의 성과와 일반적인 연구자들이 사용할 것으로 여겨지는 모형의 성과를 비교하기 위해 먼저 OLS 및 Logit을 이용하여 고위험군 예측 모형을 구축하였다. 연구자들에 의해 사용될 것으로 여겨지는 모형을 구축하기 우선적으로 위해 노인 자살을 연구한 선행연구의 연구목적, 연구방법, 연구대상, 독립변수, 종속변수 등을 조사하였다. 선행연구는 크게 두 가지로 나뉘는데 먼저 첫 번째로 시도별 노인자살의 차이와 지역적 경제적 특성 및 노인복지정책 등과의 관련성을 분석한 연구들이 있으며, 두 번째 연구들은 개인 마이크로데이터를 활용하여 개인의 자살생각과 개인의 특성 간의 관계를 분석한 것이다. 마이크로 데이터를 활용한 노인자살생각과 개인 특성을 연구한 많은 연구들은 자살 시도와 우울증 간의 강건한 상관관계를 밝혔다(황정우 외, 2017; 윤현숙·염소림, 2016; 김동배·박서영, 2010). 따라서 본 연구에서는 연구자들에게 구축될 것으로 보이는 모형은 우울증 관련 변수들을 예측변수로 사용하는 OLS와 Logit 알고리즘으로 정의하고 해당 모형의 성과와 나머지 기계학습을 사용한 알고리즘의 성과를 비교할 예정이다.

다양한 기계학습을 알고리즘 중에서 본 연구에서 사용할 알고리즘은 Boosting, Post-Lasso, Decision Tree를 사용하였다. Lasso 알고리즘의 경우 패널티 항인 λ 에 의해 추정된 계수에 편의가 발생하게 되므로 본 연구에서는 Lasso algorithm을 적용하여 중요 변수들을 먼저 추출한 뒤 추출된 변수만을 가지고 OLS 및 Logit을 수행하는 Post-Lasso 알고리즘을 사용하였다. 마지막으로 Boosting 알고리즘의 경우에는 여러 가지 Boosting algorithms 중에서 Logit을 기본 추정치로 하는 Adaboost(Adaptive boosting model) 알고리즘을 사용하였다.

사용할 알고리즘이 정해지면 훈련데이터에서 알고리즘을 추정하고 실험

데이터에서 성과를 평가하는 과정을 거치게 되는데 본 연구에서는 기계학습에서 가장 정형화된 5-fold cross validation 방법론을 사용하여 추정 및 평가를 진행하였다.²⁹⁾ 좀 더 구체적으로 설명하자면 각각의 알고리즘의 성과를 알아보기 위해, 전체 데이터를 무작위로 5개의 폴드(fold)로 나눈 후에 1개의 폴드를 실험데이터로 사용하고 나머지 4개 폴드는 훈련데이터로 사용하는 실험을 반복적으로 수행하였다. 훈련데이터에서 모델을 최적화할 때는 $90 \pm 0.5\%$ 의 Accuracy 만족시키는 범위 내에서 Recall을 최대화하는 방향으로 최적화시켰으며 최적화가 끝난 후 실험데이터를 통해서 Recall Rate를 측정되게 된다. 결과적으로 모든 폴드는 총 4회에 거쳐 훈련데이터로 사용되며 단 1회만 실험데이터로 사용하게 되며 최종적으로 산출되는 Recall Rate은 5회의 실험데이터에서 계산된 Recall Rate의 평균값으로 구해진다.

29) 교차검증의 경우 5-fold 혹은 10-fold를 사용하는 것이 일반적이다. 본 연구에서 10-fold를 사용하지 않는 이유는 실험에 사용된 데이터의 특성 때문이다. 구체적으로 종속변수가 0의 값을 가지는 경우는 총 18,733건이며, 1의 값의 경우는 총 1,631건으로 종속변수는 양(+)의 값을 상대적으로 작게 가지는 불균형 분포이다. 이에 따라 10-fold 교차검증을 실행하는 경우 각 실험데이터당 양(+)의 값이 163개만을 포함하게 되어 모형성과의 일관성이 더욱 떨어질 것으로 판단되며 이에 따라 본 연구에서는 5-fold 교차검증을 사용하였다.

〈표 V-8〉 선행연구 정리

제목	연구목적	연구방법	연구대상	독립변수	종속변수
김형수·권이경(2013), 「한국 노인자살률과 사회·경제적 요인의 관련성」, 『한국콘텐츠학회 논문지』, 13(6), 236~245	우리나라 노인자살의 원인을 거시적 관점에서, 노인 자살률과 경제·사회적 요인의 관련성을 파악하고 이에 기초하여 노인자살 예방에 관한 정책적 방안을 모색	노인 자살률 경향을 검토 후, 사회경제적 변수들의 변화 시 노인자살률의 변화 양상을 시계열적 (1990~2010)으로 분석	1990년부터 2010년까지 21년간 한국의 노인자살률	경제적 요인: 경제성장률, 실업률, 노인경제참가율, 상대적 빈곤율/사회적 요인: 사회복지지출비, 이혼율, 고령화비 증거율, 노인부양비	노인자살률
김형수·김신형(2014), 「우리나라 노인자살률의 지역적 편차와 요인에 관한 연구」, 『한국콘텐츠학회논문지』, 14(11), 215~224	지역적 특성에 따른 노인자살의 원인에 대해 연구	16개 시도별 노인자살률 현황을 시계열적으로 분석하고, 사회경제적 요인과 노인자살률의 관련성을 파악	2003년부터 2011년까지 9년간 지역별(16개 시도) 노인자살률	경제적 요인: 경제활동 참가율, 노인기초수급률, 고령화비율/사회적요인: 복지예산비율, 조이혼율, 지역적 특성(대도시와 기타지역으로 나눔)	전체 노인자살률, 성별 노인자살률, 연령별 (전기 후기) 노인자살률
김동배·박서영(2010), 「노인의 사회관계망 특성과 자살생각 관계」, 『한국사회복지조사연구』, 24, 109~129	노인의 사회관계망 특성과 우울이 자살생각에 미치는 영향	사회관계망 특성과 자살생각 간 관계에서 우울의 매개효과를 검증하기 위해 다중회귀분석을 실시하고 매개효과를 추정하기 위해 Sobel test를 실시	성남시 소재 7개 사회복지기관을 선정하여 60세 이상 남녀노인 800명을 대상으로 함	독립변수 - 사회관계망 특성: 외부도움 정도, 비동거자녀 접촉 여부, 사회활동 참여 여부/ 매개변수 - 우울: 한국판 노인 우울증 척도(Geriatric Depression Scale-Korea) 사용	자살생각

〈표 V-8〉의 계속

제목	연구목적	연구방법	연구대상	독립변수	종속변수
윤현숙·염소림(2016), 「노인의 우울이 자살생각에 미치는 영향에 대한 가족 연대감의 매개효과」, 『한국사회복지학』, 68(1), 53~71	노인의 우울이 자살생각에 미치는 영향을 분석하고, 가족연대감의 매개효과를 확인	변수들 간의 상관관계 분석, 우울이 자살생각에 미치는 영향을 검증하고 가족 연대감이 우울과 자살생각을 매개하는지 검증하기 위하여 Baron and Kenny(1986), Judd and Kenny(1981)과 James Brett(1984)가 제안한 매개효과 분석 방법을 수행, Sobel- test를 활용하여, 매개 효과가 나타나는지 분석	2014년 춘천시 노인생활 실태조사 자료를 이용하여 65세 이상 2,034명의 노인을 대상으로 함	독립변수 – 우울: CES -D(Center for Epidemiological Studies-Depression Scale)을 사용하여 측정 /매개변수 – 가족연대감 : Reasons for Living Scale-older Adult version(RFL-OA) 척도를 한국어로 번역하여 사용	자살생각: The suicidal Behaviors Questionnaire -Revised(SRQ-R): Validation with clinical and Nondclinical samples, Assessment, 84를 사용하여 측정
권중돈·김유진·임태영 (2011), 「노인돌봄서비스 이용 독거노인의 자살생각에 영향을 미치는 요인에 관한 연구」, 『노인복지연구』, 51, 297~320	독거노인들의 자살생각에 과거 자살 사도 경험과 음주 정도가 어떤 영향을 주는지, 자살생각에 대해 음주정도가 자살사도 경험과의 관계에서 조절효과를 가지는지 검증	다중회귀분석 실시	서울시 서대문구와 강동구에 거주하며 노인돌봄서비스를 제공받고 있는 65세 이상의 독거노인 553명을 대상	독립변수: 자살사도 경험/ 조절변수: 음주 정도	자살생각: Beck, Kovacs and Weissman(1979)의 자살생각 척도를 신민섭(1993)이 변안한 척도를 활용

〈표 V-8〉의 계속

제목	연구목적	연구방법	연구대상	독립변수	종속변수
황정우·이강욱·김정유·이동하·김두명(2017), 「동거 및 독거노인의 우울이 자살사고에 미치는 영향과 대인관계의 조절효과」, 『정신보건과 사회사업』, 45(1), 36~62	동거 및 독거노인 각각의 자살사고에 미치는 요인은 무엇이며, 대인관계의 조절효과는 어떠한지 알아보고자 함	노인집단에 따른 우울이 자살사고에 영향을 미치는 영향을 알아보기 위하여 조절효과를 반영한 위계적 회귀분석을 실시	강원도의 65세 이상 노인을 대상으로 자살 고위험자를 선별	독립변수 - 성별, 나이, 경제적 상태, 신체적 건강, 문제음주, 자살시도 경험, 우울 /조절변수 - 대인관계 (친구, 이웃과의 연락 빈도)	자살사고

자료: 저자 작성

마지막으로 앞서 언급하였듯이 본 연구의 목적은 기계학습 알고리즘을 통하여 현행 노인자살을 예방하는 정책의 효율성 및 효과성을 개선하는 방안을 모색하는 것이다. 기존의 자살예방정책은 고위험군 노인들을 식별하기 위해 노인돌봄이 및 맞춤형 방문간호사를 통해 노인들을 대상으로 마음건강 검진을 실시하고 해당 결과를 통해서 고위험군을 식별하고 있다. 이러한 정책 수행과정이 정확하게 작동하기 위해서는 모든 노인들을 대상으로 검진을 실시해야 되고 이에 따라 재정의 부담으로 작용할 수 있다. 따라서 정성적인 평가가 아닌 행정데이터 등을 이용하여 자살 고위험군을 동일하게 혹은 정확하게 예측을 할 수 있다면 비용이 많이 들어가는 정성평가를 통해서 고위험군의 식별할 필요성이 적어지게 된다. 기존에 고위험군을 식별하기 위해 사용되는 마음건강검진은 우울감이나 만족감 등의 감정적인 요소들을 측정하는 것으로 「노인실태조사」에서는 우울감(변수명 B6_1-B6_15)의 변수가 이에 해당한다. 따라서 본 연구에서는 기계학습 알고리즘을 사용할 때 이러한 감정변수가 예측변수로 포함된 경우와 포함되지 않는 경우 두 가지 경우를 모두 고려하여 알고리즘의 성과를 평가함으로써 기계학습 알고리즘의 정책개선 가능성에 대해서 탐색한다.

(2) 모형 추정결과

〈표 V-9〉는 Baseline 알고리즘의 Accuracy와 Recall Rate를 보여주고 있다. OLS와 Logit 알고리즘 모두 우울증과 관련이 있는 요소만을 이용하여 구축하였으며 모형의 추정된 계수의 값은 〈부표 V-1〉에 수록하였다.³⁰⁾ OLS 알고리즘의 Recall Rate이 21.27%이며 Logit 알고리즘의 실험데이터에서의 Recall Rate은 26.34%로 추정되었는데 이는 100명의 실제 자살 고위험

30) 우울증 관련 변수들은 다음과 같다. 우울증척도_현재생활 만족, 우울증척도_의욕저하, 우울증척도_헛된 느낌, 우울증척도_지루함, 우울증척도_상쾌함, 우울증척도_불안함, 우울증척도_마음의 즐거움, 우울증척도_절망적 느낌, 우울증척도_나가기 싫음, 우울증척도_기억력 나쁨(동년배 비교), 우울증척도_살아있음에 대한 즐거움, 우울증척도_쓸모없음, 우울증척도_기력줄음, 우울증척도_희망없음, 우울증척도_다른사람들보다 처지가 더 못함

군에 해당하는 노인들 중에서 OLS 알고리즘(Logit 알고리즘)은 21.27명 (26.34명)을 정확하게 파악하였음을 의미한다.

〈표 V-9〉 Baseline 알고리즘의 성과지표

(단위: %)

구분	알고리즘명	Accuracy	Recall
1	OLS	90.08	21.27
2	Logit	89.95	26.34

자료: 보건복지부, 「노인실태조사」 2014 및 2017 자료를 활용하여 저자 추정

〈표 V-10〉은 이용 가능한 모든 변수들을 활용하였을 때의 기계학습 알고리즘들의 성과를 제시하고 있는데, 흥미로운 점은 우울증 관련 변수 등 모든 변수를 사용하여 추정하였을 때 Decision Tree, OLS-Post Lasso, Logit-Post Lasso 알고리즘의 Recall Rate의 경우 우울증 관련 변수들만을 사용한 Logit 알고리즘과 비교하여 Recall Rate의 성과가 하락하였다는 점이다. 이는 470개의 변수를 모두 사용할 경우 훈련데이터에서의 overfitting 문제를 Regularization을 통해서 적절히 대응하지 못하였음을 의미하며 모형의 성과를 올리기 위한 방안의 고민이 필요할 것으로 보인다.

예를 들어, Lasso 알고리즘에 추가적인 제약을 통해서 모형의 성과를 향상시키는 것이 가능한데, 자살 고위험군의 식별의 경우 연구자들이 우울증 관련 변수들의 중요성을 알고 있기 때문에 Lasso 알고리즘을 이용하여 예측 변수들을 선택할 때 우울증 관련 변수들을 필수적으로 선택하게 제약을 추가할 수 있다. Lasso 알고리즘에 이러한 제약을 추가한 뒤 모형을 훈련시켰을 때 실험데이터에서의 모형의 성과는 〈표 V-9〉의 4-1과 5-1에 제시되어 있다. 모형의 Recall Rate은 OLS-Post Lasso의 경우 28.14% Logit-Post Lasso의 경우 31.82% 향상되어 해당 제약을 주지 않은 경우와 비교하여 성과는 각각 24.40%, 36.57%만큼 향상되었다. 또한 Baseline의 알고리즘의 성과지표와 비교하여도 제약을 추가한 Lasso 알고리즘의 성과는 향상되었다. 따라서 Lasso 알고리즘의 경우 Regularization을 통한 알고리즘의 Overfitting을

적절히 대응하지 못하는 경우가 발생한다면 연구자의 자의적인 판단으로 중요하게 여기는 변수들은 필수적으로 선택하는 제약을 추가하는 것도 모형 향상에 기여할 수 있는 것으로 보인다.³¹⁾

마지막으로 <표 V-10>은 AdaBoost의 Accuracy와 Recall Rate을 보여주는 데 Accuracy는 90.07이며 Recall Rate은 41.17로 측정되어 Logit 알고리즘을 활용한 벤치마크 케이스와 비교 시 Accuracy는 그대로 유지하면서도 성과가 무려 약 56.30% 향상되었음을 알 수 있다. 따라서 우울증 관련 변수 등을 사용하여 고위험군을 식별할 경우에도 해당 변수 이외의 추가적인 변수들을 활용하여 DB을 구축하고 기계학습 방법론을 사용할 경우 자살 고위험군을 보다 정확하게 식별할 수 있음을 보여준다.

<표 V-10> 알고리즘의 성과지표(모든 변수 사용)

구분	알고리즘	Accuracy	Recall
1	OLS	0.8991	0.3083
2	Logit	0.8992	0.3623
3	Decision Tree	0.8994	0.2226
4	OLS - Post Lasso	0.9000	0.2262
5	Logit - Post Lasso	0.8991	0.2330
6	AdaBoost(Logit)	0.9007	0.4117
4-1	OLS - Post Lasso	0.9002	0.2814
5-1	Logit - Post Lasso	0.8997	0.3182

주: 1, 4-1과 5-1의 알고리즘의 경우 우울증 관련 변수들을 Lasso 알고리즘이 필수적으로 선택하게 제약을 추가
자료: 보건복지부, 「노인실태조사」 자료를 활용하여 추정함

우울증 관련 변수들을 제외하고 그 외의 변수들을 가지고 추정한 모형의 Recall Rate는 <표 V-11>에 제시되어 있다. <표 V-10>과 비교 시 모든 알고리즘의 모형의 성과(Recall Rate)가 하락하는 것으로 나타났으나, 3번부터

31) 본 연구의 알고리즘의 성과(Recall Rate) 분석 시 OLS가 Logit에 비해 Lasso를 사용 여부와 관련없이 떨어지는 것으로 나오는데 이는 기존의 선행연구 결과와도 일치하는 경향이다(Sansone, 2019).

5번에 해당하는 알고리즘을 제외하면 우울증 관련 변수들을 포함하고 있지 않은 경우에도 벤치마크 모형과 비교하에는 높은 Recall Rate을 기록하였다. 특히 AdaBoost와 Logit의 경우 감정변수들을 제외하고도 Recall Rate을 각각 32.30, 32.84를 기록하여 벤치마크 케이스의 Recall Rate인 26.34에 비해 무려 성과가 약 22% 높게 추정되었다. 이러한 AdaBoost와 Logit의 성과는 정책적으로 중요한 함의를 지닐 수 있는데 왜냐하면 정부가 쉽게 이용 가능한 행정데이터만을 이용하여 설문조사의 경우와 동일한 성과를 보여준다면 비용 측면에서 정책의 효율성을 높일 수 있기 때문이다.

〈표 V-11〉 알고리즘의 성과지표(우울증 관련 변수들 제외함)

구분	알고리즘	Accuracy	Recall
1	OLS	0.9005	0.2581
2	Logit	0.8991	0.3284
3	Decision Tree	0.8999	0.2174
4	OLS - Post Lasso	0.9001	0.1723
5	Logit - Post Lasso	0.9002	0.1892
6	AdaBoost(Logit)	0.9005	0.3230

자료: 보건복지부, 「노인실태조사」 자료를 활용하여 추정함

따라서 해당 알고리즘의 예측에 중요하게 사용된 변수가 무엇인지 파악하는 것은 정책적으로 중요한 의미를 지니게 되는데 본 연구에서는 먼저 Friedman(2001)과 Schonlau(2005)가 제시한 Boosting 알고리즘에서 변수가 예측에 미치는 영향을 계산하는 방법을 활용하여 AdaBoost 알고리즘에서 중요하게 사용된 변수를 살펴보고자 한다. Friedman(2001)과 Schonlau(2005)가 제시한 특정 변수의 영향력(Influence)은 기본적으로 Boosting을 최적화 시 모든 나무에서 해당 변수가 몇 번 선택되었는지 그리고 선택된 변수가 log-likelihood에 미치는 영향이 얼마인지에 따라 결정이 된다. log-likelihood는 각각의 예측변수들을 모델에 포함시킨 경우와 포함시키지 않은 경우의 성과 차이를 통해서 추정되며, 동 테스트를 반복적으로(5회) 수

행하여 성과 차이의 평균값이 가장 큰 상위 15개 예측변수를 제시하였다.

〈표 V-12〉는 AdaBoost 알고리즘의 변수별 영향력을 우울증 관련 변수들을 포함하는 경우와 포함하지 않는 경우로 구분하여 제시하고 있다. 먼저 우울증 관련 변수들을 포함하는 경우 변수별 영향력 관련 상위 15개의 변수들을 살펴보면 7개의 변수가 우울증 관련 변수들임을 알 수 있었다. 이는 우울증 관련 변수들이 자살 고위험군을 식별하는 데 중요하다는 것을 의미해서 앞선 선행 연구들의 결과와 일치한다.

〈표 V-12〉 AdaBoost 알고리즘의 변수별 영향력

우울증 관련 변수를 포함한 경우		우울증 관련 변수를 제외한 경우	
변수명	영향력	변수명	영향력
우울증척도_절망적 느낌	0.148	타인으로 인해 감정을 상함_여부	0.202
우울증척도_헛된 느낌	0.141	만족도_경제상태	0.140
우울증척도_다른사람들보다 처지가 더 못함	0.135	만족도_자녀와의 관계	0.128
우울증척도_살아있음에 대한 즐거움	0.106	비동거 손자녀 전체_연락 빈도 (지난 1년 간)	0.078
만족도_자녀와의 관계	0.064	일상생활 차별 경험 유무	0.070
만족도_경제상태	0.058	영양관리_금전상태에 따른 음식구입 어려움	0.062
우울증척도_지루함	0.051	현재 일_만족도	0.054
우울증척도_나가기 싫음	0.071	비동거자녀_간병/수발/병원동행_도움 받음	0.043
일상생활 차별 경험 유무	0.036	영양관리_과일 미섭취	0.039
동작수행 어려움_쌀 1말(8kg) 정도 물건 들어 올리거나 옮기기	0.036	영양관리_거의 매번 혼자 식사함	0.039
영양관리_하루에 3가지 이상의 서로 다른 약 복용	0.035	노후생활_노후생활비 마련 방법	0.035
타인으로 인해 감정을 상함_여부	0.033	지난 1년간 구직활동 노력(1순위)	0.035
지난 1년간 자녀와의 갈등 경험	0.029	형제/자매 생존 여부	0.027
우울증척도_마음의 즐거움	0.029	최장기 일자리_직업중분류	0.027
노후생활_노후생활비 마련 방법	0.027	배우자_간병/수발/병원동행_도움 받음	0.023

자료: 보건복지부 「노인실태조사」를 활용하여 추정함

우울증 관련 변수를 제외한 AdaBoost 알고리즘에서 사용된 중요 변수들을 살펴보면, 타인으로 인해 감정을 상함_여부, 만족도_경제상태, 만족도_자녀와의 관계, 비동거 손자녀 전체_연락 빈도(지난 1년간), 일상생활 차별경험 유무, 영양관리_금전상태에 따른 음식구입 어려움, 현재 일_만족도, 비동거자녀_간병/수발/병원동행_도움 받음, 영양관리_과일 미섭취, 영양관리_거의 매번 혼자 식사함, 노후생활_노후생활비 마련 방법, 지난 1년간 구직활동 노력(1순위) 순으로 높게 나타났다. 다만 해당 변수들의 경우 정부의 행정데이터를 통해서 획득 가능한 변수들은 아니며 추가적인 설문조사가 필요한 경우가 많아서 기계학습을 통하여 정책 비용의 감소 가능성 여부는 명확하지 않다. 따라서 추후 연구에서는 모든 변수 중에서 행정데이터 등을 통해서 쉽게 획득 가능한 변수로 한정 후 해당 알고리즘을 통해서 모형을 예측하는 분석을 실시할 예정이다.

Logit 알고리즘의 경우에 우울증 관련 변수를 제외 시 Recall Rate이 32.84로 높게 추정되었는데 행정데이터만을 활용하여 모형 예측의 가능성을 검토하기 위해서 Logit 알고리즘의 경우도 변수별 영향력을 우울증 관련 변수들을 포함하는 경우와 포함하지 않는 경우로 구분하여 살펴보았다. 먼저 <표 V-13>의 우울증 관련 변수들을 포함하는 경우를 살펴보면 변수별 영향력 관련 상위 15개의 변수들 중에서 5개의 변수가 우울증 관련 변수들임을 알 수 있었다.

우울증 변수를 제외하는 경우 영향력 관련 운동 시간(분)_(1회 기준), 만족도_경제상태, 비동거 생존자녀 중 가장 많이 접촉한 자녀_왕래 빈도, 영양관리_거의 매번 혼자 식사함, 2번가구원의 혼인상태, 그외 가구원_개인연금_유무, 노후생활_노후생활비 마련 방법, 그외 가구원_총수입액_유무, 안전사고 경험 유무(지난 1년간), 1번가구원의 혼인상태 순으로 높게 나타났다. 여기서 운동시간(건강보험의 건강검진데이터), 2번가구원의 혼인상태(주민등록정보시스템), 그외 가구원_개인연금_유무(국세청 종합소득세 신고 상세내역), 그외 가구원_총수입액_유무(국세청 종합소득세 신고 상세내역), 안전사고 경험 유무(지난 1년간)(건강보험자료), 1번가구원의 혼인상태(주민등록정

보시스템) 등 많은 변수들이 행정데이터의 구축을 통해서 확보가 가능하기 때문에 <표 V-13>의 결과는 별도의 설문조사 없이 행정데이터의 구축을 통해서 노인자살 고위험군의 식별 가능성을 보여준다. 향후 자살 고위험군 예측 모형을 위한 DB 구성에 건강보험 건강검진 데이터, 건강보험 청구자료, 국세청 종합소득세 신고내역, 주민등록정보시스템의 가족관계데이터 등을 활용할 수 있다면 노인 자살 고위험군의 식별비용 절감과 식별의 정확성을 동시에 높이는 것도 가능할 것으로 판단된다.

<표 V-13> Logit 알고리즘의 변수별 영향력

우울증 관련 변수를 포함한 경우		우울증 관련 변수를 제외한 경우	
변수명	영향력	변수명	영향력
우울증척도_다른 사람들보다 처지가 더 못함	0.164	운동 시간(분)_(1회 기준)	0.171
우울증척도_절망적 느낌	0.133	만족도_경제상태	0.085
우울증척도_헛된 느낌	0.090	비동거 생존자녀 중 가장 많이 접촉한 자녀_왕래 빈도	0.080
동작수행 어려움_운동장 한 바퀴(400m) 정도 뛰기	0.071	영양관리_거의 매번 혼자 식사함	0.077
동작수행 어려움_쌀 1말(8kg) 정도 물건 들어 올리거나 옮기기	0.059	2번가구원의 혼인상태	0.075
우울증척도_살아있음에 대한 즐거움	0.057	그 외 가구원_개인연금_유무	0.064
타인으로 인해 감정을 상함_여부	0.057	노후생활_노후생활비 마련 방법	0.064
만족도_건강상태	0.052	그 외 가구원_총수입액_유무	0.064
주로 하는 여가문화활동 2순위	0.050	안전사고 경험 유무(지난 1년 간)	0.051
우울증척도_지루함	0.050	1번가구원의 혼인상태	0.048
치료 여부_위 및 십이지장궤양	0.050	지출_문화여가비_유무	0.048
노후생활_자녀의 노부모와의 동거(적어도 한 명)에 대한 생각	0.045	평소의 건강상태	0.045
지난 1년간 자녀와의 갈등 경험	0.043	일상생활 차별 경험 유무	0.045
일상생활 차별 경험 유무	0.043	IADL_빨래(손이나 세탁기로 세탁 후 널어 말리기 포함)	0.043
자주 경험하는 차별 경험	0.038	3번가구원의 만 연령	0.040

자료: 보건복지부, 「노인실태조사」를 활용하여 추정함

마지막으로 Lasso를 이용한 Logit-Post Lasso와 OLS-Post Lasso의 경우 Recall Rate이 벤치마크 케이스에 비해 떨어지기 때문에 적합한 알고리즘이라고 할 수는 없지만 우울증 관련 변수 등을 제외한 Logit-Post Lasso의 경우 Recall Rate은 18.92로 나쁘지 않는 성과를 보여주었다. 설문조사를 통한 고위험군의 식별에 발생하는 많은 비용을 고려하였을 때 그리고 만약 Logit-Post Lasso의 경우에 비용이 적게 드는 행정데이터만을 사용하였다면 비용 대비 측면에서 Logit-Post Lasso 알고리즘의 낮은 Recall Rate는 감내할 만한 수준일 수 있다. 따라서 본 연구에서는 앞선 다른 알고리즘과 마찬가지로 Lasso 알고리즘에서 예측에 중요한 변수들이 무엇인지를 살펴보았다. 다만 Lasso의 경우에는 앞선 AdaBoost와 Logit 알고리즘에서 활용한 ‘특정 변수의 영향력 지수’를 활용하는 것이 불가능해서 반복적인 5번의 실험에서 훈련데이터를 통한 모형을 최적화할 때 해당 변수들이 몇 번 선택이 되었는지를 변수화하여 해당 변수의 중요성을 측정하였다.

〈표 V-14〉는 Lasso 알고리즘을 통해 4번 이상 선택된 변수들을 보여주고 있는데 우울증 관련 변수들이 포함된 경우를 보면 앞선 알고리즘의 경우와 마찬가지로 선택된 변수들 중에 우울증과 관련된 변수들이 많이 포함되었다. 이는 우울증을 측정하는 변수들이 자살 고위험군을 예측하는 데 매우 중요한 변수들임을 보여주고 있으며 우울증 관련 변수들만을 사용한 Logit 모형이 왜 높은 Recall Rate를 기록하였는지를 보여준다. 우울증 관련 변수를 제외한 경우를 살펴보면 앞선 알고리즘과는 다르게 만족도 관련 변수들, 영양관리 및 평소의 건강상태와 같은 변수들이 예측에 중요변수로 사용되었음을 알 수 있다. 하지만 우울증 관련 변수들을 제외한 경우에도 여전히 정부의 행정데이터를 통해서만 쉽게 획득할 수 있는 변수들만을 포함하고 있는 것은 아니며 설문조사를 통해서만 획득이 가능한 변수들을 많이 포함하고 있다. 따라서 우울증 관련 변수뿐만 아니라 정부가 현재 해당 변수를 쉽게 획득할 수 있는지 여부에 따라 데이터를 추가 분류한 뒤 이용이 용이한 변수들만을 이용해서 알고리즘을 최적화하고 성과를 평가하는 것이 중요해 보이며 이를 위한 후속연구가 필요해 보인다.

〈표 V-14〉 Logit-Post Lasso 알고리즘의 변수별 선택된 횟수

(단위: 회)

감정변수를 포함한 경우		감정변수를 제외한 경우	
변수명	횟수	변수명	횟수
우울증척도_헛된 느낌	5	평소의 건강상태	5
우울증척도_지루함	5	의사진단 여부_우울증	5
우울증척도_불안함	5	영양관리_금전상태에 따른 음식구입 어려움	5
우울증척도_절망적 느낌	5	영양관리_거의 매번 혼자 식사함	5
우울증척도_살아있음에 대한 즐거움	5	영양관리_하루에 3가지 이상의 서로 다른 약 복용	5
우울증척도_다른 사람들보다 처지가 더 못함	5	지난 1년간 치과 진료 못 받은 경험	5
영양관리_금전상태에 따른 음식구입 어려움	5	동작수행어려움_쌀 1말(8kg) 정도 물건 들어 올리거나 옮기기	5
영양관리_거의 매번 혼자 식사함	5	지난 1년간 자녀와의 갈등 경험	5
최장기 일자리_직업종류	5	비동거 손자녀 전체_연락 빈도 (지난 1년간)	5
지난 1년간 자녀와의 갈등 경험	5	비동거자녀_고민상담_도움 받음	5
비동거자녀_고민상담_도움 받음	5	낙상_지난 1년간 경험 유무	5
낙상_지난 1년간 경험 유무	5	만족도_건강상태	5
만족도_경제상태	5	만족도_경제상태	5
만족도_자녀와의 관계	5	만족도_배우자와의 관계	5
타인으로 인해 감정을 상함_여부	5	만족도_자녀와의 관계	5
일상생활 차별 경험 유무	4	일상생활 차별 경험 유무	5
재산처리방식	4	타인으로 인해 감정을 상함_여부	5
만족도_배우자와의 관계	4	희망 장례 방법	5
희망 장례 방법	4	재산처리방식	4
		거주형태(가구)	4
		의사진단 여부_우울증	4
		배우자_동반 외출 정도	4

자료: 보건복지부, 「노인실태조사」를 활용하여 추정함

바. 데이터의 한계점

결론적으로 머신러닝을 활용한 자살 모형은 자살 고위험군에 해당하는 사람을 기존의 모형에 비해 보다 정확하게 예측하였으며 우울증 관련 변수를 제외하고도 모형의 성과는 기존의 모형보다 향상되어 행정데이터만을 활용한 고위험군의 식별 가능성을 보여주었다는 데 의의가 있다. 본 항목에서는 이러한 모형의 성과에도 불구하고 모형의 예측력을 향상시킬 수 있는지 데이터의 한계점을 중심으로 논의하여 향후 「노인실태조사」의 설계에 함의점을 도출하고자 한다.

먼저 〈표 V-14〉는 훈련데이터의 규모에 따라 알고리즘의 성과가 어떻게 변화하는지를 보여주고 있다. 이를 위해 2017년 「노인실태조사」를 기준으로 훈련데이터 표본의 크기에 변화를 주면서 교차검증을 수행하였는데 실험데이터의 크기를 훈련데이터의 관측치 수와 관련 없이 고정시키기 위해 훈련데이터 크기 변화에 따른 교차검증에 사용할 실험데이터를 전체 데이터의 20%로 고정을 하였다. 그다음 나머지 80%를 활용하여 훈련데이터를 구축하였는데 그중 25%(전체 데이터의 20%), 50%(전체 데이터의 40%), 75%(전체 데이터의 60%), 100%(전체 데이터의 80%)를 추출하여 알고리즘을 훈련시키고 실험데이터를 통해 알고리즘의 성과를 측정하였다.

성과 추정결과 본 연구에서 고려중인 모든 알고리즘에서 훈련데이터의 크기가 증가함에 따라 Recall Rate이 증가하였음을 알 수 있었다. 특히 OLS와 OLS-Post Lasso 알고리즘의 경우 전체 데이터의 20%만 사용하였을 경우의 Recall Rate은 0.57과 3.77에 불과하였으나 전체 데이터의 80%를 훈련에 사용하는 경우의 Recall Rate은 25%를 초과하여 훈련데이터의 크기 증가에 따라 모형의 성과가 눈에 띄게 향상되었다. 흥미로운 점은 Logit과 Boosting algorithm은 OLS, OLS-Post Lasso, Decision Tree보다 훈련데이터의 크기에 영향을 덜 받는다는 점인데 이는 해당 알고리즘들이 모형의 외적타당성(external validity)을 더 빨리 만족시키는 것을 의미하여 훈련데이터의 크기가 작은 경우 Logit 혹은 Boosting algorithm을 사용하는 것이 바람직함을 보여준다.

〈표 V-15〉 훈련데이터의 관측치 크기별 알고리즘 성과의 차이

알고리즘	훈련데이터(20%)		훈련데이터(40%)		훈련데이터(60%)		훈련데이터(80%)	
	Accuracy	Recall	Accuracy	Recall	Accuracy	Recall	Accuracy	Recall
OLS	90.07	0.57	90.06	9.64	90.09	17.44	89.97	25.87
Logit	90.01	22.06	89.96	22.06	89.98	20.79	90.04	27.38
Decision Tree	90	5.08	89.99	9.68	89.98	11.59	89.93	18.57
OLS-Post Lasso	89.93	3.77	89.97	8.41	90.07	20	89.99	26.35
Logit-Post Lasso	89.99	20.95	89.98	20.63	90.02	21.27	90	22.7
AdaBoost (Logit)	90.05	24.76	89.99	30.79	89.95	33.01	90.01	38.31

주: 1. Lasso 알고리즘의 경우 우울증 관련 변수들을 알고리즘이 훈련데이터와 관련 없이 필수적으로 선택하게 설정함

자료: 보건복지부, 「노인실태조사」를 활용하여 추정


2017년 「노인실태조사」를 사용하는 경우와 2014년까지 결합하여 사용하는 경우의 성과를 비교하는 경우도 마찬가지로 모든 알고리즘에서 성과가 향상되었다. 특히 Adaboost 알고리즘의 경우 2017년 「노인실태조사」만을 사용하는 경우 모형의 Recall Rate은 38.31%였으나 2014년 「노인실태조사」까지 결합하는 경우 41.17%로 증가하여 모형의 성과가 약 7.47% 증가하였다. 만약 2020년 「노인실태조사」와 결합이 가능할 경우 자살 고위험군을 예측하는 모형의 성과는 더욱 증가될 수 있을 것으로 보이며 향후 해당 조사가 반복적으로 시행되어 이용 가능한 데이터가 급증할 경우 자살 고위험군 예측 모형의 정확성은 더욱 향상될 것으로 보인다. 이를 위해서는 향후 조사 설계 시 일정 부분의 변수에 대해서는 일치성을 가지는 것이 중요하며 연구자들이 시점이 다른 조사들 간의 병합을 용이하게 할 수 있게 데이터의 가공이 추가적으로 필요해 보인다.

데이터의 양적인 측면이 아닌 변수의 측면에서 살펴본다면 노인 자살 예측의 향상을 위해 노인이 거주하는 상세한 지리적 정보(행정동 단위)의 공개가 중요하다. 이는 지역별 노인 자살률의 편차가 상당히 존재할 수 있기

때문인데 구체적으로 2018년 시·도별 노인(65세 이상) 자살률을 살펴보면 울산의 경우 인구 10만명당 노인 자살률은 37.7명으로 가장 낮았고 세종시의 경우 82.8명으로 아주 높은 수치를 기록하였다(『2020 자살예방백서』, 보건복지부, 2020b).

[그림 V-6] 2018년 시·도별 노인(65세 이상) 자살률

(단위: 인구 십만명당 명)



자료: 보건복지부(2020b), p.44 [그림 16]

다만 해당 지표는 지역 간 노인인구 수의 편차를 고려하고 있지 않기 때문에 극단적으로 해당 지표는 노인인구가 많은 지역이 어디인지를 보여주는 것 이상의 정보를 제공하지 못할 수 있다. 만약 동일하게 높은 노인인구 구성을 가지고 있는 지역 간에 노인자살률에 차이가 발생한다면 지역의 어떤 특성 혹은 정책이 노인자살률 완화에 효과적인지 파악할 수 있어서 노인자살률 예방 관련 정책의 효과성을 높이는 데 활용될 수 있을 것으로 보인다. 추가적으로 기초지자체별로 노인 복지와 관련하여 제공되는 수준의 차이가 존재하므로 동일한 광역지자체 내에서도 노인자살률의 변이가 발생할 가능성이 존재한다.

종합하면, 해당 노인이 사는 지역에 관한 세세한 정보는 자살예측 모형에

중요한 변수로 기능할 가능성이 높다. 또한 획득의 용이성에서 개인들의 지리적 위치는 정부가 쉽게 획득 가능한 행정데이터이기 때문에 지리적 특성에 따라 자살 확률에 유의미한 변화가 발생한다면 해당 변수들을 활용하여 자살 고위험군을 식별하는 것은 노인 자살예방 정책의 비용 효율화를 위해서도 필요하다. 본 연구에서 활용한 「노인실태조사」의 경우 응답자의 자세한 지리적 위치에 대한 정보를 수집하고 있으니 정보의 부정확성과 해당 행정동에 거주하는 관측치가 적다는 이유로 응답자의 행정동 단위의 지리적 정보를 연구자에게 공개하고 있지 않고 있다. 2020년 「노인실태조사」 혹은 그 이후의 조사에서 행정동 단위의 정보를 획득할 수 있다면 행정동과 연계된 다양한 사회경제학 정보를 활용할 수 있기 때문에 자살예측 모형의 성능을 향상시킬 수 있을 것으로 기대된다.

VI. 결론 및 정책적 시사점

본 연구에서는 최근 새로운 실증분석 방법으로 주목을 받고 있는 머신러닝에 대해 개괄하고 정책평가와 설계에서 연구진들의 높은 관심을 끌고 있는 이유는 무엇인지, 그리고 대표적인 머신러닝 알고리즘인 결정트리와 랜덤포레스트에 대해 살펴보았다. 또한, 머신러닝을 활용하여 정책의 효과성 평가를 실시한 주요국의 연구 사례와, 예측 모델을 개발하여 정책 대상자를 선별한 최신의 연구결과들을 정리하여 시사점을 도출하였다.

그다음으로 머신러닝이 정책의 이질적 효과를 살펴보는 데 탁월한 점에 주목하여, 키질포레스트를 활용하여 2019년 수행한 조세특례평가 중, 비과세종합저축을 선정하여 머신러닝을 활용한 정책효과 추정치가 기존 선형회귀를 활용한 정책의 효과성 분석과 비교하여 얼마나 엄밀한 정책 효과성을 도출할 수 있을지를 살펴보았다. 그 결과 기존의 선형 분석과 동일하게 통계적으로 유의미한 저축효과를 찾아 볼 수 없었으나, 좀 더 다양한 특성변수를 조합할 수 있는 머신러닝을 활용하여 가입 대상자별로 정책효과의 예측치를 도출하는, 이질적 처치효과를 탐색해내고, 비과세종합저축의 혜택이 저축여력이 있는 대상을 위주로 집중될 수 있음을 찾아내었다.

마지막으로는 머신러닝을 활용한 재정정책 개선안에 대해 살펴보았다. 머신러닝의 활용으로 기존 노인자살 예방사업에 투입되는 한정된 재정이 좀 더 효과적으로 쓰일 수 있는 방안을 강구하였다. 설문조사 등의 정성평가가 아닌 노인 관련 행정 데이터 등과 머신러닝 알고리즘을 통해 사전적으로 고위험군에 해당하는 사람을 예측하고, 그들에 한정하여 자살예방정책을 실시한다면 정책에 소요되는 비용을 줄일 수 있기 때문에 효율성 측면에서의 개선을 기대할 수 있게 된다. 분석결과, Lasso 모델을 활용한 자살예측 모형은 자살 고위험군에 해당하는 사람을 기존의 모형에 비해 보다 정확하게 예측

하여 행정데이터만을 활용한 고위험군의 식별 가능성을 보여주었다.

최근 새로운 조세·재정정책이 충분한 사전점검 없이 시행되어 시행착오로 인한 사회적 비용이 증가하고 있다. 긴급재난지원금 지원 대상 선정과 관련된 논의에서 볼 수 있듯이, 정책이 의도한 효과를 극대화하기 위해서는 적절한 정책수혜자 선정은 그 무엇보다 중요한 선결과제이며, 머신러닝 방법론은 이러한 점에서 기존 분석보다 진일보한 결과를 제시해 줄 수 있다. 이탈리아의 세금 환급 프로그램의 예시와 본 연구에서 다룬 비과세종합저축 효과성 평가, 노인자살예방정책 사례에서 살펴볼 수 있듯이, 가용한 행정데이터를 활용하여 가장 효과가 좋을 것으로 기대할 수 있는 특정 집단을 선별하여 가용한 자원을 집중한다면 한정된 자원의 누수 없이 정책의 효과를 극대화할 수 있다.

사회관계망 데이터나 대규모 미시행정자료에 대한 접근성이 높아짐에 따라 머신러닝은 기존 분석방법으로는 해결할 수 없는 복잡한 문제에 대한 해결방안을 제시하는 유용한 툴로 각광받고 있다. 머신러닝이 기존 실증분석 방법을 어느 정도까지 근본적으로 바꿔놓을 수 있을지에 대한 논의는 계속 진행 중이며, 이미 정책효과를 예측하는 문제에 뛰어난 성능을 보인만큼, 앞으로 우리나라의 다양한 정책평가와 정책 설계에도 본격적으로 활용될 것을 기대한다.

참고문헌

- 국회예산정책처, 『노인건강분야 사업 분석』, 연구보고서, 2019.
- 국회의안정보시스템, 「2020년도 예산안」, 2020.
- _____, 「2020년도 기금운용계획안」, 2020.
- 권남호, 『넛지(Nudge)를 활용한 공공정책: 현황과 시사점』, 한국조세재정연구원, 2018.
- 권중돈·김유진·엄태영, 「노인돌봄서비스 이용 독거노인의 자살생각에 영향을 미치는 요인에 관한 연구: 자살시도경험과 음주행위와의 관계를 중심으로」, 『노인복지연구』, 51, 2011, pp. 297~320.
- 김동배·박서영, 「노인의 사회관계망 특성과 자살생각 관계: 우울의 매개효과 검증」, 『한국사회복지조사연구』, 24, 2010, pp. 109~129.
- 김형수·권이경, 「한국 노인자살률과 사회·경제적 요인의 관련성: 1990년~2010년 변화 추이를 중심으로」, 『한국콘텐츠학회논문지』, 13(6), 2013, pp. 236~245.
- 김형수·김신향, 「우리나라 노인자살률의 지역적 편차와 요인에 관한 연구: 16개 광역시·도를 중심으로」, 『한국콘텐츠학회논문지』, 14(11), 2014, pp. 215~224.
- 보건복지부 정신건강정책과 보도자료, 「자살예방 국가 행동계획」, 2018. 1. 23., http://www.mohw.go.kr/react/al/sal0301vw.jsp?PAR_MENU_ID=04&MENU_ID=0403&page=44&CONT_SEQ=343649, 접속일자: 2020. 12. 10.
- 보건복지부, 「보건복지부 소관 예산 및 기금운용계획 개요」, 2016~2020.
- _____, 「2020년 세입세출 사업별 설명자료(예산, 기금)」, 2020a.
- _____, 『2020 자살예방백서』, 2020b.
- 서울특별시, 서울특별시 보도자료, 「서울시, ‘신청주의’→‘적극적 발굴주의’

- 어려운 이웃 찾아 나선다」, 2014.3.13., https://www.seoul.go.kr/news/news_report.do#view/19216?tr_code=snews, 접속일자: 2020. 6. 5.
- 서울특별시, 「2019년 서울시 자살예방시행계획」, 2019. 5.
- 여유진 · 오미애 · 이병재 · 최준영 · 김근혜 · 김선 · 정다운, 『2019년 한국복지패널 기초분석 보고서』, 한국보건사회연구원, 2019.
- 오영민 · 박노옥 · 강희우, 『재정사업 사전검증체계 강화를 위한 연구-RCT도 입방안을 중심으로』, 한국조세재정연구원 연구보고서, 2015.
- 윤현숙 · 염소림, 「노인의 우울이 자살생각에 미치는 영향에 대한 가족연대감의 매개효과」, 『한국사회복지학』, 68(1), 2016, pp. 53~71.
- 정재현, 「머신러닝을 활용한 정책설계: 출산결정요인을 중심으로」, 재정포럼 2019년 9월호, 2019. 9.
- 정재현 · 강동익 · 윤성만, 『비과세종합저축에 대한 과세특례』, 2019 조세특례심층평가(I), 기획재정부 · 한국조세재정연구원, 2019.
- 황정우 · 이강욱 · 김정유 · 이동하 · 김두명. 「동거 및 독거노인의 우울이 자살사고에 미치는 영향과 대인관계의 조절효과」, 『정신건강보전과 사회복지』, 45(1), 2017, pp. 36~62.
- Abadie, A., Chingos, M. M., and West, M. R. “Endogenous stratification in randomized experiments,” *Review of Economics and Statistics*, 100(4), 2018, pp. 567~580.
- Andini, Monica, Emanuele Ciani, Guido de Blasio, Alessio D’Ignazio and Viola Salvestrini, “Targeting with machine learning: An application to a tax rebate program in Italy,” *Journal of Economic Behavior and Organization*, 156, 2018, pp. 86~102.
- Angrist, Joshua D., Guido W. Imbens, and Donald B. Rubin, “Identification of Causal Effects Using Instrumental Variables,” *Journal of the American Statistical Association*, 91(434), Jun., 1996, pp. 444~455.
- Athey, S., “Beyond Prediction: Using Big Data for Policy Problems,”

- Science*, Vol. 355, Issue. 6324, 2017, pp. 483~485.
- Athey, S. and Imbens, G. W., "The State of Applied Econometrics: Causality and Policy Evaluation," *Journal of economic perspectives*, 31(2), spring 2017, pp. 3~32.
- Athey, S., J. Tilosshirani and S. Wager, "Generalized random forests," *Annals of Statistics*, 47(2), 2019, pp. 1148~1178.
- Athey, S., J. Tibshirani, and S. Wager. "Generalized random forests". arXiv preprint arXiv:1610.01271, 2017.
- Bettinger, E. P., B. T. Long, P. Oreopoulos, and L. Sanbonmatsu, "The Role of Simplification and Information in College Decisions: Results from the H&R Block FAFSA Experiment," *National Center for Postsecondary Research* 2009.
- Bettinger, E. P., B. T. Long, P. Oreopoulos, and Sanbonmatsu, L. "The role of application assistance and information in college decisions: Results from the H&R Block FAFSA experiment," *The Quarterly Journal of Economics*, 127(3), 2012, pp. 1205~1242.
- Chalfin, A., O. Danieli, A. Hillis, Z. Jelveh, M. Luca, J. Ludwig, and S. Mullainathan, "Productivity and Selection of Human Capital with Machine Learning," *American Economic Review*, Vol. 106, No. 5, 2016, pp. 124~127.
- Chandler Dana, Steven D. Levitt and John A. List, "Predicting and Preventing Shootings among At-Risk Youth," *American Economic Review*, 101(3), 2011, pp. 288~292.
- Chernozhukov, V., M. Demirer, E. Duflo, and I. Fernandez-Val, "Generic Machine Learning Inference on Heterogeneous Treatment Effects in Randomized Experiments," NBER Working Paper No. w 24678, 2018.
- Davis, J. and S. Heller, "Rethinking the Benefits of Youth Employment Programs: The Heterogeneous Effects of Summer Jobs," *Review of*

- Economics and Statistics*, 102(4), 2020, pp. 664~677.
- Duflo, E. "Richard T. Ely lecture: The economist as plumber". *American Economic Review*, 107(5), 2017, pp. 1~26.
- Friedman, J. H., "Greedy function approximation: a gradient boosting machine". *Annals of statistics*, 2001, pp. 1189~1232.
- Gareth, James, Daniel Witten, Trevor Hastie, and Robert Tibshirani, *An Introduction to Statistical Learning with Applications in R*, Springer, 2016.
- Glazerman, Steven, Ira Nichols Barrer, Jon Valant, Jesse Chandler, and Alyson Burnett, "The choice architecture of school choice websites," *journal of research on educational effectiveness*, Vol 13, 2020.
- Guenther, N., and M. Schonlau, "Support vector machines," *The Stata Journal*, 16(4), 2016, pp. 917~937.
- Hemelt, Steven W., Kimberly B. Roth, and William W. Eaton, "Elementary school interventions: experimental evidence on postsecondary outcomes," *Educational Evaluation and Policy Analysis*, Vol. 35, Issue 4, 2013, pp. 413~436.
- Kleinberg, J., H. Lakkaraju, J. Leskovec, J. Ludwig, and S. Mullainathan, "Human Decisions and Machine Predictions," *Quarterly Journal of Economics*, 133(1), 2018, pp. 237~293.
- McBride, L., and A. Nichols, "Improved poverty targeting through machine learning: an application to the USAID poverty assessment tools," Working Paper, 2015.
- Mueller-Smith, M. "The Criminal and Labor Market Impacts of Incarceration," Working paper, 2018.
- Mullainathan, S. and J. Spiess, "Machine Learning: An Applied Econometric Approach," *Journal of Economic Perspectives*, 31(2), 2017, pp. 87~106.
- Pane, John F., Beth Ann Griffin, Daniel F. McCaffrey and Rita Karam,

- “Effectiveness of Cognitive Tutor Algebra I at Scale,” *Educational Evaluation and Policy Analysis*, 2013.
- Rodríguez-Planas, Núria., “Longer-Term Impacts of Mentoring, Educational Services, and Learning Incentives: Evidence from a Randomized Trial in the United States,” *American Economic Journal: Applied Economics*, 4(4), 2012, pp. 121~139.
- Roth Alvin E., Tayfun Sönmez, and M. Utku Ünver, “Kidney Exchange,” *The Quarterly Journal of Economics*, 119(2), May 2004, pp. 457~488.
- Sansone, D., “Beyond early warning indicators: high school dropout and machine learning,” *Oxford Bulletin of Economics and Statistics*, 81(2), 2019, pp. 456~485.
- Schonlau, Matthias, “Boosted Regression(Boosting): An Introductory Tutorial and a Stata Plugin”, *The Stata Journal*, 5(3), 2005, pp. 330~354
- Thaler, Richard H., and Cass R. Sunstein, *Nudge: Improving Decisions about Health, Wealth, and Happiness*, Yale University Press, 2008.
- UNHCR(유엔난민기구), “Global Trends forced displacement in 2019,” 2020.
- Wager, S. and Athey, S., “Estimation and Inference of Heterogeneous Treatment Effects using Random Forests,” *Journal of the American Statistical Association*, 113(523), 2018, pp. 1228~1242.

〈웹문서〉

- 「행정명령 13707」, <https://www.whitehouse.gov/sites/whitehouse.gov/files/images/EO%2013707%20Implementation%20Guidance.pdf>, 접속일자: 2020. 12. 9.
- STATWORX Blog, “Machine Learning Goes Causal II: Meet the Random Forest’s Causal Brother,” <https://www.statworx.com/ch/blog/machine-learning-goes-causal-ii-meet-the-random-forests-causal-brother/>, 접속일자: 2020. 12. 10.

〈통계자료〉

- 보건복지부, 「노인실태조사」, <https://www.data.go.kr/data/15004296/fileData.do>, 접속일자: 2020. 6. 5.
- 서울특별시, 「연도별 예산서」, http://news.seoul.go.kr/gov/archives/category/govdata_c1/budget_c1/data_budget_c1/data_document_budget-n2, 접속일자: 2020. 6. 23.
- 재정정보공개시스템 「열린재정: 재정통계 > 상세재정통계DB > 예산 > 세출/지출 세부사업 예산편성현황(총액)」, <http://www.openfiscaldata.go.kr/portal/main.do>, 접속일자: 2020. 6. 16.
- 중앙자살예방센터, 「국제자살통계」, <https://www.spckorea-stat.or.kr/international01.do>, 접속일자: 2020. 6. 5.
- 통계청, 「가계금융복지조사」, https://www.kostat.go.kr/portal/korea/kor_nw/1/4/4/index.board, 접속일자: 2020. 12. 10.
- _____, 「사망원인통계」, https://www.kostat.go.kr/portal/korea/kor_nw/1/6/2/index.board, 접속일자: 2020. 6. 5.
- _____, 「사회조사」, https://www.kostat.go.kr/portal/korea/kor_nw/1/6/3/index.board, 접속일자: 2020. 6. 5.
- 한국보건사회연구원, 「한국복지패널」, <https://www.koweps.re.kr>, 접속일자: 2020. 6. 5.
- 한국보건산업진흥원, 「국민건강영양조사」, <https://knhanes.cdc.go.kr/knhanes>, 접속일자: 2020. 12. 3.
- 한국여성정책연구원, 「여성가족패널조사」, <https://klowf.kwdi.re.kr>, 접속일자: 2020. 9. 28.

부록

〈부표-1〉 노인자살 위험군 예측 모형 분석 DB의 구성 항목

(2017년 변수명 기준)

변수명	변수특성	구분	변수설명	문항내용
M1	더미/ 범주형	인지기능	인지기능_년	0. 틀림 1. 맞음
M2	더미/ 범주형	인지기능	인지기능_계절	0. 틀림 1. 맞음
M3	더미/ 범주형	인지기능	인지기능_일	0. 틀림 1. 맞음
M4	더미/ 범주형	인지기능	인지기능_요일	0. 틀림 1. 맞음
M5	더미/ 범주형	인지기능	인지기능_월	0. 틀림 1. 맞음
M6	더미/ 범주형	인지기능	인지기능_도/특별시/ 광역시	0. 틀림 1. 맞음
M7	더미/ 범주형	인지기능	인지기능_시/군/구	0. 틀림 1. 맞음
M8	더미/ 범주형	인지기능	인지기능_동/읍/면	0. 틀림 1. 맞음
M9	더미/ 범주형	인지기능	인지기능_현재 위치 (건물 층수)	0. 틀림 1. 맞음
M10	더미/ 범주형	인지기능	인지기능_현 장소 이름	0. 틀림 1. 맞음
M11_1	더미/ 범주형	인지기능	인지기능_나무1	0. 틀림 1. 맞음
M11_2	더미/ 범주형	인지기능	인지기능_자동차1	0. 틀림 1. 맞음
M11_3	더미/ 범주형	인지기능	인지기능_모자1	0. 틀림 1. 맞음
M12_1	더미/ 범주형	인지기능	인지기능_빨셈1	0. 틀림 1. 맞음
M12_2	더미/ 범주형	인지기능	인지기능_빨셈2	0. 틀림 1. 맞음

변수명	변수특성	구분	변수설명	문항내용
M12_3	더미/ 범주형	인지기능	인지기능_빨셈3	0. 틀림 1. 맞음
M12_4	더미/ 범주형	인지기능	인지기능_빨셈4	0. 틀림 1. 맞음
M12_5	더미/ 범주형	인지기능	인지기능_빨셈5	0. 틀림 1. 맞음
M13_1	더미/ 범주형	인지기능	인지기능_나무2	0. 틀림 1. 맞음
M13_2	더미/ 범주형	인지기능	인지기능_자동차2	0. 틀림 1. 맞음
M13_3	더미/ 범주형	인지기능	인지기능_모자2	0. 틀림 1. 맞음
M14_1	더미/ 범주형	인지기능	인지기능_시계	0. 틀림 1. 맞음
M14_2	더미/ 범주형	인지기능	인지기능_연필	0. 틀림 1. 맞음
M15	더미/ 범주형	인지기능	인지기능_ 간장공장공장장	0. 틀림 1. 맞음
M16_1	더미/ 범주형	인지기능	인지기능_ 오른손으로 받기	0. 틀림 1. 맞음
M16_2	더미/ 범주형	인지기능	인지기능_반으로 접기	0. 틀림 1. 맞음
M16_3	더미/ 범주형	인지기능	인지기능_ 무릎 위에 놓기	0. 틀림 1. 맞음
M17	더미/ 범주형	인지기능	인지기능_오각형 그리기	0. 틀림 1. 맞음
M18	더미/ 범주형	인지기능	인지기능_옷을 빨아입는 이유	0. 틀림 1. 맞음
M19	더미/ 범주형	인지기능	인지기능_ 티끌 모아 태산의 뜻	0. 틀림 1. 맞음
p1_ga_no	더미/ 범주형	가구 일반사항	응답자1_가구원번호	
p1_type2	더미/ 범주형	가구 일반사항	응답자1_ 대상자와의 관계	조사매뉴얼 <별첨 1> 참조
p2_ga_no	더미/ 범주형	가구 일반사항	응답자2_가구원 번호	
noin_ga	더미/ 범주형	가구 일반사항	노인(만 65세 이상) 가구원 수	실수
noin_josa	더미/ 범주형	가구 일반사항	조사완료 노인 수	실수

변수명	변수특성	구분	변수설명	문항내용
ga_h	더미/ 범주형	가구 일반사항	노인가구 형태	조사매뉴얼 <별첨 2> 참조
A3_ga1	더미/ 범주형	가구 일반사항	1번가구원의 성별	1. 남자 2. 여자
A4_1_m_ga1	더미/ 범주형	가구 일반사항	1번가구원의 생월	실수
A5_ga1	더미/ 범주형	가구 일반사항	1번가구원의 혼인상태	1. 미혼 2. 유배우(기혼) 3. 사별(기혼) 4. 이혼(기혼) 5. 별거(기혼) 6. 기타 7. 사망 9. 비해당(만 14세 이하)
A6_1_ga1	더미/ 범주형	가구 일반사항	1번가구원의 교육수준	0. 미취학 (만 10세 이하의 미취학자) 1. 무학(글자모름) 2. 무학(글자해독) 3. 초등학교 4. 중학교 5. 고등학교 6. 대학(4년 미만) 7. 대학교 이상
A7_ga1	더미/ 범주형	가구 일반사항	1번가구원의 취업여부	1. 예 2. 아니오 9. 비해당(만 14세 이하)
A8_ga1	더미/ 범주형	가구 일반사항	1번가구원의 응답 노인과의 관계 코드	조사매뉴얼 <별첨 1> 참조
A9_ga1	더미/ 범주형	가구 일반사항	1번가구원의 노인 대상자 확인	0. 비대상자(만 64세 이하) 1. 노인조사 대상자이면서 (만 65세 이상) 조사완료 2. 노인조사 대상자이지만 (만 65세 이상) 조사미완 3. 대리응답 4. A9-1의1.~3.에 해당하는 대리응답 대상이지만 조사 미완 5. 사망
ga_no2	더미/ 범주형	가구 일반사항	2번가구원의 가구원번호	실수
A2_ga2	더미/ 범주형	가구 일반사항	2번가구원의 가구주와의 관계 코드	조사매뉴얼 <별첨 3> 참조

변수명	변수특성	구분	변수설명	문항내용
A3_ga2	더미/ 범주형	가구 일반사항	2번가구원의 성별	1. 남자 2. 여자
A4_1_m_ga2	더미/ 범주형	가구 일반사항	2번가구원의 생월	실수
A5_ga2	더미/ 범주형	가구 일반사항	2번가구원의 혼인상태	1. 미혼 2. 유배우(기혼) 3. 사별(기혼) 4. 이혼(기혼) 5. 별거(기혼) 6. 기타 7. 사망 9. 비해당(만 14세 이하)
A6_1_ga2	더미/ 범주형	가구 일반사항	2번가구원의 교육수준	0. 미취학 (만 10세 이하의 미취학자) 1. 무학(글자모름) 2. 무학(글자해독) 3. 초등학교 4. 중학교 5. 고등학교 6. 대학(4년 미만) 7. 대학교 이상
A7_ga2	더미/ 범주형	가구 일반사항	2번가구원의 취업여부	1. 예 2. 아니오 9. 비해당(만 14세 이하)
A8_ga2	더미/ 범주형	가구 일반사항	2번가구원의 응답 노인과의 관계 코드	조사매뉴얼 <별첨 1> 참조
A9_ga2	더미/ 범주형	가구 일반사항	2번가구원의 노인 대상자 확인	0. 비대상자(만 64세 이하) 1. 노인조사 대상자이면서 (만 65세 이상) 조사완료 2. 노인조사 대상자이지만 (만 65세 이상) 조사미완 3. 대리응답 4. A9-1의1.~3.에 해당하는 대리응답 대상이지만 조사 미완 5. 사망
ga_no3	더미/ 범주형	가구 일반사항	3번가구원의 가구원번호	실수
A2_ga3	더미/ 범주형	가구 일반사항	3번가구원의 가구주와의 관계 코드	조사매뉴얼 <별첨 3> 참조
A3_ga3	더미/ 범주형	가구 일반사항	3번가구원의 성별	1. 남자 2. 여자

변수명	변수특성	구분	변수설명	문항내용
A4_1_m_ga3	더미/ 범주형	가구 일반사항	3번가구원의 생월	실수
A5_ga3	더미/ 범주형	가구 일반사항	3번가구원의 혼인상태	1. 미혼 2. 유배우(기혼) 3. 사별(기혼) 4. 이혼(기혼) 5. 별거(기혼) 6. 기타 7. 사망 9. 비해당(만 14세 이하)
A6_1_ga3	더미/ 범주형	가구 일반사항	3번가구원의 교육수준	0. 미취학 (만 10세 이하의 미취학자) 1. 무학(글자모름) 2. 무학(글자해독) 3. 초등학교 4. 중학교 5. 고등학교 6. 대학(4년 미만) 7. 대학교 이상
A7_ga3	더미/ 범주형	가구 일반사항	3번가구원의 취업여부	1. 예 2. 아니오 9. 비해당(만 14세 이하)
A8_ga3	더미/ 범주형	가구 일반사항	3번가구원 응답 노인과의 관계 코드	조사매뉴얼 <별첨 1> 참조
A9_ga3	더미/ 범주형	가구 일반사항	3번가구원의 노인 대상자 확인	0. 비대상자(만 64세 이하) 1. 노인조사 대상자이면서 (만 65세 이상) 조사완료 2. 노인조사 대상자이지만 (만 65세 이상) 조사미완 3. 대리응답 4. A9-1의1.~3.에 해당하는 대리응답 대상이지만 조사 미완 5. 사망
B1	더미/ 범주형	건강상태	평소의 건강상태	1. 매우 건강하다 2. 건강한 편이다 3. 그저 그렇다 4. 건강이 나쁜 편이다 5. 건강이 매우 나쁘다
B2_1_1	더미/ 범주형	건강상태	의사진단 여부_고혈압	1. 예 2. 아니요

변수명	변수특성	구분	변수설명	문항내용
B2_2_1	더미/ 범주형	건강상태	치료 여부_고혈압	1. 예 2. 아니요
B2_1_2	더미/ 범주형	건강상태	의사진단 여부_뇌졸중 (중풍, 뇌경색)	1. 예 2. 아니요
B2_2_2	더미/ 범주형	건강상태	치료 여부_뇌졸중 (중풍, 뇌경색)	1. 예 2. 아니요
B2_1_3	더미/ 범주형	건강상태	의사진단 여부_ 고지혈증	1. 예 2. 아니요
B2_2_3	더미/ 범주형	건강상태	치료 여부_고지혈증	1. 예 2. 아니요
B2_1_4	더미/ 범주형	건강상태	의사진단 여부_ 협심증, 심근경색증	1. 예 2. 아니요
B2_2_4	더미/ 범주형	건강상태	치료 여부_ 협심증, 심근경색증	1. 예 2. 아니요
B2_1_5	더미/ 범주형	건강상태	의사진단 여부_ 기타 심장질환	1. 예 2. 아니요
B2_2_5	더미/ 범주형	건강상태	치료 여부_ 기타 심장질환	1. 예 2. 아니요
B2_1_6	더미/ 범주형	건강상태	의사진단 여부_당뇨병	1. 예 2. 아니요
B2_2_6	더미/ 범주형	건강상태	치료 여부_당뇨병	1. 예 2. 아니요
B2_1_7	더미/ 범주형	건강상태	의사진단 여부_ 갑상선 질환	1. 예 2. 아니요
B2_1_8	더미/ 범주형	건강상태	의사진단 여부_ 골관절염 또는 류머티즘 관절염	1. 예 2. 아니요
B2_2_8	더미/ 범주형	건강상태	치료 여부_골관절염 또는 류머티즘 관절염	1. 예 2. 아니요
B2_1_9	더미/ 범주형	건강상태	의사진단 여부_ 골다공증	1. 예 2. 아니요
B2_2_9	더미/ 범주형	건강상태	치료 여부_골다공증	1. 예 2. 아니요
B2_1_10	더미/ 범주형	건강상태	의사진단 여부_ 요통, 좌골신경통	1. 예 2. 아니요
B2_2_10	더미/ 범주형	건강상태	치료 여부_요통, 좌골신경통	1. 예 2. 아니요
B2_1_11	더미/ 범주형	건강상태	의사진단 여부_ 만성기관지염, 폐기종 (COPD)	1. 예 2. 아니요

변수명	변수특성	구분	변수설명	문항내용
B2_1_12	더미/ 범주형	건강상태	의사진단 여부_천식	1. 예 2. 아니요
B2_1_13	더미/ 범주형	건강상태	의사진단 여부_ 폐결핵, 결핵	1. 예 2. 아니요
B2_1_14	더미/ 범주형	건강상태	의사진단 여부_백내장	1. 예 2. 아니요
B2_2_14	더미/ 범주형	건강상태	치료 여부_백내장	1. 예 2. 아니요
B2_1_15	더미/ 범주형	건강상태	의사진단 여부_녹내장	1. 예 2. 아니요
B2_1_16	더미/ 범주형	건강상태	의사진단 여부_ 만성중이염	1. 예 2. 아니요
B2_1_17	더미/ 범주형	건강상태	의사진단 여부_ 암(악성신생물)	1. 예 2. 아니요
B2_1_18	더미/ 범주형	건강상태	의사진단 여부_ 위 및 십이지장궤양	1. 예 2. 아니요
B2_2_18	더미/ 범주형	건강상태	치료 여부_ 위 및 십이지장궤양	1. 예 2. 아니요
B2_1_19	더미/ 범주형	건강상태	의사진단 여부_간염	1. 예 2. 아니요
B2_1_20	더미/ 범주형	건강상태	의사진단 여부_간경변	1. 예 2. 아니요
B2_1_22	더미/ 범주형	건강상태	의사진단 여부_ 전립선비대증	1. 예 2. 아니요
B2_2_22	더미/ 범주형	건강상태	치료 여부_ 전립선비대증	1. 예 2. 아니요
B2_1_23	더미/ 범주형	건강상태	의사진단 여부_요실금	1. 예 2. 아니요
B2_1_24	더미/ 범주형	건강상태	의사진단 여부_ 성병(매독 등)	1. 예 2. 아니요
B2_1_25	더미/ 범주형	건강상태	의사진단 여부_빈혈	1. 예 2. 아니요
B2_1_26	더미/ 범주형	건강상태	의사진단 여부_피부병	1. 예 2. 아니요
B2_1_27	더미/ 범주형	건강상태	의사진단 여부_우울증	1. 예 2. 아니요
B2_1_28	더미/ 범주형	건강상태	의사진단 여부_치매	1. 예 2. 아니요
B2_1_29	더미/ 범주형	건강상태	의사진단 여부_골절, 탈골 및 사고 후유증	1. 예 2. 아니요

변수명	변수특성	구분	변수설명	문항내용
B2_1_32	더미/ 범주형	건강상태	의사진단 여부_기타	1. 예 2. 아니요
B2_2_32	더미/ 범주형	건강상태	치료 여부_기타	1. 예 2. 아니요
B4	더미/ 범주형	건강상태	지난 1개월 동안 의료기관 이용 여부	1. 예 2. 아니요
B5	더미/ 범주형	건강상태	지난 1년 간 병원 입원 여부	1. 예 2. 아니요
B6_1	더미/ 범주형	건강상태	우울증척도_ 현재생활 만족	1. 예 2. 아니요
B6_2	더미/ 범주형	건강상태	우울증척도_의욕저하	1. 예 2. 아니요
B6_3	더미/ 범주형	건강상태	우울증척도_헛된 느낌	1. 예 2. 아니요
B6_4	더미/ 범주형	건강상태	우울증척도_지루함	1. 예 2. 아니요
B6_5	더미/ 범주형	건강상태	우울증척도_상쾌함	1. 예 2. 아니요
B6_6	더미/ 범주형	건강상태	우울증척도_불안함	1. 예 2. 아니요
B6_7	더미/ 범주형	건강상태	우울증척도_ 마음의 즐거움	1. 예 2. 아니요
B6_8	더미/ 범주형	건강상태	우울증척도_ 절망적 느낌	1. 예 2. 아니요
B6_9	더미/ 범주형	건강상태	우울증척도_ 나가기 싫음	1. 예 2. 아니요
B6_10	더미/ 범주형	건강상태	우울증척도_기억력 나쁨(동년배 비교)	1. 예 2. 아니요
B6_11	더미/ 범주형	건강상태	우울증척도_ 살아있음에 대한 즐거움	1. 예 2. 아니요
B6_12	더미/ 범주형	건강상태	우울증척도_쓸모없음	1. 예 2. 아니요
B6_13	더미/ 범주형	건강상태	우울증척도_기력줄음	1. 예 2. 아니요
B6_14	더미/ 범주형	건강상태	우울증척도_희망없음	1. 예 2. 아니요
B6_15	더미/ 범주형	건강상태	우울증척도_다른사람들 보다 처지가 더 못함	1. 예 2. 아니요
C1	더미/ 범주형	건강행태	현재 흡연 여부	1. 예(현재 피움) 2. 아니요

변수명	변수특성	구분	변수설명	문항내용
C2	더미/ 범주형	건강행태	지난 1년간 음주 빈도	0. 최근 1년간 전혀 마시지 않았다 1. 연1회 이상~12회 미만 2. 한달에 1회 정도 3. 한달에 2~3회 정도 4. 일주일에 1회 정도 5. 일주일에 2~3회 정도 6. 일주일에 4~6회 정도 7. 매일
C3	더미/ 범주형	건강행태	평소 운동 여부	1. 예 2. 아니요
C4_1_1	더미/ 범주형	건강행태	몸무게 측정 여부	1. 측정 2. 미측정
C4_2_1	더미/ 범주형	건강행태	키 측정 여부	1. 측정 2. 미측정
C5_1	더미/ 범주형	건강행태	영양관리_음식의 양, 종류 조절	1. 예 2. 아니요
C5_2	더미/ 범주형	건강행태	영양관리_하루 2끼 미만	1. 예 2. 아니요
C5_3_1	더미/ 범주형	건강행태	영양관리_과일 미섭취	1. 예 2. 아니요
C5_4	더미/ 범주형	건강행태	영양관리_거의 매일 3잔 이상의 술	1. 예 2. 아니요
C5_5	더미/ 범주형	건강행태	영양관리_구강상태에 따른 음식섭취 어려움	1. 예 2. 아니요
C5_6	더미/ 범주형	건강행태	영양관리_금전상태에 따른 음식구입 어려움	1. 예 2. 아니요
C5_7	더미/ 범주형	건강행태	영양관리_거의 매번 혼자 식사함	1. 예 2. 아니요
C5_8	더미/ 범주형	건강행태	영양관리_하루에 3가지 이상의 서로 다른 약 복용	1. 예 2. 아니요
C5_9	더미/ 범주형	건강행태	영양관리_지난 6개월간 의도치 않은 5kg 이상의 체중변화	1. 예 2. 아니요
C5_10	더미/ 범주형	건강행태	영양관리_장보기, 음식만들기, 식사 감당 어려움	1. 예 2. 아니요
C6_1	더미/ 범주형	건강행태	경로식당 이용	0. 전혀 이용하지 않았다 1. 거의 매일(주 4회 이상) 2. 일주일에 2~3회 정도

변수명	변수특성	구분	변수설명	문항내용
				3. 일주일에 1회 정도 4. 한달에 1~2회 정도 5. 3개월에 1~2회 정도 6. 1년에 1~2회 정도
C6_2	더미/ 범주형	건강행태	식사배달서비스 이용	0. 전혀 이용하지 않았다 1. 거의 매일(주4회 이상) 2. 일주일에 2~3회 정도 3. 일주일에 1회 정도 4. 한달에 1~2회 정도 5. 3개월에 1~2회 정도 6. 1년에 1~2회 정도
C7_1	더미/ 범주형	건강행태	지난 2년간 건강검진 여부(치매검진 제외)	1. 예 2. 아니요
C8_a	더미/ 범주형	건강행태	지난 1년간 병의원 진료 못 받은 경험	1. 예 2. 아니요
C8_b	더미/ 범주형	건강행태	지난 1년간 치과 진료 못 받은 경험	1. 예 2. 아니요
D1-1	더미/ 범주형	기능상태와 간병수발	보조기 사용 여부_시력	1. 예(사용) 2. 아니요(미사용)
D1-2	더미/ 범주형	기능상태와 간병수발	일상생활의 불편함_ 시력	1. 불편하지 않다 2. 불편한 편이다 3. 매우 불편하다
D2-1	더미/ 범주형	기능상태와 간병수발	보조기 사용 여부_청력	1. 예(사용) 2. 아니요(미사용)
D2-2	더미/ 범주형	기능상태와 간병수발	일상생활의 불편함_ 청력	1. 불편하지 않다 2. 불편한 편이다 3. 매우 불편하다
D3-1	더미/ 범주형	기능상태와 간병수발	보조기 사용 여부_씹기	1. 예(사용) 2. 아니요(미사용)
D3-2	더미/ 범주형	기능상태와 간병수발	일상생활의 불편함_씹기	1. 불편하지 않다 2. 불편한 편이다 3. 매우 불편하다
D4	더미/ 범주형	기능상태와 간병수발	근력상태_의자나 침대에 앉았다가 일어나기 5회 반복	1. 수행함 2. 시도했으나, 수행못함(5회 못한 경우) 3. 수행시도조차 못하는 상태 (와상노인, 기타장애로 일어서기가 불가능한 경우)
D5_1	더미/ 범주형	기능상태와 간병수발	동작수행 어려움_ 운동장 한 바퀴(400m) 정도 뛰기	1. 전혀 어렵지 않다 2. 약간 어렵다 3. 매우 어렵다

변수명	변수특성	구분	변수설명	문항내용
				4. 전혀 할 수 없다 5. 모르겠다
D5_2	더미/ 범주형	기능상태와 간병수발	동작수행 어려움_ 운동장 한 바퀴(400m) 정도 걷기	1. 전혀 어렵지 않다 2. 약간 어렵다 3. 매우 어렵다 4. 전혀 할 수 없다 5. 모르겠다
D5_3	더미/ 범주형	기능상태와 간병수발	동작수행 어려움_ 쉬지않고 10계단 오르기	1. 전혀 어렵지 않다 2. 약간 어렵다 3. 매우 어렵다 4. 전혀 할 수 없다 5. 모르겠다
D5_4	더미/ 범주형	기능상태와 간병수발	동작수행 어려움_ 몸 구부리거나 꾸그려 앉거나 무릎 꿇기	1. 전혀 어렵지 않다 2. 약간 어렵다 3. 매우 어렵다 4. 전혀 할 수 없다 5. 모르겠다
D5_5	더미/ 범주형	기능상태와 간병수발	동작수행 어려움_ 머리보다 높은 곳에 있는 것 손 뻗쳐 닿기	1. 전혀 어렵지 않다 2. 약간 어렵다 3. 매우 어렵다 4. 전혀 할 수 없다 5. 모르겠다
D5_6	더미/ 범주형	기능상태와 간병수발	동작수행 어려움_ 쌀 1말(8kg) 정도 물건 들어 올리거나 옮기기	1. 전혀 어렵지 않다 2. 약간 어렵다 3. 매우 어렵다 4. 전혀 할 수 없다 5. 모르겠다
D6_1	더미/ 범주형	기능상태와 간병수발	ADL_옷입기(옷 꺼내기, 단추, 지퍼, 벨트)	1. 완전 자립 2. 부분 도움 3. 완전 도움
D6_2	더미/ 범주형	기능상태와 간병수발	ADL_세수, 양치질, 머리감기	1. 완전 자립 2. 부분 도움 3. 완전 도움
D6_3	더미/ 범주형	기능상태와 간병수발	ADL_목욕 또는 샤워하기(욕조 드나들기, 때밀기, 샤워)	1. 완전 자립 2. 부분 도움 3. 완전 도움
D6_4	더미/ 범주형	기능상태와 간병수발	ADL_차려 놓은 음식 먹기	1. 완전 자립 2. 부분 도움 3. 완전 도움
D6_5	더미/ 범주형	기능상태와 간병수발	ADL_누웠다 일어나 방 밖으로 나가기	1. 완전 자립 2. 부분 도움 3. 완전 도움

변수명	변수특성	구분	변수설명	문항내용
D6_6	더미/ 범주형	기능상태와 간병수발	ADL_화장실 출입과 대소변 후 닦고 옷 입기	1. 완전 자립 2. 부분 도움 3. 완전 도움
D6_7	더미/ 범주형	기능상태와 간병수발	ADL_대소변 조절하기	1. 완전 자립 2. 부분 도움 3. 완전 도움
D7_1	더미/ 범주형	기능상태와 간병수발	IADL_몸단장(빛질, 화장, 면도, 손톱/ 발톱 깎기)	1. 완전 자립 2. 부분 도움 3. 완전 도움
D7_2	더미/ 범주형	기능상태와 간병수발	IADL_집안일(실내청소, 설거지, 침구정리, 집안 정리정돈 등)	1. 완전 자립 2. 부분 도움 3. 완전 도움
D7_3	더미/ 범주형	기능상태와 간병수발	IADL_식사준비 (음식재료준비, 요리, 상 차리기)	1. 완전 자립 2. 부분 도움 3. 완전 도움
D7_4	더미/ 범주형	기능상태와 간병수발	IADL_빨래(손이나 세탁기로 세탁 후 늘어 말리기 포함)	1. 완전 자립 2. 부분 도움 3. 완전 도움
D7_5	더미/ 범주형	기능상태와 간병수발	IADL_제시간에 정해진 양의 약 챙겨먹기	1. 완전 자립 2. 부분 도움 3. 완전 도움
D7_6	더미/ 범주형	기능상태와 간병수발	IADL_금전관리(용돈, 통장관리, 재산관리)	1. 완전 자립 2. 부분 도움 3. 완전 도움
D7_7	더미/ 범주형	기능상태와 간병수발	IADL_근거리 외출하기 (가까운 거리 걸어서)	1. 완전 자립 2. 부분 도움 3. 완전 도움
D7_8	더미/ 범주형	기능상태와 간병수발	IADL_물건 구매 결정, 돈 지불, 거스름돈 받기	1. 완전 자립 2. 적은 부분 도움 3. 많은 부분 도움 4. 완전 도움
D7_9	더미/ 범주형	기능상태와 간병수발	IADL_전화 걸고 받기	1. 완전 자립 2. 적은 부분 도움 3. 많은 부분 도움 4. 완전 도움
D7_10	더미/ 범주형	기능상태와 간병수발	IADL_교통수단 이용하기 (대중교통, 개인 차)	1. 완전 자립 2. 적은 부분 도움 3. 많은 부분 도움 4. 완전 도움
D8	더미/ 범주형	기능상태와 간병수발	일상생활 수행에 있어 도움받음 여부	1. 예 2. 아니요

변수명	변수특성	구분	변수설명	문항내용
D8_1_3	더미/ 범주형	기능상태와 간병수발	도움주체_친척, 이웃 친구 지인	1. 도움 받음 2. 도움 받지 않음
D8_1_4	더미/ 범주형	기능상태와 간병수발	도움주체_ 개인 간병인이나 가사도우미(파출부)	1. 도움 받음 2. 도움 받지 않음
D8_1_5	더미/ 범주형	기능상태와 간병수발	도움주체_장기요양보험 서비스(요양보호사 등)	1. 도움 받음 2. 도움 받지 않음
D8_1_6	더미/ 범주형	기능상태와 간병수발	도움주체_노인돌봄서비스 (가사간병서비스 등 각종 공공 돌봄서비스)	1. 도움 받음 2. 도움 받지 않음
D9	더미/ 범주형	기능상태와 간병수발	노인장기요양보험 등급 신청 경험 유무	1. 예 2. 아니요
D9_2	더미/ 범주형	기능상태와 간병수발	장기요양 등급 미신청 이유	0. 건강이 양호해서(도움이 필요 없어서) 1. 노인장기요양보험에 대해 알지 못해서 2. 건강상태가 불량하지만 등급인정을 받지 못할 것 같아서 3. 타인의 도움을 받고 싶지 않아서 4. 비용이 부담될 것 같아서 5. 노인요양시설보다 요양 병원에 입원하는 것이 더 낫다고 생각해서 6. 장기요양보험에는 원하는 서비스가 없어서 7. 현재 이용하는 서비스(재가 돌봄서비스 개인적으로 이용 하는 서비스 등)로 충분해서 8. 기타
E1	더미/ 범주형	여가활동과 사회활동	지난 1년간 TV시청 및 라디오 청취 여부	1. 예 2. 아니요
E3_1_1	더미/ 범주형	여가활동과 사회활동	주요하는 여가문화활동 1순위	조사매뉴얼 <별첨 7> 참조
E3_1_2	더미/ 범주형	여가활동과 사회활동	주요하는 여가문화활동 2순위	조사매뉴얼 <별첨 7> 참조
E5	더미/ 범주형	여가활동과 사회활동	지난 1년간 평생교육 참여 여부	1. 예 2. 아니요
E5_1	더미/ 범주형	여가활동과 사회활동	평생교육 참여 영역	1. 건강관리(증진)/운동 관련 교육 2. 문화예술(춤/가요/음악)

변수명	변수특성	구분	변수설명	문항내용
				관련교육 3. 여학교육 4. 인문학(시/수필)교육 5. 정보화교육 6. 취업교육과직업교육 7. 기타
E5_2	더미/ 범주형	여가활동과 사회활동	평생교육 실시 기관	1. 노인(종합)복지관/센터(노인 여가복지시설) 2. 경로당 3. 대한노인회운영 노인교실 (대학) 4. 종교기관운영 노인교실 (대학) 5. 시/군구민회관,주민센터 6. 초/중/고/대학교 7. 공공문화센터((종합) 사회 복지관, 여성회관, 문화예술 회관, 도서관, 박물관 등) 8. 사설문화센터 (백화점, 신문사, 방송사 등), 학원 9. 장소에 구애받지 않고 매체 활용(TV/라디오/인터넷강좌, 컴퓨터/인터넷활용학습, 책/전문잡지 등 인쇄매체) 10. 기타
E5_3	더미/ 범주형	여가활동과 사회활동	평생교육 참여 빈도	1. 주 4회 이상 2. 주 2~3회 3. 주 1회 4. 2주 1회 5. 월 1회 6. 월 1회 미만
E6_a	더미/ 범주형	여가활동과 사회활동	동호회(클럽활동)_ 참여 여부	1. 예 2. 아니요
E6_b	더미/ 범주형	여가활동과 사회활동	친목단체_참여 여부	1. 예 2. 아니요
E6_1_b	더미/ 범주형	여가활동과 사회활동	친목단체_참여 빈도	1. 주 4회 이상 2. 주 2~3회 3. 주 1회 4. 2주 1회 5. 월 1회 6. 월 1회 미만
E6_c	더미/ 범주형	여가활동과 사회활동	정치사회단체_ 참여 여부	1. 예 2. 아니요

변수명	변수특성	구분	변수설명	문항내용
E7	더미/ 범주형	여가활동과 사회활동	자원봉사활동 경험 유무	1. 현재 하고 있음 2. 과거에 한 적은 있으나, 현재는 하고 있지 않음 3. 평생 한 적이 없음
E9	더미/ 범주형	여가활동과 사회활동	종교 종류	0. 없음 1. 불교 2. 개신교(기독교) 3. 천주교 4. 유교 5. 원불교 6. 기타
E10_1	더미/ 범주형	여가활동과 사회활동	향후 활동희망_ 자원봉사활동	1. 반드시 하고 싶음 2. 될 수 있으면 하고 싶음 3. 기회가 되면 할 생각이 있음 4. 별로 할 생각이 없음 5. 전혀 할 생각이 없음
E10_2	더미/ 범주형	여가활동과 사회활동	향후 활동희망_ 학습활동	1. 반드시 하고 싶음 2. 될 수 있으면 하고 싶음 3. 기회가 되면 할 생각이 있음 4. 별로 할 생각이 없음 5. 전혀 할 생각이 없음
E10_3	더미/ 범주형	여가활동과 사회활동	향후 활동희망_ 취미여가활동	1. 반드시 하고 싶음 2. 될 수 있으면 하고 싶음 3. 기회가 되면 할 생각이 있음 4. 별로 할 생각이 없음 5. 전혀 할 생각이 없음
E10_4	더미/ 범주형	여가활동과 사회활동	향후 활동희망_ 종교활동	1. 반드시 하고 싶음 2. 될 수 있으면 하고 싶음 3. 기회가 되면 할 생각이 있음 4. 별로 할 생각이 없음 5. 전혀 할 생각이 없음
E10_5	더미/ 범주형	여가활동과 사회활동	향후 활동희망_ 정치사회단체활동	1. 반드시 하고 싶음 2. 될 수 있으면 하고 싶음 3. 기회가 되면 할 생각이 있음 4. 별로 할 생각이 없음 5. 전혀 할 생각이 없음
E10_6	더미/ 범주형	여가활동과 사회활동	향후 활동희망_ 친목단체활동	1. 반드시 하고 싶음 2. 될 수 있으면 하고 싶음 3. 기회가 되면 할 생각이 있음 4. 별로 할 생각이 없음 5. 전혀 할 생각이 없음

변수명	변수특성	구분	변수설명	문항내용
E11_1	더미/ 범주형	여가활동과 사회활동	경로당_지난 1년 간 이용 여부	1. 예 2. 아니요
E11_3_1	더미/ 범주형	여가활동과 사회활동	경로당_이용 만족도	1. 매우 만족한다 2. 만족한다 3. 그저 그렇다 4. 만족하지 않는다 5. 전혀 만족하지 않는다
E12_1	더미/ 범주형	여가활동과 사회활동	경로당_향후(계속) 이용 여부	1. 이용하겠다 2. 이용하지 않겠다
E11_2	더미/ 범주형	여가활동과 사회활동	노인복지관_지난 1년간 이용 여부	1. 예 2. 아니요
E11_2_2_ a	더미/ 범주형	여가활동과 사회활동	노인복지관_이용하는 주된 이유(1순위)	1. 평생교육프로그램 이용 2. 취미여가프로그램 이용 3. 건강증진프로그램 이용 4. 식사서비스 이용 5. 주간보호 등 돌봄관련 서비스 이용 6. 상담, 정서지원프로그램 이용 7. 일자리, 소득지원프로그램 이용 8. 자원봉사활동참여 9. 친목도모 10. 기타
E11_3_2	더미/ 범주형	여가활동과 사회활동	노인복지관_ 이용 만족도	1. 매우 만족한다 2. 만족한다 3. 그저 그렇다 4. 만족하지 않는다 5. 전혀 만족하지 않는다
E12_2	더미/ 범주형	여가활동과 사회활동	노인복지관_향후(계속) 이용 여부	1. 이용하겠다 2. 이용하지 않겠다
F1	더미/ 범주형	경제활동	현재 경제활동 여부	1. 현재 일한다 2. 일한 경험은 있으나, 지금은 하지 않는다 3. 평생 일을 하지 않았다
F1_1	더미/ 범주형	경제활동	현재 일_직업중분류	조사매뉴얼 <별첨 8> 참조
F1_2	더미/ 범주형	경제활동	현재 일_일의 내용	1. 농림어업 2. 경비/수위/시설관리 3. 청소업무 4. 생산작업 5. 가사돌봄 6. 운전/운송

변수명	변수특성	구분	변수설명	문항내용
				7. 전문직 8. 행정사무 9. 조리/음식업 10. 택배/배달 11. 현장관리 12. 환경/조경 13. 건설/기계 14. 문화예술 15. 공공질서유지 16. 폐휴지수거 17. 기타
F1_3	더미/ 범주형	경제활동	현재 일_종사상 지위	1. 상용근로자 2. 임시근로자 3. 일용근로자 4. 고용주 5. 자영업자 6. 무급가족종사자 7. 특수형태근로종사자 8. 기타
F1_3_1	더미/ 범주형	경제활동	현재 일_ 정부지원일자리 여부	1. 예 2. 아니요
F1_4	더미/ 범주형	경제활동	현재 일_기관	1. 사업체 아님(농림어업) 2. 개인사업체(가게) 3. 민간회사 4. 중앙/지방정부 또는 기타 공공기관 5. 비영리법인, 시민단체 또는 종교단체 6. 특정한 회사나 사업체에 소속되어 있지 않음 7. 정식으로 등록되지 않은 사업체 8. 기타
F1_8	더미/ 범주형	경제활동	현재 일_일하는 가장 큰 이유	1. 생계비 마련 2. 용돈이 필요해서 3. 건강유지를 위해 4. 사람들과 사귄 수 있으므로 5. 시간을 보내기 위해 6. 능력을 발휘하기 위해 7. 경력을 활용하기 위해 8. 기타
F1_9	더미/ 범주형	경제활동	현재 일_만족도	1. 매우 만족한다 2. 만족한다

변수명	변수특성	구분	변수설명	문항내용
				3. 그저 그렇다 4. 만족하지 않는다 5. 전혀 만족하지 않는다
F1_10	더미/ 범주형	경제활동	현재 일_최장기 종사직업 여부	1. 예 2. 아니요
F2	더미/ 범주형	경제활동	최장기 일자리_ 직업종분류	조사매뉴얼 <별첨 8> 참조
F2_1	더미/ 범주형	경제활동	최장기 일자리_ 종사상 지위	1. 상용근로자 2. 임시근로자 3. 일용근로자 4. 고용주 5. 자영업자 6. 무급가족종사자 7. 특수형태근로종사자 8. 기타
F2_1_1	더미/ 범주형	경제활동	최장기 일자리_ 정부지원일자리 여부	1. 예 2. 아니요
F2_3	더미/ 범주형	경제활동	최장기 일자리_일을 그만둔 이유	1. 정년퇴직 2. 건강이 좋지 않아서 3. 정리해고, 명예퇴직, 폐업, 휴업 4. 가사문제(육아,가사,간병) 5. 근로조건 및 환경이 나빠서 6. 이직, 창업, 승진 7. 일할 필요가 없어서 8. 기타
F2_4	더미/ 범주형	경제활동	최장기 일자리_퇴직 후 가교일자리 여부	1. 예 2. 아니요
F3	더미/ 범주형	경제활동	향후 근로 희망 여부	1. 일을 하고 싶지 않다 2. 지금 하고 있는 일을 계속 하고 싶다 3. 지금과는 다른 일을 하고 싶다 4. 지금은 일하지 않으나 앞으로 일을 하고 싶다
F3_4_1	더미/ 범주형	경제활동	지난 1년간 구직활동 노력(1순위)	0. 노력하지 않음 1. 취업지원센터(동사무소, 구청, 대한노인회, 고용센터, 복지관 등)의뢰 2. 개인적 인맥의뢰 3. 신문, 잡지, 컴퓨터 등 검색

변수명	변수특성	구분	변수설명	문항내용
				4. 자기소개서 및 이력서 작성, 면접컨설팅 참여 5. 직업상담, 집단상담프로그램, 일자리박람회 등 참여 6. 직업교육훈련참여 7. 기타
F4	더미/ 범주형	경제활동	노인일자리사업 참여 경험 유무	1. 현재 참여하고 있다 2. 참여한 적이 있다 3. 신청했으나 참여기회가 없었다 4. 신청한 적이 없다
F4_1	더미/ 범주형	경제활동	노인일자리사업 참여 유형	1. 공익형 2. 재능나눔형 3. 시장형사업단(공동작업형, 제조판매형, 전문서비스형) 4. 인력파견형 5. 시니어인턴십, 고령자친화 기업, 기업연계형
F5	더미/ 범주형	경제활동	향후 노인일자리사업 참여 의향	1. 예 2. 아니요
G1	더미/ 범주형	손)자녀/배우자 와의 관계 및 가구형태	비동거 생존자녀 유무	1. 따로 살고 있는 생존자녀가 있다 2. 따로 살고 있는 생존자녀는 없지만, 사망한 자녀의 배우자는 있다 3. 따로 살고 있는 생존자녀나 자녀의 배우자가 전혀 없다
G2	더미/ 범주형	손)자녀/배우자 와의 관계 및 가구형태	비동거 생존자녀 전체_ 왕래 빈도(지난 1년간)	0. 왕래(연락)를 거의 하지 않는다 1. 거의 매일(주 4회 이상) 2. 일주일에 2~3회 정도 3. 일주일에 1회 정도 4. 한달에 1~2회 정도 5. 3개월에 1~2회 정도 6. 1년에 1~2회 정도 7. 기타
G2_1	더미/ 범주형	손)자녀/배우자 와의 관계 및 가구형태	비동거 생존자녀 전체_ 연락 빈도(지난 1년간)	0. 왕래(연락)를 거의 하지 않는다 1. 거의 매일(주 4회 이상) 2. 일주일에 2~3회 정도 3. 일주일에 1회 정도 4. 한달에 1~2회 정도 5. 3개월에 1~2회 정도

변수명	변수특성	구분	변수설명	문항내용
				6. 1년에 1~2회 정도 7. 기타
G3	더미/ 범주형	손)자녀/배우자 와의 관계 및 가구형태	비동거 생존자녀 중 가장 많이 접촉한 자녀	조사매뉴얼 <별첨 1> 참조
G3_1	더미/ 범주형	손)자녀/배우자 와의 관계 및 가구형태	비동거 생존자녀 중 가장 많이 접촉한 자녀_ 거리	1. 걸어서 10분 미만 2. 걸어서 10분~30분 미만 3. 자동차로 30분 미만 4. 자동차로 30분~1시간 미만 5. 자동차로 1시간~2시간 미만 6. 자동차로 2시간~3시간 미만 7. 자동차로 3시간 이상 8. 해외거주 9. 기타
G3_2	더미/ 범주형	손)자녀/배우자 와의 관계 및 가구형태	비동거 생존자녀 중 가장 많이 접촉한 자녀_왕래 빈도	0. 왕래(연락)를 거의 하지 않는다 1. 거의 매일(주 4회 이상) 2. 일주일에 2~3회 정도 3. 일주일에 1회 정도 4. 한달에 1~2회 정도 5. 3개월에 1~2회 정도 6. 1년에 1~2회 정도 7. 기타
G3_3	더미/ 범주형	손)자녀/배우자 와의 관계 및 가구형태	비동거 생존자녀 중 가장 많이 접촉한 자녀_ 연락 빈도	0. 왕래(연락)를 거의 하지 않는다 1. 거의 매일(주 4회 이상) 2. 일주일에 2~3회 정도 3. 일주일에 1회 정도 4. 한달에 1~2회 정도 5. 3개월에 1~2회 정도 6. 1년에 1~2회 정도 7. 기타
G4	더미/ 범주형	손)자녀/배우자 와의 관계 및 가구형태	지난 1년간 자녀와의 갈등 경험	1. 예 2. 아니요
G4_1	더미/ 범주형	손)자녀/배우자 와의 관계 및 가구형태	갈등을 경험한 가장 심각한 이유	1. 자녀와의 동거 여부를 둘러싼 갈등 2. 나 또는 배우자의 수발 관련 갈등 3. 자녀가 경제적 도움 요구 4. 나 또는 배우자 생활비 보조와 관련한 갈등 5. 나 또는 배우자의 자녀 편애

변수명	변수특성	구분	변수설명	문항내용
				6. 자녀의 진로, 이성교제, 결혼문제 7. 기타
G5	더미/ 범주형	손)자녀/배우자 와의 관계 및 가구형태	비동거 손자녀 유무	1. 예 2. 아니요
G5_1	더미/ 범주형	손)자녀/배우자 와의 관계 및 가구형태	비동거 손자녀 전체_ 왕래 빈도(지난 1년간)	0. 왕래(연락)를 거의 하지 않는다 1. 거의 매일(주 4회 이상) 2. 일주일에 2~3회 정도 3. 일주일에 1회 정도 4. 한달에 1~2회 정도 5. 3개월에 1~2회 정도 6. 1년에 1~2회 정도 7. 기타
G5_2	더미/ 범주형	손)자녀/배우자 와의 관계 및 가구형태	비동거 손자녀 전체_ 연락 빈도(지난 1년간)	0. 왕래(연락)를 거의 하지 않는다 1. 거의 매일(주 4회 이상) 2. 일주일에 2~3회 정도 3. 일주일에 1회 정도 4. 한달에 1~2회 정도 5. 3개월에 1~2회 정도 6. 1년에 1~2회 정도 7. 기타
G6	더미/ 범주형	손)자녀/배우자 와의 관계 및 가구형태	배우자_건강상태	1. 매우 건강하다 2. 건강한 편이다 3. 그저 그렇다 4. 건강이 나쁜 편이다 5. 건강이 매우 나쁘다
G7	더미/ 범주형	손)자녀/배우자 와의 관계 및 가구형태	배우자_동반 외출 정도	0. 없음 1. 거의 매일(주 4회 이상) 2. 일주일에 2~3회 정도 3. 일주일에 1회 정도 4. 한달에 1~2회 정도 5. 3개월에 1~2회 정도 6. 1년에 1~2회 정도
G8_m	더미/ 범주형	손)자녀/배우자 와의 관계 및 가구형태	단독가구(독거/부부) 형성 시기_월	실수
G9	더미/ 범주형	손)자녀/배우자 와의 관계 및 가구형태	단독가구(독거/부부) 형성 이유	1. 경제적으로 능력이 있어서 2. 건강해서 3. 개인생활 또는 부부생활을 누리기 위해서

변수명	변수특성	구분	변수설명	문항내용
				4. 살고 있는 곳에서 떠나기 싫어서 5. 자녀가 결혼해서 6. 자녀가 따로 살기를 원하여서 7. 자녀가 직장(학업) 때문에 다른지역에 있어서 8. 자녀의 경제적 형편이 되지 않아서 9. 기타
G10	더미/범주형	손)자녀/배우자와의 관계 및 가구형태	단독가구(독거/부부) 생활 시 어려운 점	0. 없음 1. 아플 때 간호해 줄 사람이 없음 2. 가사일 등 일상생활 문제를 처리하기 어려움 3. 경제적 불안감 4. 안전에 대한 불안감 5. 심리적 불안감 또는 외로움 6. 기 타
G11	더미/범주형	손)자녀/배우자와의 관계 및 가구형태	기혼자녀 동거 이유	1. 자녀와 같이 사는 것이 당연하다고 생각 2. 혼자 또는 배우자와 사는 것만으로는 외로워서 3. 나 또는 배우자를 돌보줄 사람이 필요해서 4. 내가 경제적 능력이 없어서 5. 자녀에게 가사, 육아 등의 도움을 주기 위하여 6. 자녀가 경제적 능력이 없어서 7. 기타
G12	더미/범주형	손)자녀/배우자와의 관계 및 가구형태	기혼자녀 동거 시 일상생활 부담	1. 나 또는 배우자가 수행 2. 자녀가수행 3. 공동수행 4. 각자 알아서 따로 하는 편
G13	더미/범주형	손)자녀/배우자와의 관계 및 가구형태	노후생활_자녀의 노부모와의 동거 (적어도 한 명)에 대한 생각	1. 예 2. 아니요
G13_1	더미/범주형	손)자녀/배우자와의 관계 및 가구형태	노후생활_자녀의 부모와의 동거_대상	1. 장남 2. 아들 중 누군가 3. 장녀 4. 딸 중 누군가

변수명	변수특성	구분	변수설명	문항내용
				5. 딸/아들 상관없이 형편이 되는 자녀 6. 딸/아들 상관없이 마음이 맞는 자녀 7. 기타
G14	더미/ 범주형	손)자녀/배우자와의 관계 및 가구형태	노후생활_노후생활비 마련 방법	1. 본인 스스로 마련하는 것이 좋다 2. 자녀들이 마련해 주어야 한다 3. 사회보장제도(연금 등) 등 국가적 차원에서 보장되어야 한다 4. 본인과 자녀가 함께 마련 5. 본인과 사회보장제도(연금 등)가 함께 마련 6. 기타
H1	더미/ 범주형	부모, 형제/자매, 친/인척, 친구/이웃/지인과의 관계	형제/자매 생존 여부	1. 있다 2. 없다
H2	더미/ 범주형	부모, 형제/자매, 친/인척, 친구/이웃/지인과의 관계	형제/자매를 포함한 친/인척과의 왕래 빈도(지난 1년간)	0. 왕래(연락)를 거의 하지 않는다 1. 거의 매일(주 4회 이상) 2. 일주일에 2~3회 정도 3. 일주일에 1회 정도 4. 한달에 1~2회 정도 5. 3개월에 1~2회 정도 6. 1년에 1~2회 정도 7. 기타
H2_1	더미/ 범주형	부모, 형제/자매, 친/인척, 친구/이웃/지인과의 관계	형제/자매를 포함한 친/인척과의 연락 빈도(지난 1년간)	0. 왕래(연락)를 거의 하지 않는다 1. 거의 매일(주 4회 이상) 2. 일주일에 2~3회 정도 3. 일주일에 1회 정도 4. 한달에 1~2회 정도 5. 3개월에 1~2회 정도 6. 1년에 1~2회 정도 7. 기타
H3	더미/ 범주형	부모, 형제/자매, 친/인척, 친구/이웃/지인과의 관계	친구/이웃/지인과의 왕래 빈도(지난 1년간)	0. 왕래(연락)를 거의 하지 않는다 1. 거의 매일(주 4회 이상) 2. 일주일에 2~3회 정도 3. 일주일에 1회 정도 4. 한달에 1~2회 정도

변수명	변수특성	구분	변수설명	문항내용
				5. 3개월에 1~2회 정도 6. 1년에 1~2회 정도 7. 기타
H3_1	더미/ 범주형	부모, 형제/ 자매, 친/인척, 친구/이웃/ 지인과의 관계	친구/이웃/지인과의 연락 빈도(지난 1년간)	0. 왕래(연락)를 거의 하지 않는다 1. 거의 매일(주 4회 이상) 2. 일주일에 2~3회 정도 3. 일주일에 1회 정도 4. 한달에 1~2회 정도 5. 3개월에 1~2회 정도 6. 1년에 1~2회 정도 7. 기타
H4_1	더미/ 범주형	부모, 형제/ 자매, 친/인척, 친구/이웃/ 지인과의 관계	가깝게 지내는 형제/자매를 포함한 친/인척 수	실수
I1	더미/ 범주형	자녀/부모와의 부양의 교환	동거자녀_존재 여부	1. 있음 2. 없음
I1_1_1	더미/ 범주형	자녀/부모와의 부양의 교환	동거자녀_고민상담_ 도움 받음	1. 매우 그렇다 2. 그런 편이다 3. 그렇지 않은 편이다 4. 전혀 그렇지 않다
I1_1_2	더미/ 범주형	자녀/부모와의 부양의 교환	동거자녀_고민상담_ 도움 줌	1. 매우 그렇다 2. 그런 편이다 3. 그렇지 않은 편이다 4. 전혀 그렇지 않다
I1_2_1	더미/ 범주형	자녀/부모와의 부양의 교환	동거자녀_청소/식사 준비/세탁_도움 받음	1. 매우 그렇다 2. 그런 편이다 3. 그렇지 않은 편이다 4. 전혀 그렇지 않다
I1_2_2	더미/ 범주형	자녀/부모와의 부양의 교환	동거자녀_청소/식사 준비/세탁_도움 줌	1. 매우 그렇다 2. 그런 편이다 3. 그렇지 않은 편이다 4. 전혀 그렇지 않다
I1_3_1	더미/ 범주형	자녀/부모와의 부양의 교환	동거자녀_간병/수발/ 병원동행_도움 받음	1. 매우 그렇다 2. 그런 편이다 3. 그렇지 않은 편이다 4. 전혀 그렇지 않다
I1_3_2	더미/ 범주형	자녀/부모와의 부양의 교환	동거자녀_간병/수발/ 병원동행_도움 줌	1. 매우 그렇다 2. 그런 편이다 3. 그렇지 않은 편이다 4. 전혀 그렇지 않다

변수명	변수특성	구분	변수설명	문항내용
l1_4_1_1	더미/ 범주형	자녀/부모와의 부양의 교환	동거자녀_정기적 현금지원_도움 받음	1. 있다 2. 없다
l1_4_1_2	더미/ 범주형	자녀/부모와의 부양의 교환	동거자녀_정기적 현금지원_도움 줌	1. 있다 2. 없다
l1_4_2_1	더미/ 범주형	자녀/부모와의 부양의 교환	동거자녀_비정기적 현금지원_도움 받음	1. 있다 2. 없다
l1_4_2_2	더미/ 범주형	자녀/부모와의 부양의 교환	동거자녀_비정기적 현금지원_도움 줌	1. 있다 2. 없다
l1_4_3_1	더미/ 범주형	자녀/부모와의 부양의 교환	동거자녀_현물지원_ 도움 받음	1. 있다 2. 없다
l1_4_3_2	더미/ 범주형	자녀/부모와의 부양의 교환	동거자녀_현물지원_ 도움 줌	1. 있다 2. 없다
l2	더미/ 범주형	자녀/부모와의 부양의 교환	비동거자녀_존재 여부	1. 있음 2. 없음
l2_1_1	더미/ 범주형	자녀/부모와의 부양의 교환	비동거자녀_고민상담_ 도움 받음	1. 매우 그렇다 2. 그런 편이다 3. 그렇지 않은 편이다 4. 전혀 그렇지 않다
l2_1_2	더미/ 범주형	자녀/부모와의 부양의 교환	비동거자녀_고민상담_ 도움 줌	1. 매우 그렇다 2. 그런 편이다 3. 그렇지 않은 편이다 4. 전혀 그렇지 않다
l2_2_1	더미/ 범주형	자녀/부모와의 부양의 교환	비동거자녀_청소/식사 준비/세탁_도움 받음	1. 매우 그렇다 2. 그런 편이다 3. 그렇지 않은 편이다 4. 전혀 그렇지 않다
l2_2_2	더미/ 범주형	자녀/부모와의 부양의 교환	비동거자녀_청소/식사준 비/세탁_도움 줌	1. 매우 그렇다 2. 그런 편이다 3. 그렇지 않은 편이다 4. 전혀 그렇지 않다
l2_3_1	더미/ 범주형	자녀/부모와의 부양의 교환	비동거자녀_간병/수발/ 병원동행_도움 받음	1. 매우 그렇다 2. 그런 편이다 3. 그렇지 않은 편이다 4. 전혀 그렇지 않다
l2_3_2	더미/ 범주형	자녀/부모와의 부양의 교환	비동거자녀_간병/수발/ 병원동행_도움 줌	1. 매우 그렇다 2. 그런 편이다 3. 그렇지 않은 편이다 4. 전혀 그렇지 않다
l2_4_1_1	더미/ 범주형	자녀/부모와의 부양의 교환	비동거자녀_정기적 현금지원_도움 받음	1. 있다 2. 없다

변수명	변수특성	구분	변수설명	문항내용
i2_4_1_2	더미/ 범주형	자녀/부모와의 부양의 교환	비동거자녀_정기적 현금지원_도움 줌	1. 있다 2. 없다
i2_4_2_1	더미/ 범주형	자녀/부모와의 부양의 교환	비동거자녀_비정기적 현금지원_도움 받음	1. 있다 2. 없다
i2_4_2_2	더미/ 범주형	자녀/부모와의 부양의 교환	비동거자녀_비정기적 현금지원_도움 줌	1. 있다 2. 없다
i2_4_3_1	더미/ 범주형	자녀/부모와의 부양의 교환	비동거자녀_현물지원_ 도움 받음	1. 있다 2. 없다
i2_4_3_2	더미/ 범주형	자녀/부모와의 부양의 교환	비동거자녀_현물지원_ 도움 줌	1. 있다 2. 없다
i3	더미/ 범주형	자녀/부모와의 부양의 교환	본인(배우자)부모_ 존재 여부	1. 있음 2. 없음
i4	더미/ 범주형	자녀/부모와의 부양의 교환	본인(배우자)부모_ 존재 여부	1. 있음 2. 없음
i4_1_1	더미/ 범주형	자녀/부모와의 부양의 교환	배우자_고민상담_ 도움 받음	1. 매우 그렇다 2. 그런 편이다 3. 그렇지 않은 편이다 4. 전혀 그렇지 않다
i4_1_2	더미/ 범주형	자녀/부모와의 부양의 교환	배우자_고민상담_ 도움 줌	1. 매우 그렇다 2. 그런 편이다 3. 그렇지 않은 편이다 4. 전혀 그렇지 않다
i4_2_1	더미/ 범주형	자녀/부모와의 부양의 교환	배우자_청소/식사준비/ 세탁_도움 받음	1. 매우 그렇다 2. 그런 편이다 3. 그렇지 않은 편이다 4. 전혀 그렇지 않다
i4_2_2	더미/ 범주형	자녀/부모와의 부양의 교환	배우자_청소/식사준비/ 세탁_도움 줌	1. 매우 그렇다 2. 그런 편이다 3. 그렇지 않은 편이다 4. 전혀 그렇지 않다
i4_3_1	더미/ 범주형	자녀/부모와의 부양의 교환	배우자_간병/수발/병원 동행_도움 받음	1. 매우 그렇다 2. 그런 편이다 3. 그렇지 않은 편이다 4. 전혀 그렇지 않다
i4_3_2	더미/ 범주형	자녀/부모와의 부양의 교환	배우자_간병/수발/병원 동행_도움 줌	1. 매우 그렇다 2. 그런 편이다 3. 그렇지 않은 편이다 4. 전혀 그렇지 않다
i6	더미/ 범주형	자녀/부모와의 부양의 교환	손자녀(10세 미만) 돌봄 여부(지난 1년간)	1. 있다 2. 없다

변수명	변수특성	구분	변수설명	문항내용
J1_1	더미/ 범주형	생활환경	시장, 슈퍼 등 일상용품 구매 장소까지 걸리는 시간	1. 걸어서 5분 미만 2. 걸어서 5분~10분 미만 3. 걸어서 10분~30분 미만 4. 걸어서 30분 이상
J1_2	더미/ 범주형	생활환경	병의원, 보건소 등 보건의료기관까지 걸리는 시간	1. 걸어서 5분 미만 2. 걸어서 5분~10분 미만 3. 걸어서 10분~30분 미만 4. 걸어서 30분 이상
J1_3	더미/ 범주형	생활환경	주민센터까지 걸리는 시간	1. 걸어서 5분 미만 2. 걸어서 5분~10분 미만 3. 걸어서 10분~30분 미만 4. 걸어서 30분 이상
J1_4	더미/ 범주형	생활환경	노인복지관/노인복지회 관까지 걸리는 시간	1. 걸어서 5분 미만 2. 걸어서 5분~10분 미만 3. 걸어서 10분~30분 미만 4. 걸어서 30분 이상
J1_5	더미/ 범주형	생활환경	사회복지관/장애인 복지관/여성회관 등까지 걸리는 시간	1. 걸어서 5분 미만 2. 걸어서 5분~10분 미만 3. 걸어서 10분~30분 미만 4. 걸어서 30분 이상
J1_6	더미/ 범주형	생활환경	버스 정류장/ 지하철역까지 걸리는 시간	1. 걸어서 5분 미만 2. 걸어서 5분~10분 미만 3. 걸어서 10분~30분 미만 4. 걸어서 30분 이상
J2	더미/ 범주형	생활환경	외출 시 주로 이용하는 교통수단	0. 없음(도보만) 1. 버스 2. 지하철 3. 택시 4. 자가용 5. 자전거 6. 오토바이 7. 기타
J3	더미/ 범주형	생활환경	외출 시 가장 불편한 점	0. 없음 1. 버스(전철)타고 내리기 2. 계단이나 경사로 오르내리기 3. 교통수단부족 4. 이동하기에 불편한 도로상태 5. 노인을 배려하지 않은 교통편의시설 6. 차량이 많아 다니기에 위험함 7. 기타

변수명	변수특성	구분	변수설명	문항내용
J4	더미/ 범주형	생활환경	현재 운전 여부	1. 현재 한다 2. 전에는 했으나, 지금은 하지 않는다 3. 평생 한 적이 없다
J4_1	더미/ 범주형	생활환경	운전시 어려움 느끼는 정도	1. 매우 그렇다 2. 그런 편이다 3. 그저 그렇다 4. 그렇지 않은 편이다 5. 전혀 그렇지 않다
J5	더미/ 범주형	생활환경	낙상_지난 1년간 경험 유무	1. 있다 2. 없다
J5_1	더미/ 범주형	생활환경	낙상_병원 치료 여부	1. 예 2. 아니요
J5_2	더미/ 범주형	생활환경	낙상_가장 큰 이유	1. 바닥이 미끄러워서 2. 사람이나 사물에 부딪혀서 3. 보도나 문의 턱에 걸려 4. 경사가 급해서 5. 조명이 어두워서 6. 다리를 접질러서(발을 헛디뎠서) 7. 갑자기 어지러워서 8. 다리에 힘이 풀려서(갑자기 주저앉아서) 9. 기타
J6	더미/ 범주형	생활환경	안전사고 경험 유무 (지난 1년간)	1. 예 2. 아니요
J7_1	더미/ 범주형	생활환경	지난 1년간 범죄피해 여부_재산범죄	1. 예 2. 아니요
J7_2	더미/ 범주형	생활환경	지난 1년간 범죄피해 여부_폭력 및 강력범죄	1. 예 2. 아니요
J7_3	더미/ 범주형	생활환경	지난 1년간 범죄피해 여부_노인 대상 사기성 물건 구매	1. 예 2. 아니요
J7_4	더미/ 범주형	생활환경	지난 1년간 범죄피해 여부_보이스피싱 피해	1. 예 2. 아니요
K2_1	더미/ 범주형	노후생활과 삶의 질	만족도_건강상태	1. 매우 만족함 2. 만족함 3. 그저 그렇다 4. 만족하지 않음 5. 전혀 만족하지 않음
K2_2	더미/ 범주형	노후생활과 삶의 질	만족도_경제상태	1. 매우 만족함 2. 만족함 3. 그저 그렇다

변수명	변수특성	구분	변수설명	문항내용
				4. 만족하지 않음 5. 전혀 만족하지 않음
K2_3	더미/ 범주형	노후생활과 삶의 질	만족도_배우자와의 관계	1. 매우 만족함 2. 만족함 3. 그저 그렇다 4. 만족하지 않음 5. 전혀 만족하지 않음
K2_4	더미/ 범주형	노후생활과 삶의 질	만족도_자녀와의 관계	1. 매우 만족함 2. 만족함 3. 그저 그렇다 4. 만족하지 않음 5. 전혀 만족하지 않음
K2_5	더미/ 범주형	노후생활과 삶의 질	만족도_사회/여가/ 문화활동	1. 매우 만족함 2. 만족함 3. 그저 그렇다 4. 만족하지 않음 5. 전혀 만족하지 않음
K2_6	더미/ 범주형	노후생활과 삶의 질	만족도_친구 및 지역사회 관계	1. 매우 만족함 2. 만족함 3. 그저 그렇다 4. 만족하지 않음 5. 전혀 만족하지 않음
K3_1	더미/ 범주형	노후생활과 삶의 질	가치관_노인이 재혼하는 것	1. 매우 좋아 보인다 2. 좋아 보이는 편이다 3. 그저 그렇다 4. 별로 좋아 보이지 않는다 5. 전혀 좋아 보이지 않는다
K3_2	더미/ 범주형	노후생활과 삶의 질	가치관_노인이 일하는 것	1. 매우 좋아 보인다 2. 좋아 보이는 편이다 3. 그저 그렇다 4. 별로 좋아 보이지 않는다 5. 전혀 좋아 보이지 않는다
K3_3	더미/ 범주형	노후생활과 삶의 질	가치관_노인이 새로운 것을 배우는 것	1. 매우 좋아 보인다 2. 좋아 보이는 편이다 3. 그저 그렇다 4. 별로 좋아 보이지 않는다 5. 전혀 좋아 보이지 않는다
K3_4	더미/ 범주형	노후생활과 삶의 질	가치관_노인이 젊어 보이려고 외모를 가꾸는 것	1. 매우 좋아 보인다 2. 좋아 보이는 편이다 3. 그저 그렇다 4. 별로 좋아 보이지 않는다 5. 전혀 좋아 보이지 않는다

변수명	변수특성	구분	변수설명	문항내용
K4	더미/ 범주형	노후생활과 삶의 질	일상생활 차별 경험 유무	1. 예 2. 아니요
K5_1	더미/ 범주형	노후생활과 삶의 질	타인으로부터 신체적 고통을 당함_여부	1. 예 2. 아니요
K5_3	더미/ 범주형	노후생활과 삶의 질	타인으로 인해 감정을 상함_여부	1. 예 2. 아니요
K5_3_1	더미/ 범주형	노후생활과 삶의 질	타인으로 인해 감정을 상함_행위자	조사매뉴얼 <별첨 1> 참조
K5_4	더미/ 범주형	노후생활과 삶의 질	타인으로부터 금전적 피해를 입음_여부	1. 예 2. 아니요
K5_5	더미/ 범주형	노후생활과 삶의 질	가족이나 보호자가 돌봐주지 않음_여부	1. 예 2. 아니요
K5_6	더미/ 범주형	노후생활과 삶의 질	가족이나 보호자의 방임 및 생활비 미지원_여부	1. 예 2. 아니요
K7	더미/ 범주형	노후생활과 삶의 질	재산처리방식	1. 모든 자녀에게 골고루 상속 2. 장남에게 더 많이 상속 3. 장남에게만 상속 4. 효도한 자녀에게 전부/더 많이 상속 5. 경제사정이 나쁜 자녀에게 전부/더 많이 상속 6. 전체 또는 일부 사회에 환원 7. 나 자신(배우자)을 위해 쓰겠다 8. 기타
K8_1	더미/ 범주형	노후생활과 삶의 질	죽음준비_수의	1. 예 2. 아니요
K8_2	더미/ 범주형	노후생활과 삶의 질	죽음준비_묘지	1. 예 2. 아니요
K8_3	더미/ 범주형	노후생활과 삶의 질	죽음준비_상조회 가입	1. 예 2. 아니요
K8_4	더미/ 범주형	노후생활과 삶의 질	죽음준비_유서 작성	1. 예 2. 아니요
K8_5	더미/ 범주형	노후생활과 삶의 질	죽음준비_교육 수강	1. 예 2. 아니요
K9	더미/ 범주형	노후생활과 삶의 질	희망 장례 방법	1. 화장 후 납골당 2. 화장 후 자연장(수목/잔디/ 화초장/매장) 3. 화장 후 산골(산/강/바다에 뿌리는 것) 4. 매장

변수명	변수특성	구분	변수설명	문항내용
				5. 시신기증 6. 기타 7. 아직 생각해 보지 않음
K10	더미/ 범주형	노후생활과 삶의 질	연명치료에 대한 생각	1. 매우 찬성한다 2. 찬성하는 편이다 3. 그저 그렇다 4. 반대하는 편이다 5. 매우 반대한다
K11	더미/ 범주형	노후생활과 삶의 질	만 60세 이후 자살생각	1. 예 2. 아니요
L1	더미/ 범주형	정책적 이슈에 대한 노인의 인식	거주형태(가구)	1. 자가 2. 전세 3. 보증금 있는 월세 4. 보증금 없는 월세(사글세) 5. 무상
L3_1	더미/ 범주형	정책적 이슈에 대한 노인의 인식	현재 거주지 주거환경 불만족 이유	1. 시장과 대형 마트, 은행 등 각종 생활 시설이 부족 하거나 이용하기에 불편 2. 대중교통이 부족하거나 이용하기에 불편 3. 녹지공간, 공원 등이 부족 하거나 이용하기에 불편 4. 의료시설이 부족하거나 이용하기에 불편 5. 각종 사회복지시설(여가, 문화 포함)이 부족하거나 이용 하기에 불편 6. 범죄가 자주 발생하거나 발생할 우려가 높은 지역 이라서 7. 자녀 또는 친구와 멀리 떨어져 있어서 8. 기타
N1_1_a	더미/ 범주형	경제상태	지출_보건의료비_유무	1. 있음 2. 없음
N1_3_a	더미/ 범주형	경제상태	지출_문화여가비_유무	1. 있음 2. 없음
N1_4_a	더미/ 범주형	경제상태	지출_경조사비_유무	1. 있음 2. 없음
N2	더미/ 범주형	경제상태	국민기초생활보장 수급자 여부	1. 국민기초생활보장수급자 2. 국민기초생활보장수급자는 아니지만 의료급여수급자

변수명	변수특성	구분	변수설명	문항내용
				3. 국민기초생활보장수급자도 의료급여수급자도 아님
N3_1_1_a	더미/ 범주형	경제상태	본인_근로소득_유무	1. 있음 2. 없음
N3_1_2_a	더미/ 범주형	경제상태	본인_사업소득_유무	1. 있음 2. 없음
N3_1_3_a	더미/ 범주형	경제상태	본인_재산소득_유무	1. 있음 2. 없음
N3_1_4_a	더미/ 범주형	경제상태	본인_개인연금_유무	1. 있음 2. 없음
N3_1_5_a	더미/ 범주형	경제상태	본인_퇴직연금_유무	1. 있음 2. 없음
N3_1_6_a	더미/ 범주형	경제상태	본인_주택/농지연금_ 유무	1. 있음 2. 없음
N3_1_7_a	더미/ 범주형	경제상태	본인_사적이전소득_ 유무	1. 있음 2. 없음
N3_1_8_a	더미/ 범주형	경제상태	본인_공적연금_유무	1. 있음 2. 없음
N3_1_9_a	더미/ 범주형	경제상태	본인_기초연금_유무	1. 있음 2. 없음
N3_1_13_a	더미/ 범주형	경제상태	본인_기타공적급여_ 유무	1. 있음 2. 없음
N3_1_14_a	더미/ 범주형	경제상태	본인_기타소득_유무	1. 있음 2. 없음
N3_1_15_a	더미/ 범주형	경제상태	본인_총수입액_유무	1. 있음 2. 없음
N3_2_1_a	더미/ 범주형	경제상태	그외 가구원_근로소득_ 유무	1. 있음 2. 없음
N3_2_2_a	더미/ 범주형	경제상태	그외 가구원_사업소득_ 유무	1. 있음 2. 없음
N3_2_3_a	더미/ 범주형	경제상태	그외 가구원_재산소득_ 유무	1. 있음 2. 없음
N3_2_4_a	더미/ 범주형	경제상태	그외 가구원_개인연금_ 유무	1. 있음 2. 없음
N3_2_5_a	더미/ 범주형	경제상태	그외 가구원_퇴직연금_ 유무	1. 있음 2. 없음
N3_2_6_a	더미/ 범주형	경제상태	그외 가구원_주택/ 농지연금_유무	1. 있음 2. 없음
N3_2_7_a	더미/ 범주형	경제상태	그외 가구원_ 사적이전소득_유무	1. 있음 2. 없음

변수명	변수특성	구분	변수설명	문항내용
N3_2_8_a	더미/ 범주형	경제상태	그외 가구원_공적연금_유무	1. 있음 2. 없음
N3_2_9_a	더미/ 범주형	경제상태	그외 가구원_기초연금_유무	1. 있음 2. 없음
N3_2_13_a	더미/ 범주형	경제상태	그외 가구원_기타공적 급여_유무	1. 있음 2. 없음
N3_2_14_a	더미/ 범주형	경제상태	그외 가구원_기타소득_유무	1. 있음 2. 없음
N3_2_15_a	더미/ 범주형	경제상태	그외 가구원_총수입액_유무	1. 있음 2. 없음
N3_3_1_a	더미/ 범주형	경제상태	가구_근로소득_유무	1. 있음 2. 없음
N3_3_2_a	더미/ 범주형	경제상태	가구_사업소득_유무	1. 있음 2. 없음
N3_3_3_a	더미/ 범주형	경제상태	가구_재산소득_유무	1. 있음 2. 없음
N3_3_7_a	더미/ 범주형	경제상태	가구_사적이전소득_유무	1. 있음 2. 없음
N3_3_14_a	더미/ 범주형	경제상태	가구_기타소득_유무	1. 있음 2. 없음
N5	더미/ 범주형	경제상태	지출 생활비 중 가장 부담되는 항목(가구)	0. 없음 1. 식비(주식비와 부식비) 2. 교육비 3. 월세 4. 주거관련비(주택관리비, 냉난방비, 수도비 등) 5. 보건의료비(건강보험료 제외) 6. 간병 수발비(장기요양본인 부담금, 개인 간병비, 용품 등) 7. 가구집기/가사용품 8. 피복비(옷, 신발 등 구입비) 9. 교양오락비 10. 교통비(차량구입비 제외) 11. 통신비(전화, 인터넷, 핸드폰 사용료 등) 12. 경조사비 13. 부채상환 14. 기타
N6_1_1_a	더미/ 범주형	경제상태	본인_부동산자산_유무	1. 있음 2. 없음
N6_1_2_a	더미/ 범주형	경제상태	본인_금융자산_유무	1. 있음 2. 없음

변수명	변수특성	구분	변수설명	문항내용
N6_1_3_a	더미/ 범주형	경제상태	본인_기타자산_유무	1. 있음 2. 없음
N6_1_4_a	더미/ 범주형	경제상태	본인_부채_유무	1. 있음 2. 없음
jo1	더미/ 범주형	조사원 확인사항	주택 종류	1. 단독주택 2. 아파트 3. 연립/다세대주택 4. 기타
jo2	더미/ 범주형	조사원 확인사항	주거 위치	1. 지하 또는 반지하 2. 지상 3. 옥탑
jo4	더미/ 범주형	조사원 확인사항	노인이 생활하는 데 편리함 정도	1. 생활하기 불편한 구조이다 2. 생활하기 불편한 구조는 아니지만, 노인을 배려한 설비는 없다 3. 노인을 배려한 설비(문턱 없애기, 경사조절, 손잡이 설치 등)를 갖추고 있다 4. 기타
jo5	더미/ 범주형	조사원 확인사항	배우자의 노인조사 실시 여부	1. 배우자 조사 완료 2. 배우자 조사 미실시(65세 이상) 3. 배우자 조사 비해당(65세 미만) 4. 배우자 없음(미혼, 사별, 이혼, 별거, 비동거 배우자)
jo5_a_2	더미/ 범주형	조사원 확인사항	배우자 가구원번호	실수
ID_A3	더미/ 범주형	응답자용 변수	응답자_성별	
ID_A5	더미/ 범주형	응답자용 변수	응답자_혼인상태	
ID_A6_1	더미/ 범주형	응답자용 변수	응답자_교육수준	
ID_A7	더미/ 범주형	응답자용 변수	응답자_취업여부	
time	연속형	가구 일반사항	조사표 완료 소요시간	실수
visit	연속형	가구 일반사항	총방문 횟수	실수
total_ga	연속형	가구 일반사항	총가구원 수	실수

변수명	변수특성	구분	변수설명	문항내용
H1_2	연속형	가구 일반사항	동거자녀 수_계	실수
H1_2_1	연속형	가구 일반사항	동거자녀 수_남자	실수
H1_2_2	연속형	가구 일반사항	동거자녀 수_여자	실수
H1_2_3	연속형	가구 일반사항	동거자녀 수_미혼	실수
H1_2_4	연속형	가구 일반사항	동거자녀 수_기혼	실수
A4_1_y_ga1	연속형	가구 일반사항	1번가구원의 생년	실수
A4_2_ga1	연속형	가구 일반사항	1번가구원의 만 연령	실수
A6_2_ga1	연속형	가구 일반사항	1번가구원의 교육연수	실수 99. 비해당(만 64세 이하)
A4_1_y_ga2	연속형	가구 일반사항	2번가구원의 생년	실수
A4_2_ga2	연속형	가구 일반사항	2번가구원의 만 연령	실수
A6_2_ga2	연속형	가구 일반사항	2번가구원의 교육연수	실수 99. 비해당(만 64세 이하)
A4_1_y_ga3	연속형	가구 일반사항	3번가구원의 생년	실수
A4_2_ga3	연속형	가구 일반사항	3번가구원의 만 연령	실수
B2_3	연속형	건강상태	의사진단 만성질환 총 수	실수
B3	연속형	건강상태	현재 3개월 이상 복용하고 있는 의사처방약(알)	실수
B4_1	연속형	건강상태	지난 1개월 동안 의료기관 이용시 횟수	실수
B5_1_1	연속형	건강상태	지난 1년간 병원 입원시 횟수	실수
C2_1	연속형	건강행태	음주 시 평균 음주량	실수
C3_1	연속형	건강행태	운동 빈도(일)_ (일주일 기준)	실수
C3_2	연속형	건강행태	운동 시간(분)_ (1회 기준)	실수

변수명	변수특성	구분	변수설명	문항내용
C3_3	연속형	건강행태	주로 하는 운동	조사매뉴얼 <별첨 6> 참조
C4_1	연속형	건강행태	몸무게	실수
C4_2	연속형	건강행태	키	실수
E11_1_1	연속형	여가활동과 사회활동	경로당 일주일 평균 이용 정도	실수
E11_1_2	연속형	여가활동과 사회활동	노인복지관 일주일 평균 이용 정도	실수
F1_5_d	연속형	경제활동	현재 일_평균 주 근무일수	실수
F1_5_t	연속형	경제활동	현재 일_평균 주 근무시간	실수
F1_7_y	연속형	경제활동	현재 일_종사기간(년)	실수
F1_7_m	연속형	경제활동	현재 일_종사기간(월)	실수
F2_2_y	연속형	경제활동	최장기 일자리_종사기간(년)	실수
F2_2_m	연속형	경제활동	최장기 일자리_종사기간(월)	실수
F3_2	연속형	경제활동	향후 희망 근로시간 (주당)	실수
F3_3	연속형	경제 활동	향후 희망 근로소득(월)	실수
G1_1	연속형	손자녀/배우자와의 관계 및 가구형태	비동거 생존자녀 총수	실수
G1_1_1	연속형	손자녀/배우자와의 관계 및 가구형태	비동거 생존자녀 수_남자	실수
G1_1_2	연속형	손자녀/배우자와의 관계 및 가구형태	비동거 생존자녀 수_여자	실수
G1_1_3	연속형	손자녀/배우자와의 관계 및 가구형태	비동거 생존자녀 수_미혼	실수
G1_1_4	연속형	손자녀/배우자와의 관계 및 가구형태	비동거 생존자녀 수_기혼	실수
G5_a	연속형	손자녀/배우자와의 관계 및 가구형태	비동거 손자녀 수	실수
G8_y	연속형	손자녀/배우자와의 관계 및 가구형태	단독가구(독거/부부) 형성 시기_년	실수

변수명	변수특성	구분	변수설명	문항내용
H1_1	연속형	부모, 형제/ 자매, 친/인척, 친구/이웃/ 지인과의 관계	살아있는 형제/자매 수	실수
H4_2	연속형	부모, 형제/ 자매, 친/인척, 친구/이웃/ 지인과의 관계	가깝게 지내는 친구/이웃/지인 수	실수
J4_3	연속형	생활환경	운전을 그만 둔 나이	실수
J5_a	연속형	생활환경	낙상 지난 1년간 낙상 횟수	실수
K1	연속형	노후생활과 삶의질	노인 연령 기준	실수
M_total	연속형	인지기능	인지기능_총점	실수
N1_1_b	연속형	경제상태	지출_보건의료비_ 금액(월평균)	실수
N1_3_b	연속형	경제상태	지출_문화여가비_ 금액(월평균)	실수
N1_4_b	연속형	경제상태	지출_경조사비_ 금액(월평균)	실수
N3_1_1_b	연속형	경제상태	본인_근로소득_금액	실수
N3_1_2_b	연속형	경제상태	본인_사업소득_금액	실수
N3_1_3_b	연속형	경제상태	본인_재산소득_금액	실수
N3_1_4_b	연속형	경제상태	본인_개인연금_금액	실수
N3_1_5_b	연속형	경제상태	본인_퇴직연금_금액	실수
N3_1_6_b	연속형	경제상태	본인_주택/농지연금_ 금액	실수
N3_1_7_b	연속형	경제상태	본인_사적이전소득_ 금액	실수
N3_1_8_b	연속형	경제상태	본인_공적연금_금액	실수
N3_1_9_b	연속형	경제상태	본인_기초연금_금액	실수
N3_1_13_b	연속형	경제상태	본인_기타공적급여_ 금액	실수
N3_1_14_b	연속형	경제상태	본인_기타소득_금액	실수
N3_1_15_b	연속형	경제상태	본인_총수입액_금액	실수
N3_2_1_b	연속형	경제상태	그외_가구원_근로소득_ 금액	실수

변수명	변수특성	구분	변수설명	문항내용
N3_2_2_b	연속형	경제상태	그외 가구원_사업소득_금액	실수
N3_2_3_b	연속형	경제상태	그외 가구원_재산소득_금액	실수
N3_2_4_b	연속형	경제상태	그외 가구원_개인연금_금액	실수
N3_2_5_b	연속형	경제상태	그외 가구원_퇴직연금_금액	실수
N3_2_6_b	연속형	경제상태	그외 가구원_주택/농지연금_금액	실수
N3_2_7_b	연속형	경제상태	그외 가구원_사적이전소득_금액	실수
N3_2_8_b	연속형	경제상태	그외 가구원_공적연금_금액	실수
N3_2_9_b	연속형	경제상태	그외 가구원_기초연금_금액	실수
N3_2_13_b	연속형	경제상태	그외 가구원_기타공적급여_금액	실수
N3_2_14_b	연속형	경제상태	그외 가구원_기타소득_금액	실수
N3_2_15_b	연속형	경제상태	그외 가구원_총수입액_금액	실수
N3_3_1_b	연속형	경제상태	가구_근로소득_금액	실수
N3_3_2_b	연속형	경제상태	가구_사업소득_금액	실수
N3_3_3_b	연속형	경제상태	가구_재산소득_금액	실수
N3_3_7_b	연속형	경제상태	가구_사적이전소득_금액	실수
N3_3_14_b	연속형	경제상태	가구_기타소득_금액	실수
N4	연속형	경제상태	작년 한 해 월평균 소비지출액(가구)	실수
N6_1_1_b	연속형	경제상태	본인_부동산자산_금액	실수
N6_1_2_b	연속형	경제상태	본인_금융자산_금액	실수
N6_1_3_b	연속형	경제상태	본인_기타자산_금액	실수
N6_1_4_b	연속형	경제상태	본인_부채_금액	실수
ID_A4_2	연속형	응답자용 변수	응답자_만 연령	
ID_A6_2	연속형	응답자용 변수	응답자_교육연수	

자료: 「노인실태조사」 2014 및 2017 코드북을 참조하여 재구성

머신러닝(Machine Learning)을 활용한 조세·재정정책의 평가와 설계

정재현 · 이환웅

머신러닝은 알고리즘 스스로 데이터 기반 학습을 통하여 작업의 성능을 향상시키는 것으로, 기존의 모델을 활용한 추정과 비교하여 더 나은 예측치를 제공한다. 최근 빅데이터의 성장과 컴퓨팅 성능의 발달로 머신러닝이 다양한 분야에 활용되고 있으며 특히 정부의 조세·재정정책 및 규제의 설계와 효과성 평가에 머신러닝의 활용 방안에 대한 논의가 활발하다.

본 연구에서는 정책의 평가 및 설계에 머신러닝이 활용되고 있는 현황을 살펴보고, 현재 시행되고 있는 조세 및 재정정책에 대한 머신러닝 분석을 수행하여 제도 개선방안을 제시하고자 하였다.

도입하는 장에서는 최근 새로운 실증분석방법으로 주목을 받고 있는 머신러닝에 대해 개괄하고 정책평가와 설계에서 연구진들의 높은 관심을 끌고 있는 이유는 무엇인지, 그리고 대표적인 머신러닝 알고리즘인 결정트리와 랜덤포레스트에 대해 살펴보았다. 또한, 머신러닝을 활용하여 정책의 효과성 평가를 실시한 연구 사례와, 예측모델을 개발하여 정책 대상자를 선별한 최신의 연구결과들을 정리하여 시사점을 도출하였다.

이어지는 장에서는 머신러닝이 정책의 실질적 효과를 살펴보는 데 탁월한 점에 주목하여, 머신러닝 분석방법이 비과세종합저축에 대한 조세특례 정책에 대한 기존의 효과성 분석을 어떻게 보완할 수 있는지를 살펴보고 기존의 방법론 대비 유용성을 실증하였다. 다음으로는 노인자살 예방사업을 선정하

여, 머신러닝의 활용으로 기존 사업에 투여되는 한정된 재화가 좀 더 효과적으로 쓰일 수 있는 방안을 강구하였다. 분석결과, 머신러닝을 활용한 자살 예측 모형은 자살 고위험군에 해당하는 사람을 기존의 모형에 비해 보다 정확하게 예측하여 행정데이터만을 활용한 고위험군의 식별 가능성을 보여주었다.

머신러닝이 기존 실증분석 방법을 어느 정도까지 근본적으로 바꿔놓을 수 있을지에 대한 논의는 계속 진행 중이며, 이미 정책효과를 예측하는 문제에 뛰어난 성능을 보인 만큼, 앞으로 우리나라의 다양한 정책평가와 정책 설계에도 본격적으로 활용될 것을 기대한다.

Public Policy Evaluation Using Machine Learning

Jaehyun Jung · Hwanoong Lee

This study explores how machine learning methods can be used to evaluate the effectiveness of public finance policies and inform policy decisions.

We first document the characteristics of machine learning to find its own place in the policy evaluation toolbox. Focusing on a different problem that machine learning can address, i.e., the problem of prediction, we briefly discuss how machine learning algorithms work, where they excel, and where they can be most usefully applied.

We then discuss how machine learning can improve the effectiveness of public policies by focusing on two examples-1) a special taxation program on tax-free comprehensive savings for the elderly, the disabled and 2) the suicide prevention program for the elderly. Our first example on the special taxation program is to highlight the importance of detecting heterogeneous treatment effects and thus optimizing resource allocation. The estimation of heterogeneous treatment effects using machine learning can answer the question of which policy targets respond the most to a certain tax or social welfare programs. We find that there can be a certain subgroup that can significantly benefit from the tax-free

savings. Our second example shows how machine learning can improve beneficiary targeting by exploiting increasingly available amounts of administrative data. We illustrate the benefits of machine learning targeting when compared to the standard practice by showing that targeting those groups could potentially gain more from the suicide prevention program.

While we deal with two examples, the machine learning methods applied in this paper can be more broadly considered for other impact evaluation programs and policy targeting tool development.

■ 저자약력

정재현

연세대학교 경영학과 졸업

미국 Columbia Sustainable Development 경제학 박사

현. 한국조세재정연구원 부연구위원

이환웅

연세대학교 경영학과 졸업


미국 Michigan State University 경제학 박사

현. 한국조세재정연구원 부연구위원

연구보고서 20-08

머신러닝(Machine Learning)을 활용한 조세·재정정책의 평가와 설계

발행	2020년 12월 31일
저자	정재현 · 이환웅
발행인	김유찬
발행처	한국조세재정연구원
주소	30147 세종특별자치시 시청대로 336
전화	(044)414-2114(대)
홈페이지	www.kipf.re.kr
등록	1993. 7. 15. 제2014-24호
정가	8,000원
조판 및 인쇄	호정씨앤티
I S B N	979-11-6655-021-8



KOREA INSTITUTE
OF PUBLIC FINANCE

kipf 한국조세재정연구원

30147 세종특별자치시 시청대로 336
TEL: (044)414-2114(代) www.kipf.re.kr



9 791166 550218

ISBN 979-11-6655-021-8